



摘 要

期权定价是金融工程的核心问题之一。Black-Scholes-Merton模型、常弹性方差模型和Heston随机波动率模型是三大经典期权定价框架，其定价问题在数学上均归结为求解相应的偏微分方程：前两者对应二维抛物型方程，Heston引入随机波动率后升至三维。传统数值方法在求解高维偏微分方程时面临维数灾难，计算代价随维度指数增长。物理信息神经网络将偏微分方程残差嵌入损失函数，无需网格剖分，能够有效缓解这一计算瓶颈；然而，现有物理信息神经网络研究大多针对单一定价模型，缺乏将三大模型统一求解的方法，且传统工具要求用户手动指定模型类型和数值参数，对非专业用户门槛较高。

本文研究基于物理信息神经网络与大语言模型的三模型期权定价方法。在物理信息神经网络部分，通过软掩码机制和加法参数化输出，将三大模型的偏微分方程算子统一为单一参数化形式，由一个深层全连接网络同时覆盖三种模型的解映射，无需分别训练独立网络。软掩码通过连续插值函数实现模型间的平滑过渡，当随机波动率参数趋近于零时自动退化为前两种模型，当其较大时激活Heston的随机波动率项；加法参数化以Black-Scholes解析解为基线，网络学习绝对修正量，解决了深度虚值区域的数值退化问题，终值条件通过Black-Scholes公式的极限行为自然满足。在大语言模型部分，引入DeepSeek作为智能路由层，通过结构化输出实现可靠的参数提取和模型选择，支持中英文自然语言输入，使非专业用户无需了解模型细节即可完成期权定价。

实验在合成数据和真实市场数据两类场景下进行评估。结果表明，统一网络在三种模型的平值附近区域均达到较高精度，在Black-Scholes-Merton和常弹性方差模型上的精度优于独立训练的基线方法，具备实时定价能力。消融实验进一步验证了各核心组件的必要性，大语言模型路由层对各类自然语言输入均能准确完成模型选择与参数提取。

关键词： 物理信息神经网络；期权定价；Black-Scholes-Merton模型；CEV模型；Heston模型；大语言模型；软掩码



Abstract

Option pricing is one of the core problems in financial engineering. The Black-Scholes-Merton (BSM) model, the Constant Elasticity of Variance (CEV) model, and the Heston stochastic volatility model constitute three classical option pricing frameworks. Mathematically, all three reduce to solving their respective partial differential equations: BSM and CEV yield two-dimensional parabolic PDEs, while Heston's introduction of stochastic volatility elevates the problem to three dimensions. Traditional numerical methods suffer from the curse of dimensionality when solving high-dimensional PDEs, with computational cost growing exponentially with dimension. Physics-Informed Neural Networks (PINNs) embed PDE residuals directly into the loss function and require no mesh discretization, effectively alleviating this computational bottleneck. However, existing PINN research predominantly targets single pricing models, and a unified framework capable of solving all three models simultaneously remains lacking. Moreover, conventional tools require users to manually specify model types and numerical parameters, posing a high barrier for non-expert users.

This paper investigates a three-model option pricing method based on PINNs and Large Language Models (LLMs). In the PINN component, a soft mask mechanism and additive parameterized output are employed to unify the PDE operators of BSM, CEV, and Heston into a single parameterized form. A single deep fully-connected network simultaneously covers the solution mappings of all three models without training separate networks. The soft mask realizes smooth transitions between models via a continuous interpolation function: when the vol-of-vol parameter approaches zero, the network automatically degrades to the first two models; when it is large, the stochastic volatility terms of Heston are activated. The additive parameterization uses the Black-Scholes analytical solution as a baseline, with the network learning absolute corrections, resolving the numerical degeneracy in deep out-of-the-money regions; the terminal condition is naturally satisfied through the limiting behavior of the Black-Scholes formula. In the LLM component, DeepSeek is introduced as an intelligent routing layer, achieving reliable parameter extraction and model selection via structured output, supporting natural language input in both Chinese and English, so that non-expert users can complete



option pricing without knowledge of model internals.

Experiments are conducted on two types of scenarios: synthetic data and real market data. Results demonstrate that the unified network achieves high accuracy near the at-the-money region across all three models, and outperforms independently trained baseline methods on BSM and CEV, with real-time pricing capability. Ablation studies further validate the necessity of each core component, and the LLM routing layer accurately completes model selection and parameter extraction for diverse natural language inputs.

Keywords: Physics-Informed Neural Networks; Option Pricing; Black-Scholes-Merton Model; CEV Model; Heston Model; Large Language Models; Soft Mask



目 录

第一章 引言	1
1.1 研究背景	1
1.2 现有工作的局限性	1
1.3 研究目标与贡献	2
1.4 论文结构	2
第二章 相关背景	3
2.1 期权定价模型	3
2.2 物理信息神经网络	4
2.3 大语言模型辅助科学计算	6
2.4 本章小结	6
第三章 三种期权模型求解方法	7
3.1 基于PDE方程的期权定价模型	7
3.2 PINN训练方法	9
3.2.1 网络架构与加法参数化输出	9
3.2.2 损失函数与配点采样	10
3.3 LLM路由层	11
3.4 参数化PINN对比方法	12
3.5 本章小结	13
第四章 实验评估与市场验证	14
4.1 实验参数	14
4.2 数据集	14
4.3 评估指标	15
4.4 消融实验	15
4.5 实验结果	16
4.6 本章小结	20
第五章 结论	21
5.1 工作总结	21
5.2 局限性与未来工作	21



附录 A 代码架构与关键实现	23
A.1 三模型PINN核心模型	23
A.1.1 网络定义伪代码	23
A.1.2 统一PDE残差计算伪代码	24
A.2 LLM路由层实现	25
A.2.1 系统提示词	25
A.2.2 参数校验伪代码	26
A.3 参考解实现	26
A.3.1 BSM解析解	26
A.3.2 Heston半解析解（特征函数方法）	27
A.4 训练配置	27
参考文献	28
致谢	30



符号列表

状态变量

符号	含义
S	标的资产（股票）当前价格
$V(S, t)$	欧式期权价值（BSM/CEV模型）
$V(S, v, t)$	欧式期权价值（Heston模型）
v	瞬时方差（Heston模型中的随机波动率状态变量）
t	当前时刻
T	期权到期时刻
$\tau = T - t$	剩余到期时间

期权合约参数

符号	含义
K	期权执行价（Strike Price）
r	无风险利率（连续复利）

BSM模型参数

符号	含义
σ	标的资产的常数波动率（BSM）或尺度参数（CEV）
μ	标的资产的漂移率
W_t	标准布朗运动

CEV模型参数

符号	含义
β	弹性参数，控制波动率对股价的依赖程度； $\beta = 1$ 退化为BSM， $\beta < 1$ 产生杠杆效应

Heston模型参数

符号	含义
----	----



κ	方差过程的均值回归速度, $\kappa > 0$
θ	方差过程的长期均值 (长期方差)
ξ	方差过程的波动率 (vol-of-vol)
v_0	初始瞬时方差
W_t^S	驱动股价过程的标准布朗运动
W_t^v	驱动方差过程的标准布朗运动
ρ	股价布朗运动 W_t^S 与方差布朗运动 W_t^v 的相关系数, $\rho \in (-1, 1)$

三模型PINN方法符号

符号	含义
λ	模型参数向量 $(\sigma, \beta, \kappa, \theta, \xi, \rho)$
$\mathcal{F}[\cdot]$	统一PDE算子
mask	软掩码 $\tanh(\xi/0.05)^2$, 用于在BSM/CEV与Heston之间连续插值
σ_{eff}	等效波动率, 用于加法参数化中的Black-Scholes基线计算
V_{BS}	Black-Scholes解析解, 作为加法参数化的基线
$\hat{V}$	三模型PINN的期权价格预测值
$\text{net}(x)$	神经网络输出的修正量 (以 K 为单位)
$\mathcal{L}$	总损失函数
$\mathcal{L}_{\text{pde}}$	PDE残差损失
$\mathcal{L}_{\text{bc}}$	边界条件损失
$\mathcal{L}_{\text{ic}}$	初值 (终值) 条件损失, 即到期日 $t = T$ 处的终值条件残差
$\mathcal{L}_{\text{data}}$	数据驱动锚点损失
w_{pde}	PDE残差损失的权重系数
w_{bc}	边界条件损失的权重系数
w_{data}	数据锚点损失的权重系数
N_c	每训练步的PDE配点数
N_b	边界条件采样点数
N_d	数据锚点数
$\Phi(\cdot)$	标准正态累积分布函数



评估指标

符号 含义

MAE 平均绝对误差 (Mean Absolute Error)

RMSE 均方根误差 (Root Mean Square Error)

$\text{RelMAE}_{\text{ATM}}$ 平值附近区域的平均相对误差

缩写

缩写 全称

BSM Black-Scholes-Merton模型

CEV Constant Elasticity of Variance, 常弹性方差模型

PINN Physics-Informed Neural Network, 物理信息神经网络

ICPINN Improved Constrained PINN, 改进约束物理信息神经网络

LLM Large Language Model, 大语言模型

PDE Partial Differential Equation, 偏微分方程

ATM At-The-Money, 平值期权 ($S \approx K$)

OTM Out-of-The-Money, 虚值期权 (看涨期权 $S < K$)

ITM In-The-Money, 实值期权 (看涨期权 $S > K$)

CIR Cox-Ingersoll-Ross过程, 用于Heston模型的方差过程

FFT Fast Fourier Transform, 快速傅里叶变换

API Application Programming Interface, 应用程序接口



第一章 引言

1.1 研究背景

期权是金融衍生品市场的核心工具，广泛应用于风险对冲与投机套利。自Black、Scholes与Merton于1973年提出BSM模型^[1,2]以来，期权定价理论经历了从常数波动率到局部波动率、再到随机波动率的持续演进。BSM模型以常数波动率假设为基础，具有封闭解析解，适用于短期定价，但无法解释市场中普遍存在的波动率微笑现象。为此，Cox和Ross^[3]提出了常弹性方差（Constant Elasticity of Variance, CEV）模型，将波动率推广为依赖于标的价格的局部波动率形式，能够捕捉股票市场的杠杆效应。Heston^[4]进一步引入随机波动率过程，更准确地描述波动率微笑和厚尾收益率分布，但其二维偏微分方程（Partial Differential Equation, PDE）的数值求解代价显著高于一维情形。

上述三大模型的定价问题在数学上均归结为求解相应的PDE。传统数值方法（有限差分、有限元）在求解高维PDE时面临维数灾难：网格点数随维度指数增长，Heston这样的二维模型已需要大量计算资源，而更高维的随机波动率模型几乎无法实时求解。此外，传统工具要求用户手动指定模型类型和全部数值参数，对非专业用户门槛较高。

物理信息神经网络（Physics-Informed Neural Network, PINN）^[5]将PDE残差直接嵌入损失函数，无需网格剖分，训练完成后可对任意输入即时推断，能够有效缓解上述计算瓶颈。近年来，PINN已被应用于BSM^[6]、CEV^[12]、Heston^[8,9]等期权定价模型，验证了神经网络求解期权定价PDE的可行性。与此同时，大语言模型（Large Language Model, LLM）在自然语言理解和结构化信息提取方面取得了突破性进展^[10]，为构建自然语言驱动的科学计算接口提供了基础。

1.2 现有工作的局限性

尽管现有PINN期权定价研究已取得一定进展，但仍存在两方面主要不足。

一方面，现有工作（Dhiman等^[6]、Hainaut等^[8]）均针对单一模型分别训练独立的PINN，三个模型之间无法共享网络权重。当需要同时支持多种定价模型时，必须维护多套独立的训练流程和模型文件，不仅增加了工程复杂度，也无法利用不同模型之间PDE结构的内在联系。

另一方面，现有PINN工具要求用户手动指定模型类型和所有数值参数。选



选择合适的定价模型本身需要量化金融背景，普通用户难以判断在当前市场条件下应使用BSM、CEV还是Heston，这在一定程度上限制了PINN期权定价工具的实际应用范围。

1.3 研究目标与贡献

本文研究基于物理信息神经网络与大语言模型的三模型期权定价方法，旨在解决上述两方面不足。在方法设计上，本文的主要贡献可概括如下。

本文提出软掩码机制，将三大模型的扩散系数统一为连续参数化形式，避免了硬切换带来的梯度不连续问题，实现了BSM、CEV与Heston之间的平滑过渡。在此基础上，采用加法参数化输出，以Black-Scholes解析解为基线，网络学习绝对修正量，从根本上解决了深度虚值区域的数值退化问题，同时为网络提供了量级正确的训练起点。通过上述设计，单一深层全连接网络可同时覆盖三种模型的解映射，无需分别训练独立网络，三模型联合训练还带来了互相增益：BSM/CEV的简单结构为Heston提供了良好的初始化，有助于克服二维PDE的收敛困难。

在交互方式上，本文引入DeepSeek LLM作为智能路由层，通过结构化JSON输出实现可靠的参数提取与模型选择，支持中英文自然语言输入，使非专业用户无需了解模型细节即可完成期权定价。

实验在合成数据和真实市场数据两类场景下进行评估。结果表明，三种模型的平值附近相对误差均低于1%，在BSM和CEV上的精度优于独立训练的PINN基线，单次推断耗时约2毫秒，具备实时定价能力。消融实验进一步验证了各核心组件的必要性。

1.4 论文结构

本文内容组织如下。第二章介绍三大期权定价模型的PDE形式、物理信息神经网络的基本原理及其在期权定价中的应用，以及大语言模型辅助科学计算的进展。第三章介绍基于大模型和PINN的三模型期权求解方式，包括统一PDE算子、软掩码机制、加法参数化输出、网络架构、损失函数、训练策略和LLM路由层。第四章报告实验结果，包括精度评估、消融实验和真实SPY期权市场回溯。第五章总结全文并讨论局限性与未来工作方向。



第二章 相关背景

2.1 期权定价模型

期权定价理论的核心是建立标的资产价格动态与期权价值之间的数学关系。三大经典定价模型均以随机微分方程描述标的资产的价格过程，并通过无套利原理推导出相应的PDE，其结构差异正是本文统一框架设计的出发点。

Black、Scholes与Merton于1973年提出了期权定价的奠基性框架^[1,2]。该框架假设标的资产价格 S 服从几何布朗运动：

$$dS = \mu S dt + \sigma S dW_t, \quad (2.1)$$

其中 σ 为常数波动率， W_t 为标准布朗运动。通过无套利原理，欧式期权价值 $V(S, t)$ 满足BSM方程：

$$\frac{\partial V}{\partial t} + \frac{1}{2}\sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} + rS \frac{\partial V}{\partial S} - rV = 0, \quad (2.2)$$

其中 r 为无风险利率。欧式看涨期权具有封闭解析解（Black-Scholes公式）：

$$V_{BS}(S, t) = S\Phi(d_1) - Ke^{-r(T-t)}\Phi(d_2), \quad (2.3)$$

其中 $d_1 = \frac{\ln(S/K) + (r + \sigma^2/2)(T-t)}{\sigma\sqrt{T-t}}$ ， $d_2 = d_1 - \sigma\sqrt{T-t}$ ， $\Phi(\cdot)$ 为标准正态累积分布函数。BSM模型的主要局限在于假设波动率为常数，无法解释市场中普遍存在的波动率微笑现象。

为克服上述局限，Cox和Ross^[3]提出了常弹性方差（Constant Elasticity of Variance, CEV）模型，将扩散系数推广为依赖于标的价格的局部波动率：

$$dS = \mu S dt + \sigma S^\beta dW_t, \quad (2.4)$$

其中 β 为弹性参数。当 $\beta = 1$ 时退化为BSM；当 $\beta < 1$ 时，波动率随股价上涨而下降，能够捕捉股票市场的杠杆效应。对应的期权定价PDE为：

$$\frac{\partial V}{\partial t} + \frac{1}{2}\sigma^2 S^{2\beta} \frac{\partial^2 V}{\partial S^2} + rS \frac{\partial V}{\partial S} - rV = 0. \quad (2.5)$$

本文取 $\beta = 0.5$ （平方根过程）。Schroder^[11]指出， $\beta = 0.5$ 时CEV欧式看涨期权存在精确解析解（非中心卡方分布），本文以此作为CEV的参考基准。



进一步地, Heston^[4]将波动率建模为均值回归过程 (CIR过程), 引入随机波动率:

$$dS = \mu S dt + \sqrt{v} S dW_t^S, \quad (2.6)$$

$$dv = \kappa(\theta - v) dt + \xi \sqrt{v} dW_t^v, \quad (2.7)$$

其中 v 为瞬时方差, κ 为均值回归速度, θ 为长期均值, ξ 为vol-of-vol, dW_t^S 与 dW_t^v 的相关系数为 ρ 。期权价值 $V(S, v, t)$ 满足二维PDE:

$$\frac{\partial V}{\partial t} + \frac{1}{2}vS^2\frac{\partial^2 V}{\partial S^2} + \rho\xi vS\frac{\partial^2 V}{\partial S\partial v} + \frac{1}{2}\xi^2v\frac{\partial^2 V}{\partial v^2} + rS\frac{\partial V}{\partial S} + \kappa(\theta - v)\frac{\partial V}{\partial v} - rV = 0. \quad (2.8)$$

Heston模型具有半解析解 (特征函数方法与Gil-Pelaez反演), 能够产生波动率微笑和厚尾收益率分布, 在指数期权和外汇期权中被广泛使用。Feller条件 $2\kappa\theta > \xi^2$ 保证方差过程 v 始终为正。

2.2 物理信息神经网络

物理信息神经网络 (Physics-Informed Neural Network, PINN) 由Raissi等人^[5]于2019年提出, 其核心思想是将PDE残差直接嵌入神经网络的损失函数, 从而在无需网格剖分的情况下求解偏微分方程。对于PDE $\mathcal{F}[u] = 0$, PINN的总损失为:

$$\mathcal{L} = w_{\text{pde}}\mathcal{L}_{\text{pde}} + w_{\text{ic}}\mathcal{L}_{\text{ic}} + w_{\text{bc}}\mathcal{L}_{\text{bc}}, \quad (2.9)$$

其中各项分别为配点处的PDE残差、初值条件和边界条件的均方误差, $w_{\text{pde}}, w_{\text{ic}}, w_{\text{bc}}$ 为权重超参数。PDE残差通过自动微分精确计算, 无需有限差分近似。PINN无需网格剖分, 训练完成后对任意输入的推断时间约为毫秒级, 具备实时定价的潜力。

在期权定价领域, Dhiman和Hu^[6]率先将PINN应用于欧式和美式期权定价, 提出了门控网络结构, 通过浅层分支与深层分支的加权组合分别捕捉解的简单特征与复杂特征。Zamxaka^[12]系统研究了PINN对BSM和CEV模型的求解, 构建了参数化PINN, 使单个网络可在不同参数设置下直接推断期权价格。针对Heston模型, Hainaut和Casas^[8]构建了参数化PINN, 将模型参数与合约特征联合作为网络输入, 实现了训练一次、多参数组合即时定价; 该模型以PUT期权为输出, 通过put-call parity转换为CALL价格, 本文将其作为参数化Heston PINN的对比基准。Guo等人^[9]提出了改进约束PINN (Improved Constrained PINN, ICPINN), 通过输出变换将终值条件硬编码进网络结构, 减少损失函数中的冲突项, 加速



收敛。上述参数化PINN工作的共同思路是将模型参数直接作为网络输入，使单个网络覆盖整个参数空间；然而，现有参数化PINN均针对单一定价模型，不同模型之间的PDE结构差异使得跨模型统一存在本质困难。本文在此基础上，通过软掩码机制将三大模型的PDE算子统一为单一参数化形式，实现了真正意义上的三模型统一框架。

为提供可靠的对比基准，本文对上述三类代表性PINN方法进行了独立复现。**BSM-PINN**与**CEV-PINN**均采用Dhiman和Hu^[6]的门控网络结构：浅层分支（2层×64，Tanh）与深层分支（4层×64，Tanh）通过可学习的sigmoid门加权融合，输入为归一化的 $(S/S_{\max}, t/T)$ ，输出为归一化期权价值 $u = V/K$ 。**CEV-PINN**将扩散系数替换为 $\sigma^2 S^{2\beta}$ 。**Hainaut & Casas参数化PINN**^[8]采用跳跃连接网络（SkipNet）：4层×256神经元，每层接收前一层输出与原始输入的拼接，输入为9维向量 $(t, S, v, r, \kappa, \theta, \xi, \rho, T)$ ，经z-score归一化，输出PUT期权价格，通过put-call parity转换为CALL价格。三种方法的训练参数与复现结果汇总于表 2.1。

表 2.1 三种独立PINN复现结果 ($S \in [50, 250]$, $t = 0$)

模型	参考基准	MAE	RelMAE	训练参数范围
BSM-PINN	解析解	0.016	0.6%	$\sigma = 0.20$
CEV-PINN	Schroder解析解	0.074	1.69% [†]	$\sigma = 0.20$, $\beta = 0.5$
Hainaut & Casas (2024)	GL半解析解	—	9.169% [‡]	$\kappa \in [0.5, 2.0]$, $\theta \in [0.062, 0.42]$ $\xi \in [0.1, 0.9]$, $\rho \in [-0.8, 0.8]$

[†]仅统计 $V^* > 0.5$ 区域。[‡]经put-call parity转换为CALL价格，仅统计 $S/K \geq 0.85$ 区域。

上述三个独立PINN验证了各模型PDE的可解性，并为后续三模型方法提供了精度基准。

近年来，针对期权定价PDE的PINN求解效率，研究者提出了多种改进方向。部分工作通过时间分解能量最小化加速Heston模型的训练收敛；另一类工作引入自适应配点策略，在到期日附近 ($t \rightarrow T$) 和平值附近 ($S \approx K$) 集中采样，缓解收益函数折点处的残差集中问题；此外，基于极限学习机的方法利用闭式训练实现前向求解的大幅加速。本文方法与上述工作的主要区别在于：本文目标是单一网络统一三种模型，而非针对单一模型优化求解效率；上述技术（自适应配点、极限学习机）可作为正交改进方向与本文框架结合，留作未来工作。



2.3 大语言模型辅助科学计算

近年来，大语言模型在辅助科学计算方面展现出越来越强的能力。Liu等人^[10]提出了PDE-AGENT，一个工具链增强的多智能体框架，能够从自然语言描述出发，自动调用数值求解工具完成PDE的求解。该工作表明LLM具备理解PDE问题结构、选择合适求解策略的能力。在金融领域，Xiao等人^[13]提出了TradingAgents框架，通过多个专业化LLM智能体的协作完成金融交易决策，验证了LLM在金融场景下的参数提取与任务路由能力。

现代LLM（如GPT-4、DeepSeek等）能够通过约束输出格式（如JSON模式）可靠地从自然语言中提取结构化参数。本文的LLM路由层设计较PDE-AGENT更为轻量：LLM仅负责参数提取和模型选择，不参与PDE求解过程，因此延迟更低（约500ms至2000ms的API调用）、可靠性更高（结构化JSON输出避免了自由文本解析的不确定性）。

2.4 本章小结

本章梳理了BSM、CEV、Heston三大期权定价模型的PDE形式，回顾了物理信息神经网络在期权定价中的代表性工作，并介绍了大语言模型辅助科学计算的进展。现有PINN工作验证了神经网络求解期权定价PDE的可行性，但缺乏统一的三模型框架和自然语言交互能力。本文在此基础上构建了大语言模型与PINN相结合的统一期权定价系统，具体方法见第三章。



第三章 三种期权模型求解方法

本章介绍三模型PINN期权定价方法的完整设计。核心思路是：通过软掩码机制将BSM、CEV、Heston三大模型的PDE算子统一为单一参数化形式，以加法参数化输出解决深度虚值区域的数值退化问题，并引入LLM路由层支持自然语言输入。图 3.1给出了系统的三层架构概览。




图 3.1 三模型期权定价系统三层架构。交互层：用户以自然语言输入期权需求，LLM路由层提取参数并选择模型，输出结构化JSON。求解层：三模型PINN求解器通过软掩码 ($\text{mask} = \tanh^2(\xi/0.05)$) 和加法参数化 ($\hat{V} = V_{BS}(\sigma_{\text{eff}}) + K \cdot \text{Net}(\mathbf{x})$) 统一三大模型PDE，训练时以解析解/半解析解作为数据锚点。输出层：单次前向传播 ($\sim 2 \text{ ms}$) 返回期权价格及Greeks。

3.1 基于PDE方程的期权定价模型

本文涉及的三大期权定价模型均以偏微分方程为核心，其结构差异正是统一框架设计的出发点。BSM模型（式 (2.2)）以常数波动率 σ 为唯一随机性来源，



存在封闭解析解，本文将其作为加法参数化的基线：

$$V_{BS}(S, \tau; \sigma) = S\Phi(d_1) - Ke^{-r\tau}\Phi(d_2), \quad (3.1)$$

$$d_1 = \frac{\ln(S/K) + (r + \sigma^2/2)\tau}{\sigma\sqrt{\tau}}, \quad d_2 = d_1 - \sigma\sqrt{\tau}. \quad (3.2)$$

CEV模型（式 (2.5)）将扩散系数推广为 $\sigma^2 S^{2\beta}$ ，本文取 $\beta = 0.5$ ，以Schroder非中心卡方解析解作为数据锚点。Heston模型（式 (2.8)）引入随机方差 v ，PDE升至二维，以特征函数半解析解作为数据锚点。

三大模型的PDE均可写为如下统一算子：

$$\mathcal{F}[V] = \frac{\partial V}{\partial t} + \frac{1}{2}a(S, v; \lambda)\frac{\partial^2 V}{\partial S^2} + b(S, v; \lambda)\frac{\partial^2 V}{\partial S \partial v} + \frac{1}{2}c(v; \lambda)\frac{\partial^2 V}{\partial v^2} + rS\frac{\partial V}{\partial S} + d(v; \lambda)\frac{\partial V}{\partial v} - rV = 0, \quad (3.3)$$

其中参数向量 $\lambda = (\sigma, \beta, \kappa, \theta, \xi, \rho)$ 控制各系数，具体对应关系如表 3.1所示。

表 3.1 统一PDE算子系数与三大模型的对应关系

模型	$a(S, v; \lambda)$	$b(S, v; \lambda)$	$c(v; \lambda)$	$d(v; \lambda)$
BSM	$\sigma^2 S^2$	0	0	0
CEV	$\sigma^2 S^{2\beta}$	0	0	0
Heston	vS^2	$\rho\xi vS$	$\xi^2 v$	$\kappa(\theta - v)$

利用软掩码 $m = \tanh^2(\xi/0.05)$ ，统一PDE算子的各系数具体实现为：

$$a = (1 - m) \cdot \sigma^2 S^{2\beta} + m \cdot vS^2, \quad (3.4)$$

$$b = m \cdot \rho\xi vS, \quad (3.5)$$

$$c = m \cdot \xi^2 v, \quad (3.6)$$

$$d = m \cdot \kappa(\theta - v). \quad (3.7)$$

当 $\xi = 0$ 时， $m = 0$ ， $b = c = d = 0$ ，算子精确退化为一维BSM/CEV方程；当 $\xi \geq 0.3$ 时， $m \approx 0.998$ ，算子精确对应Heston二维PDE。推断时对所有输入强制 $\xi \in \{0\} \cup [0.2, \infty)$ ，避免中间值产生无金融意义的混合算子。为实现三大模型之间的连续插值，本文引入软掩码：

$$\text{mask} = \tanh\left(\frac{\xi}{0.05}\right)^2. \quad (3.8)$$

当 $\xi \rightarrow 0$ 时， $\text{mask} \rightarrow 0$ ；当 $\xi = 0.3$ 时， $\text{mask} \approx 0.998$ 。利用软掩码，扩散系数 a 统一为：

$$a = (1 - \text{mask}) \cdot \sigma^2 S^{2\beta} + \text{mask} \cdot vS^2. \quad (3.9)$$



当 $\xi = 0$ 时, $a = \sigma^2 S^{2\beta}$, 精确退化为BSM/CEV扩散项; 当 $\xi = 0.3$ 时, $a \approx v S^2$, 精确对应Heston扩散项。




图 3.2 软掩码函数 $\text{mask} = \tanh^2(\xi/0.05)$ 随vol-of-vol参数 ξ 的变化。 $\xi \rightarrow 0$ 时mask趋近于0, 扩散系数退化为BSM/CEV形式; $\xi = 0.3$ 时 $\text{mask} \approx 0.998$, 对应Heston随机波动率结构。函数在 $[0, 0.5]$ 区间内单调平滑过渡, 避免硬切换引起的梯度不连续。

软掩码的连续插值特性使网络可以学习到平滑的参数依赖关系, 避免了硬切换在 ξ 附近产生的梯度不连续问题 (消融实验见第 4.4 节)。

3.2 PINN训练方法

3.2.1 网络架构与加法参数化输出

直接用神经网络输出期权价格存在两个问题: 其一, 初始化困难, 随机初始化的网络输出量级约为 10^{-1} , 而期权价格量级约为 10^0 至 10^2 ; 其二, 深度虚值退化, 乘法参数化 $V = V_{BS} \cdot (1 + \text{net})$ 在 $V_{BS} \rightarrow 0$ 时退化。为此, 本文采用加法参数化输出:

$$\hat{V}(S, v, t; \lambda) = V_{BS}(S, \tau; \sigma_{\text{eff}}) + K \cdot \text{net}(x), \quad (3.10)$$

其中等效波动率通过软掩码计算:

$$\sigma_{\text{eff}} = (1 - \text{mask}) \cdot \sigma + \text{mask} \cdot \sqrt{v}. \quad (3.11)$$

σ_{eff} 的设计原则是: 当 $\xi = 0$ 时退化为BSM波动率 σ , 当 $\xi > 0$ 时以当前方差 $\sqrt{v}$ 替代, 使Black-Scholes基线在三种模型下均能提供合理的价格量级初始化; 对于BSM/CEV输入, $v = v_0 = \sigma^2$, 故 $\sigma_{\text{eff}} = \sigma$ 。网络最后一层权重初始化为 $\mathcal{N}(0, 0.001^2)$, 使训练开始时 $K \cdot \text{net} \approx 0$, 网络从接近正确答案的位置开始优化。深度虚值时 $V_{BS} \rightarrow 0$,



但 $K \cdot \text{net}$ 仍可输出非零修正，网络可以学习到CEV/Heston相对于BSM的价格差异。

网络输入为9维向量 $\mathbf{x} \in \mathbb{R}^9$ ，各维度的含义与归一化方式如表 3.2所示。

表 3.2 统一PINN网络输入编码

维度	变量	归一化	BSM/CEV取值	Heston取值
1	$S/S_{\max}$	$[0, 1]$	$S/300$	$S/300$
2	$v/v_{\max}$	$[0, 1]$	$v_0/1$	$v/1$
3	t/T	$[0, 1]$	t/T	t/T
4	σ	原始值	σ	0
5	β	原始值	1.0 (BSM) / 0.5 (CEV)	0
6	κ	原始值	0	κ
7	θ	原始值	0	θ
8	ξ	原始值	0	ξ
9	ρ	原始值	0	ρ

对于BSM/CEV模型， v 维度取 $v_0 = \sigma^2$ （初始方差），Heston专属参数 $(\kappa, \theta, \xi, \rho)$ 填0；网络通过 $\xi = 0$ 自动识别模型类型，与软掩码机制一致。网络采用6层全连接结构，每层128个神经元，激活函数为 $\tanh$ ：

$$h_0 = x \in \mathbb{R}^9, \quad (3.12)$$

$$h_l = \tanh(W_l h_{l-1} + b_l), \quad l = 1, \dots, 6, \quad (3.13)$$

$$\text{net}(x) = W_7 h_6 + b_7 \in \mathbb{R}. \quad (3.14)$$

最后一层权重初始化为 $\mathcal{N}(0, 0.001^2)$ ，偏置初始化为0，确保训练开始时 $\text{net} \approx 0$ 。 $\tanh$ 激活函数光滑且高阶导数有界，适合PINN中需要计算二阶偏导数的场景。当 $t = T$ 时， $\tau = T - t = 0$ ，Black-Scholes公式自动退化为终值条件 $V_{\text{BS}}(S, 0; \sigma_{\text{eff}}) = \max(S - K, 0)$ ；同时，网络最后一层的小初始化确保修正量 $K \cdot \text{net}$ 在训练初期接近0，不破坏终值条件的满足，这一设计参考了Guo等人^[9]的ICPINN方法。

3.2.2 损失函数与配点采样

三模型PINN的总损失由PDE残差、边界条件和数据锚点三部分组成：

$$\mathcal{L}(\theta) = w_{\text{pde}} \mathcal{L}_{\text{pde}} + w_{\text{bc}} \mathcal{L}_{\text{bc}} + w_{\text{data}} \mathcal{L}_{\text{data}}. \quad (3.15)$$



配点是PINN训练的核心数据来源，完全由求解域的几何结构决定，无需任何真实市场观测数据。对每个参数变体在求解域 $\Omega = [0, S_{\max}] \times [0, v_{\max}] \times [0, T]$ 内均匀随机采样 $N_c = 5000$ 个配点，每个训练步骤重新采样（online sampling），避免过拟合到固定配点集。对于BSM/CEV模型， v 维度退化为常数，配点实际为二维；对于Heston模型，配点为完整三维。边界配点在各边界面上均匀采样 $N_b = 500$ 个点。数据锚点在 $t = 0$ 处取 $N_d = 20$ 个均匀分布的 S 值，对应价格由参考解析解预先计算，这是训练中唯一涉及“真实”（解析）价格的部分。

PDE残差损失在求解域内随机采样 N_c 个配点，计算统一PDE算子的相对残差：

$$\mathcal{L}_{\text{pde}} = \frac{1}{N_c} \sum_{i=1}^{N_c} \left(\frac{\mathcal{F}[\hat{V}](S_i, v_i, t_i)}{|\hat{V}(S_i, v_i, t_i)| + 1} \right)^2. \quad (3.16)$$

分母中的 $|\hat{V}|+1$ 为相对残差归一化项，避免ATM区域的残差主导损失，使OTM区域也能获得足够的梯度信号。边界条件设置为 $V(0, v, t) = 0$ ， $V(S_{\max}, v, t) = S_{\max} - Ke^{-r(T-t)}$ ， $V(S, v_{\max}, t) \approx S$ ，边界条件损失为对应边界目标值的均方误差。纯PDE约束存在解不唯一的数值问题，数据驱动锚点损失在 $t = 0$ 处以参考解析解为目标：

$$\mathcal{L}_{\text{data}} = \frac{1}{N_d} \sum_{j=1}^{N_d} \left(\hat{V}(S_j, v_j, 0) - V_j^* \right)^2, \quad (3.17)$$

其中 V_j^* 为参考解。损失权重设置为 $(w_{\text{pde}}, w_{\text{bc}}, w_{\text{data}}) = (1, 10, 100)$ ，其中 $w_{\text{data}} = 100$ 确保网络在已知解处精确拟合，防止PDE约束将解推向错误方向；消融实验验证了此权重组合的必要性（见第4.4节）。

训练时对72个参数变体（6 BSM + 12 CEV + 54 Heston）同时采样配点：每个训练步骤中，每个参数变体各采样5000个配点，拼接后计算统一PDE残差。这一策略确保网络在三种模型的参数空间中均匀训练，避免某一模型主导损失。使用Adam优化器^[14]，初始学习率 10^{-3} ，余弦退火学习率调度（ $\eta_{\min} = 10^{-5}$ ），总训练轮数30000轮，在NVIDIA GPU上约需1小时。

3.3 LLM路由层

三种定价模型分别适用于不同的市场假设，传统工具要求用户手动指定模型类型和全部数值参数。本文引入DeepSeek LLM作为智能路由层，使用户可以通过自然语言描述期权需求，由LLM自动完成模型选择和参数提取。

系统提示词将LLM角色定义为“期权定价参数提取器”，规定模型选择规则：仅提供 σ 则选BSM，提及 β 或“CEV”则选CEV，提供 $\kappa, \theta, \xi, \rho, v_0$ 或提及“Heston”/“stochastic



volatility"则选Heston，默认BSM。对用户未提及的参数使用典型默认值 ($S = 100$, $K = 100$, $T = 1.0$, $r = 0.05$, $\sigma = 0.2$, $\beta = 0.5$, $v_0 = 0.04$, $\kappa = 2.0$, $\theta = 0.04$, $\xi = 0.3$, $\rho = -0.7$), 并通过`response_format: json_object`强制输出合法JSON。LLM的输出遵循以下JSON Schema:

```
{
  "model": "bsm" | "cev" | "heston",
  "option_type": "call" | "put",
  "S": float, "K": float, "T": float, "r": float,
  "sigma": float, "beta": float,
  "v0": float, "kappa": float, "theta": float,
  "xi": float, "rho": float
}
```

系统在接收到JSON输出后，进行参数范围校验（如 $\sigma > 0$, $\beta \in (0, 1]$, $\xi > 0$, $\rho \in (-1, 1)$ ），对越界参数截断至合法范围，再传入三模型PINN求解器。对于欧式看跌期权，通过看跌-看涨平价关系转换：

$$P = C - S + Ke^{-r(T-t)}. \quad (3.18)$$

鲁棒性方面，对于单位歧义（如“到期时间30天”与“到期时间0.082年”），系统提示词明确要求LLM将所有时间参数统一转换为年为单位输出。对于缺失字段，LLM使用预设默认值填充，不产生空值。本文的LLM路由层定位为教育和研究工具的前端接口，生产环境部署需额外增加规则校验层和审计日志。完整定价流程为：用户输入自然语言描述（中英文均可）；LLM提取参数并选择模型；三模型PINN加载预训练权重，构造参数向量 λ ；网络前向传播返回期权价格（约2ms）。

3.4 参数化PINN对比方法

为评估统一框架的有效性，本文同时实现了一个全参数化PINN（Fully Parametric PINN）作为对比基准。该方法将所有模型参数($\sigma, \beta, \kappa, \theta, \xi, \rho$)与合约特征(S, v, τ, K, r)共11维向量直接作为网络输入，采用8层 $\times 256$ 神经元的全连接网络，同样使用加法参数化输出 $\hat{V} = V_{BS}(\sigma_{\text{eff}}) + K \cdot \text{net}(x)$ 和软掩码机制。与三模型PINN的主要区别在于：参数化PINN在更宽的参数范围内（BSM: $\sigma \in [0.05, 0.50]$ ；



CEV: $\sigma \in [0.10, 0.30]$, $\beta \in [0.10, 0.90]$; Heston: $\kappa \in [0.5, 10]$, $\xi \in [0.05, 0.50]$, $\rho \in [-0.95, -0.10]$ 随机采样训练, 理论上具有更强的参数泛化能力, 但网络容量需求更高 (参数量约为三模型PINN的4倍)。

3.5 本章小结

本章介绍了三种期权模型求解方法。核心创新在于: (1) 软掩码机制将三大模型的PDE算子统一为单一参数化形式, 实现模型间的连续插值; (2) 加法参数化输出以Black-Scholes解析解为基线, 解决了深度虚值区域的数值退化问题; (3) LLM路由层通过结构化输出实现可靠的参数提取和模型选择, 并支持欧式看涨和看跌期权。下一章将报告实验结果。



第四章 实验评估与市场验证

4.1 实验参数

实验中使用的三大模型参数如表 4.1所示，三模型PINN的网络超参数如表 4.2所示。

表 4.1 实验中使用的期权定价模型参数

参数	BSM	CEV	Heston
执行价 K	100	100	100
到期时间 T	1年	1年	1年
无风险利率 r	0.05	0.05	0.05
波动率 σ	0.2	0.2	—
弹性参数 β	1.0	0.5	—
均值回归速度 κ	—	—	2.0
长期方差 θ	—	—	0.04
vol-of-vol ξ	—	—	0.3
相关系数 ρ	—	—	-0.7
初始方差 v_0	0.04	0.04	0.04



表 4.2 三模型PINN网络超参数

超参数	取值
网络层数（深度）	6
每层神经元数（宽度）	128
激活函数	tanh
输入维度	9
输出维度	1
优化器	Adam ^[14]
初始学习率	10^{-3}
学习率衰减	余弦退火 ($\eta_{\min} = 10^{-5}$)
训练步数	30000
每步配点数 N_c	每模型5000点
边界点数 N_b	每模型500点
数据锚点数 N_d	每模型20点
损失权重($w_{\text{pde}}, w_{\text{bc}}, w_{\text{data}}$)	(1, 10, 100)

4.2 数据集

实验在两类数据集上进行评估。合成数据集基于72组参数变体（6 BSM + 12 CEV + 54 Heston）生成，评估点取 $S \in [50, 250]$ 共50个均匀采样点，参考解由各模型的解析解或半解析解预先计算：BSM采用Black-Scholes解析公式（精确解）；CEV采用Schroder非中心卡方分布解析解（精度约 10^{-15} ，由`scipy.stats.ncx2`计算）；Heston采用特征函数半解析法（Gil-Pelaez反演，精度约 10^{-4} ）。

真实市场数据集使用CBOE提供的SPY（标普500 ETF）期权链数据（下载日期：2026年5月11日，SPY现价 $S = 739.75$ 美元），无风险利率取美国1年期国债收益率 $r = 4.3\%$ 。对每个到期日，筛选满足以下条件的看涨合约：隐含波动率 $IV \in (1\%, 200\%)$ 且最新成交价 > 0.10 美元；行权价 $K \in [0.85S, 1.15S]$ （ATM $\pm 15\%$ ），确保Heston特征函数数值积分的稳定性。共筛选出23个到期日，覆盖 $T \in [0.06, 2.59]$ 年的宽泛时间跨度，总计2824个合约，本节从中选取8个代表性到期日进行详细分析。参数校准方面，BSM对每个合约用Brent法反解隐含波动率，取中位数作为全局 σ^* ，校准后的 σ^* 在0.13至0.17之间；CEV最小化加权MSE，用L-BFGS-B多起点优化， $\beta \in (0.01, 1.0]$ ，中长期到期日 β 在0.1至0.5之间，说明SPY期权存在显著的杠杆效应；Heston采用Little Heston Trap稳定公



式^[15]进行半解析定价，8个起点L-BFGS-B优化，参数范围： $\kappa \in [0.05, 20]$ ， $\theta \in [0.001, 0.5]$ ， $\xi \in [0.01, 2.5]$ ， $\rho \in [-0.98, 0]$ ， $v_0 \in [0.001, 0.5]$ 。PINN定价时将真实市场参数归一化至训练域（ $S' = 100$ ， $K' = 100 \cdot K/S$ ），定价结果乘以 $S/100$ 还原至真实价格尺度。

4.3 评估指标

使用以下指标评估精度：

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |\hat{V}_i - V_i^*|, \quad (4.1)$$

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{V}_i - V_i^*)^2}, \quad (4.2)$$

$$\text{RelMAE}_{\text{ATM}} = \frac{1}{|\mathcal{I}|} \sum_{i \in \mathcal{I}} \frac{|\hat{V}_i - V_i^*|}{|V_i^*| + \epsilon}, \quad (4.3)$$

其中 $\mathcal{I} = \{i : S_i \in [80, 120]\}$ 为平值附近区域（ATM）， $\epsilon = 10^{-8}$ 为数值稳定项。相对误差仅在ATM区域计算，避免深度虚值区域（ $V^* \approx 0$ ）导致的数值不稳定。对于涉及Hainaut和Casas^[8]复现模型的Heston评估，指标仅在 $S/K \geq 0.85$ 的数据点上计算，原因在于深度虚值CALL对应深度实值PUT，Hainaut模型直接输出PUT价格再经put-call parity转换，深度实值PUT的绝对价格较大，转换误差被同比例放大，若不加过滤则会不公平地主导整体指标。

4.4 消融实验

为验证各设计组件的必要性，本节进行消融实验，逐一去除三模型PINN方法的关键组件，观察对精度的影响，结果汇总于表 4.3。

将软掩码替换为硬切换（即当 $\xi = 0$ 时完全使用BSM/CEV系数，当 $\xi > 0$ 时完全使用Heston系数），重新训练后BSM精度大幅下降（MAE从0.0005变为2.2771），Heston精度同样显著下降（MAE从0.102变为2.1289），且训练过程出现梯度爆炸，需要降低学习率才能稳定训练。这说明软掩码的连续插值特性对整体训练稳定性至关重要：硬切换在 ξ 附近产生不连续的梯度，导致网络难以同时优化BSM/CEV和Heston两种模式。将加法参数化替换为直接输出（网络直接预测期权价格，不加Black-Scholes基线），重新训练后BSM精度大幅下降（MAE从0.0005变为1.8368），Heston精度同样显著下降（MAE从0.102变为2.3083），深度虚值区域误差尤为突出，验证了加法参数化在初始化和深度虚值稳定性两方面的优势。

去除数据驱动锚点损失 ($w_{\text{data}} = 0$)，仅使用PDE残差和边界条件约束，重新训练后BSM精度下降 (MAE从0.0005变为0.0144)，且训练结果不稳定；Heston精度显著下降 (MAE从0.102变为0.4243)，说明数据锚点对于确定解的唯一性至关重要：纯PDE约束在配点稀疏时存在多个局部最优，数据锚点提供了额外的约束，将解锁定在正确的分支上。

表 4.3 消融实验结果 (BSM和Heston的MAE)

配置	BSM MAE	Heston MAE
完整模型 (软掩码+加法参数化+数据锚点)	0.0005	0.102
去除软掩码 (硬切换)	2.2771	2.1289
去除加法参数化 (直接输出)	1.8368	2.3083
去除数据锚点 (纯PDE约束)	0.0144	0.4243

消融实验表明，三个设计组件均对最终精度有显著贡献。软掩码和加法参数化的影响最为突出：去除任一组件后，BSM和Heston的MAE均上升至1.8以上，说明两者共同构成了统一框架稳定训练的基础。数据锚点的影响相对温和但不可忽视：去除后BSM MAE上升约29倍，Heston MAE上升约4倍，说明锚点对于确定解的唯一性和收敛稳定性均有重要作用。

4.5 实验结果

图 4.1展示了三模型PINN的训练损失曲线。PDE残差损失主导总损失；边界条件损失和数据锚点损失在训练早期快速下降；余弦退火调度使网络在后期持续精细化。72个参数变体的联合训练使网络在宽泛的参数空间上具备良好的泛化能力。




图 4.1 三模型PINN (v16) 训练损失曲线 (30000步, 72个参数变体)。总损失与PDE残差损失同步下降; 边界条件损失和数据锚点损失在训练早期快速收敛至 10^{-5} 量级。

表 4.4给出了三模型PINN与独立PINN和参数化PINN的精度对比, 图 4.2展示了各方法的价格曲线对比结果。三大模型的ATM相对误差均低于1%, 在标准参数集下表现均衡。三模型PINN在BSM和CEV上的精度显著优于独立PINN基线和参数化PINN; 在Heston上参数化PINN略优 (0.430% vs 0.599%), 原因是其训练范围更宽, 但网络参数量约为三模型PINN的4倍, 在BSM和CEV上精度反而更低, 说明软掩码和加法参数化实现了更高效的归纳偏置。Hainaut & Casas (2024) 的较高误差主要来自评估参数轻微超出训练范围以及put-call parity转换引入的额外误差。

表 4.4 各方法精度对比 ($S \in [50, 250]$, $t = 0$)

方法	参考基准	MAE	RelMAE _{ATM}
独立BSM-PINN	BS解析解	0.055	1.311%
独立CEV-PINN	Schroder解析解	0.073	6.053%
Hainaut & Casas (2024)	GL半解析解	—	4.885%
参数化PINN (BSM)	BS解析解	0.003	0.126%
参数化PINN (CEV)	Schroder解析解	0.017	1.230%
参数化PINN (Heston)	GL半解析解	0.078	0.430%
三模型PINN (BSM)	BS解析解	0.0005	0.0009%
三模型PINN (CEV)	Schroder解析解	0.032	0.790%
三模型PINN (Heston)	GL半解析解	0.102	0.599%



表 4.5 三模型PINN按价值区间的相对误差 (RelMAE, $t = 0$, $K = 100$)

模型	深度虚值 ($S/K < 0.80$)	虚值 ($[0.80, 0.95]$)	平值 ($[0.95, 1.05]$)	实值 (> 1.05)
BSM	1.34%	0.11%	0.0006%	0.08%
CEV	— [†]	1.35%	1.28%	0.40%
Heston	51.91% [‡]	0.93%	0.61%	0.26%

[†]CEV深度虚值区域 ($S/K < 0.80$) 内 $V^* \approx 0$, 相对误差分母趋零, 数值不稳定, 记为—。[‡]Heston深度虚值区域相对误差偏高, 原因同上; 绝对误差 (MAE) 在该区域仍处于 10^{-3} 量级。平值区域 ($[0.95, 1.05]$)

与表 4.4 中 RelMAE_{ATM} 一致。




图 4.2 三模型PINN与参考解价格曲线对比 ($t = 0$, $S \in [50, 250]$)。实线为参考解, 虚线为三模型PINN; 竖虚线标记平值点 ($S = K$)。

三模型PINN的推断速度在GPU上约为2ms, CPU上约为8ms, 能够同时支持三种模型, 无需针对不同参数重新计算。训练开销方面, 三模型PINN在单块NVIDIA GPU (float32精度) 上训练30000步约需1小时, 总参数量约10万; 参数化PINN (8层 $\times$ 256) 参数量约40万, 训练时间约3小时; 独立训练三个单模型PINN合计约需2小时, 且无法共享参数。三模型PINN以约一半的训练时间实现了与独立PINN相当或更优的精度, 体现了统一框架的参数效率优势。PINN的另一优势是可通过自动微分直接计算Greeks, 无需额外推导。BSM的Delta、Gamma、Vega平均相对误差均低于0.2% (见表 4.6), 与解析解高度吻合。Heston Delta的平均误差为1.83%, Gamma误差较高 (11.41%), 主要集中在高 κ 、高 ξ 的极端参数区域, 在基准参数设置下与文献中同类工作的精度水平相当 (详见表 4.7)。大语言模型路由层对中英文混合输入、参数顺序不同、参数名称变体均能正确处理, 当用户未明确指定模型但提供了特定参数时, 能够正确推断应使用的模型。

为进一步验证三模型PINN在真实市场条件下的表现, 本节使用第 4.2 节描述的SPY期权链数据, 选取8个代表性到期日进行详细分析。在短期期权 ($T <$



表 4.6 BSM Greeks精度（三模型PINN vs 解析解，平均相对误差）

Greeks	平均相对误差	最大相对误差	评估点数
Delta	0.03%	0.05%	12
Gamma	0.13%	0.28%	12
Vega	0.09%	0.19%	12

表 4.7 Heston Greeks精度（三模型PINN vs 有限差分参考解，平均相对误差）

Greeks	平均相对误差	最大相对误差	评估点数
Delta	1.83%	3.21%	12
Gamma	11.41%	28.70%	12
Vega	2.14%	5.83%	12

0.15年）上，三个校准模型的MAE几乎相同，说明短期波动率微笑较平坦，额外自由度对定价贡献有限。在中长期期权（ $T > 0.25$ 年）上，Heston明显优于BSM：以Aug 21（ $T = 0.271$ ）为例，Heston MAE=\$0.13，仅为BSM MAE（\$1.64）的8%，体现了随机波动率模型在中长期定价中的优势。Sep 30和Dec 31两个到期日误差偏高，可能与季末、年末流动性变化有关，属于市场特殊情况。PINN-BSM的MAE与校准BSM几乎相同（ $T < 0.4$ 年），验证了本文方法的参数泛化性。PINN-Heston的MAE显著高于校准Heston，根本原因在于：训练参数范围（ $\kappa \in [1.0, 3.0]$ ， $\xi \in [0.2, 0.4]$ ）无法覆盖SPY校准得到的极端参数（ κ 可高达20， ξ 可高达2.1）；以及三模型PINN用同一网络拟合三种模型，Heston的5维参数空间构成容量瓶颈，需从架构层面改进，留作未来工作（见第 5.2节）。五种方法相对市场价格的MAE汇总于表 4.8。



表 4.8 五种方法与SPY真实市场价格的MAE对比（单位：美元）

到期日	$T(\text{年})$	n	校准	校准	PINN	PINN	参数化 PINN
			BSM	Heston	-BSM	-Heston	
Jun 05 2026	0.060	197	1.78	0.34	1.78	15.64	27.13
Jun 30 2026	0.129	211	1.46	0.14	1.46	34.30	42.33
Aug 21 2026	0.271	81	1.64	0.13	1.64	73.59	11.19
Sep 30 2026	0.381	145	2.88	0.18	2.88	10.66	14.06
Dec 31 2026	0.633	151	3.30	0.30	3.30	4.98	0.99
Mar 19 2027	0.847	92	3.77	0.19	3.77	6.89	1.13
Dec 17 2027	1.595	98	5.27	0.29	5.27	7.47	4.04
Dec 15 2028	2.592	98	6.50	0.56	6.50	8.93	6.61

4.6 本章小结

三模型PINN（v16）在三大模型上均达到实用精度： $\text{BSM RelMAE}_{\text{ATM}}=0.0009\%$ ， $\text{CEV RelMAE}_{\text{ATM}}=0.79\%$ ， $\text{Heston RelMAE}_{\text{ATM}}=0.599\%$ ，三种模型的ATM相对误差均低于1%。消融实验验证了软掩码、加法参数化和数据锚点三个设计组件的必要性。精度对比实验表明，三模型PINN在BSM和CEV上的精度优于参数化PINN，在Heston上参数化PINN略优，但三模型PINN的网络参数量仅为参数化PINN的约四分之一，具有更高的参数效率。真实市场回测表明，校准Heston在中长期期权上显著优于BSM，PINN-BSM在训练参数范围内具有优异的泛化能力，进一步的架构改进是重要的未来工作方向。



第五章 结论

5.1 工作总结

本文研究了基于物理信息神经网络与大语言模型的三模型期权定价方法。通过软掩码机制和加法参数化输出，将BSM、CEV、Heston三大模型的PDE算子统一为单一参数化形式，由一个网络同时覆盖三种模型的解映射，无需分别训练独立网络。这是首个将三大经典期权定价模型统一在单一PINN网络中的工作，现有研究（Dhiman等^[6]、Hainaut等^[8]）均针对单一模型分别训练，无法共享网络权重。三模型联合训练还带来了互相增益：BSM/CEV的简单结构为Heston提供了良好的初始化，有助于克服二维PDE的收敛困难。

与参数化PINN相比，三模型PINN在BSM和CEV上精度更高，在Heston上参数化PINN略优，但三模型PINN的网络参数量仅为参数化PINN的约四分之一，说明软掩码和加法参数化实现了更高效的归纳偏置。在交互方式上，本文引入大语言模型路由层支持自然语言输入，是PINN与LLM结合用于期权定价的首次尝试；与PDE-AGENT^[10]相比，LLM仅作为路由层而不参与求解，延迟更低、可靠性更高。实验结果表明，三种模型的ATM相对误差均低于1%，推断速度约2ms，消融实验验证了各核心组件的必要性。

5.2 局限性与未来工作

本文的工作存在若干局限性。PINN-Heston在真实市场数据上的泛化能力不足：当前Heston训练参数范围无法覆盖SPY期权校准得到的极端参数，且三模型PINN用同一个网络同时拟合三种模型，Heston的5维参数空间对网络容量要求远高于BSM/CEV，构成根本性的容量瓶颈。此外，当前方法仅针对欧式看涨期权，不支持美式期权或奇异期权；LLM路由层依赖外部API，存在约500ms至2000ms的调用延迟；当前框架仅输出点估计，不提供预测不确定性，而不确定性量化在金融风险管理中至关重要。

基于上述局限性，未来工作可从以下方向展开。在模型扩展方面，可将框架推广至美式期权（处理自由边界问题）和障碍期权（修改边界条件），并针对A股市场（上证50ETF期权、沪深300ETF期权）重新校准参数范围，适配国内数据接口和市场微结构特殊规则。在架构改进方面，可为Heston模型设计专用子网络或增大网络容量，扩大训练参数范围以覆盖真实市场的极端参数；引入



贝叶斯PINN或集成方法提供不确定性估计；将LLM路由层替换为本地部署的小型语言模型，降低API依赖和调用延迟，同时保护用户的期权参数隐私。此外，利用PINN的自动微分能力直接计算Greeks（Delta、Gamma、Vega等），无需有限差分近似，在风险管理中具有重要价值。



附录 A 代码架构与关键实现

本附录介绍三模型PINN期权定价系统的代码架构和关键模块的实现细节，供读者复现实验结果参考。

A.1 三模型PINN核心模型

A.1.1 网络定义伪代码

```
class UnifiedPINN(nn.Module):
```

```
    输入维度: 9 (S/Smax, v/vmax, t/T, sigma, beta,  
                kappa, theta, xi, rho)
```

```
    网络结构: 6层全连接, 每层128神经元, tanh激活
```

```
    最后一层: 权重初始化  $N(0, 0.001^2)$ , 偏置=0
```

```
    前向传播 forward(S, v, t, lambda):
```

```
        # 1. 归一化输入
```

```
        x = [S/300, v/1, t/T, sigma, beta,  
             kappa, theta, xi, rho]
```

```
        # 2. 计算软掩码
```

```
        mask = tanh(xi / 0.05)^2
```

```
        # 3. 计算等效波动率
```

```
        sigma_eff = (1-mask)*sigma + mask*sqrt(v)
```

```
        # 4. 计算BS基线 (解析公式)
```

```
        V_BS = black_scholes(S, K, tau, r, sigma_eff)
```

```
        # 5. 网络修正量
```

```
        net_out = MLP(x) # 6层全连接
```

```
        # 6. 加法参数化输出
```



```
V_hat = V_BS + K * net_out
return V_hat
```

A.1.2 统一PDE残差计算伪代码

```
def compute_pde_residual(model, S, v, t, lambda):
    # 使用自动微分计算偏导数
    V = model(S, v, t, lambda)

    dV_dt = autograd(V, t)
    dV_dS = autograd(V, S)
    d2V_dS2 = autograd(dV_dS, S)
    dV_dv = autograd(V, v)
    d2V_dv2 = autograd(dV_dv, v)
    d2V_dSdv = autograd(dV_dS, v)

    # 软掩码
    mask = tanh(xi / 0.05)^2

    # 统一系数
    a = (1-mask)*sigma^2*S^(2*beta) + mask*v*S^2
    b = mask * rho * xi * v * S
    c = mask * xi^2 * v
    d = mask * kappa * (theta - v)

    # 统一PDE算子
    F = (dV_dt
        + 0.5*a*d2V_dS2
        + b*d2V_dSdv
        + 0.5*c*d2V_dv2
        + r*S*dV_dS
        + d*dV_dv
        - r*V)
```



```
# 相对归一化残差  
residual = F / (|V| + 1)  
return mean(residual^2)
```

A.2 LLM路由层实现

A.2.1 系统提示词

LLM路由层使用以下系统提示词（英文，以提高LLM的理解准确率）：

You are an option pricing parameter extractor.

Extract parameters from user input and output JSON.

Rules for model selection:

- If user mentions "Heston", "stochastic volatility", "vol-of-vol", kappa/theta/xi/rho: use "heston"
- If user mentions "CEV", "constant elasticity", "beta": use "cev"
- Otherwise: use "bsm"

Default values if not specified:

S=100, K=100, T=1.0, r=0.05, sigma=0.2,
beta=0.5, v0=0.04, kappa=2.0, theta=0.04,
xi=0.3, rho=-0.7

Output format (JSON only, no explanation):

```
{  
  "model": "bsm"|"cev"|"heston",  
  "option_type": "call"|"put",  
  "S": float, "K": float, "T": float, "r": float,  
  "sigma": float, "beta": float,  
  "v0": float, "kappa": float, "theta": float,  
  "xi": float, "rho": float  
}
```



A.2.2 参数校验伪代码

```
def validate_params(params):  
    # 范围校验与截断  
    params["sigma"] = clip(params["sigma"], 0.01, 2.0)  
    params["beta"] = clip(params["beta"], 0.1, 1.0)  
    params["kappa"] = clip(params["kappa"], 0.1, 10.0)  
    params["theta"] = clip(params["theta"], 0.001, 1.0)  
    params["xi"] = clip(params["xi"], 0.01, 2.0)  
    params["rho"] = clip(params["rho"], -0.99, 0.99)  
    params["v0"] = clip(params["v0"], 0.001, 1.0)  
    params["T"] = clip(params["T"], 0.01, 10.0)  
    params["S"] = clip(params["S"], 1.0, 1000.0)  
    params["K"] = clip(params["K"], 1.0, 1000.0)  
    return params
```

A.3 参考解实现

A.3.1 BSM解析解

```
def black_scholes(S, K, tau, r, sigma, option_type):  
    if tau <= 0:  
        if option_type == "call":  
            return max(S - K, 0)  
        else:  
            return max(K - S, 0)  
  
    d1 = (log(S/K) + (r + 0.5*sigma^2)*tau) \  
        / (sigma * sqrt(tau))  
    d2 = d1 - sigma * sqrt(tau)  
  
    if option_type == "call":  
        return S*N(d1) - K*exp(-r*tau)*N(d2)  
    else:  
        return K*exp(-r*tau)*N(-d2) - S*N(-d1)
```



A.3.2 Heston半解析解（特征函数方法）

Heston模型的欧式看涨期权价格通过特征函数方法计算：

$$V_{\text{Heston}} = S \cdot P_1 - K e^{-rT} \cdot P_2, \quad (\text{A.1})$$

其中 P_1 和 P_2 通过Gil-Pelaez反演公式计算：

$$P_j = \frac{1}{2} + \frac{1}{\pi} \int_0^\infty \text{Re} \left[\frac{e^{-i\phi \ln K} \varphi_j(\phi)}{i\phi} \right] d\phi, \quad j = 1, 2, \quad (\text{A.2})$$

其中 $\varphi_j(\phi)$ 为Heston模型的特征函数，具体形式见Heston（1993）原文。数值积分使用高斯-勒让德求积，积分上限截断为500，节点数为200，精度约 10^{-4} 。

A.4 训练配置

表 A.1列出了完整的训练配置，供复现实验参考。

表 A.1 三模型PINN完整训练配置

配置项	取值
随机种子	42
训练设备	NVIDIA GPU（CUDA）
配点数 N_c	每模型5000点（BSM/CEV/Heston各5000）
边界点数 N_b	每模型500点
数据锚点数 N_d	每模型20点
优化器	Adam（ $\beta_1 = 0.9$, $\beta_2 = 0.999$ ）
初始学习率	1×10^{-3}
学习率调度	余弦退火（ $\eta_{\min} = 1 \times 10^{-5}$ ）
总训练步数	30000
损失权重($w_{\text{pde}}, w_{\text{bc}}, w_{\text{data}}$)	(1, 10, 100)
软掩码阈值	0.05
最后一层初始化	$\mathcal{N}(0, 0.001^2)$
BSM参数范围（训练）	$\sigma \in [0.10, 0.35]$ ，共6个变体
CEV参数范围（训练）	$\sigma \in [0.15, 0.25]$, $\beta \in [0.3, 0.9]$ ，共12个变体
Heston参数范围（训练）	$\kappa \in [1.0, 3.0]$, $\theta \in [0.02, 0.06]$, $\xi \in [0.2, 0.4]$, $\rho \in [-0.7, -0.5]$ ，共54个变体



参考文献

- [1] BLACK F, SCHOLES M. The pricing of options and corporate liabilities[J]. Journal of Political Economy, 1973, 81(3): 637–654. DOI: [10.1086/260062](https://doi.org/10.1086/260062).
- [2] MERTON R C. Theory of rational option pricing[J]. The Bell Journal of Economics and Management Science, 1973, 4(1): 141–183. DOI: [10.2307/3003143](https://doi.org/10.2307/3003143).
- [3] COX J C, ROSS S A. The valuation of options for alternative stochastic processes[J]. Journal of Financial Economics, 1976, 3(1–2): 145–166. DOI: [10.1016/0304-405X\(76\)90023-4](https://doi.org/10.1016/0304-405X(76)90023-4).
- [4] HESTON S L. A closed-form solution for options with stochastic volatility with applications to bond and currency options[J]. The Review of Financial Studies, 1993, 6(2): 327–343. DOI: [10.1093/rfs/6.2.327](https://doi.org/10.1093/rfs/6.2.327).
- [5] RAISSI M, PERDIKARIS P, KARNIADAKIS G E. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations[J]. Journal of Computational Physics, 2019, 378: 686–707. DOI: [10.1016/j.jcp.2018.10.045](https://doi.org/10.1016/j.jcp.2018.10.045).
- [6] DHIMAN G, HU J. Physics-informed neural networks for option pricing[J]. arXiv preprint arXiv:2312.06711, 2023.
- [7] BAE H O, KANG S, LEE M. Numerical method using PINN for solving the Black-Scholes equation with local volatility[J]. arXiv preprint arXiv:2407.01990, 2024.
- [8] HAINAUT D, CASAS A. Pricing of options in the Heston model using the Feynman-Kac formula and physics-informed neural networks[J]. arXiv preprint arXiv:2407.15054, 2024.
- [9] GUO Y, et al. IC-PINN: Initial condition-enforced physics-informed neural networks for solving partial differential equations[J]. arXiv preprint arXiv:2404.01234, 2024.
- [10] LIU J, ZHU R, XU J, et al. PDE-AGENT: A toolchain-augmented multi-agent framework for PDE solving[J]. arXiv preprint arXiv:2512.16214, 2025.
- [11] SCHRODER M. Computing the constant elasticity of variance option pricing formula[J]. Journal of Finance, 1989, 44(1): 211–219.
- [12] ZAMXAKA S. Physics-informed neural networks for option pricing under the Black-Scholes and CEV models[D]. [S.l.]: University of Cape Town, 2023.
- [13] XIAO Y, et al. TradingAgents: Multi-agents LLM financial trading framework[J/OL]. arXiv preprint arXiv:2412.20138, 2024. <https://arxiv.org/abs/2412.20138>.
- [14] KINGMA D P, BA J. Adam: A method for stochastic optimization[J/OL]. arXiv preprint arXiv:1412.6980, 2014. <https://arxiv.org/abs/1412.6980>.
- [15] ALBRECHER H, MAYER P, SCHOUTENS W, et al. The little Heston trap[J]. Wilmott Magazine, 2007, January: 83–92.



-
- [16] LOUSKOS K, et al. Physics-informed neural networks for american option pricing[J]. arXiv preprint arXiv:2110.01990, 2021.



致 谢

感谢石老师在本文研究过程中给予的悉心指导和宝贵建议。感谢上海科技大学信息科学与技术学院提供的计算资源支持,本文的实验在309实验室服务器上完成。

未完待续...