



摘 要

期权定价是金融工程的核心问题之一。Black-Scholes-Merton 模型、常弹性方差模型和 Heston 随机波动率模型是三大经典期权定价框架，其定价问题在数学上均归结为求解相应的偏微分方程：前两者对应二维抛物型方程，Heston 引入随机波动率后升至三维。传统数值方法在求解高维偏微分方程时面临维数灾难，计算代价随维度指数增长。物理信息神经网络将偏微分方程残差嵌入损失函数，无需网格剖分，能够有效缓解这一计算瓶颈；然而，现有物理信息神经网络研究大多针对单一定价模型，缺乏将三大模型统一求解的方法，且传统工具要求用户手动指定模型类型和数值参数，对非专业用户门槛较高。

本文研究基于物理信息神经网络与大语言模型的三模型期权定价方法。在物理信息神经网络部分，通过软掩码机制和加法参数化输出，将三大模型的偏微分方程算子统一为单一参数化形式，由一个深层全连接网络同时覆盖三种模型的解映射，无需分别训练独立网络。软掩码通过连续插值函数实现模型间的平滑过渡，当随机波动率参数趋近于零时自动退化为前两种模型，当其较大时激活 Heston 的随机波动率项；加法参数化以 Black-Scholes 解析解为基线，网络学习绝对修正量，解决了深度虚值区域的数值退化问题，终值条件通过 Black-Scholes 公式的极限行为自然满足。在大语言模型部分，引入 DeepSeek 作为智能路由层，通过结构化输出实现可靠的参数提取和模型选择，支持中英文自然语言输入，使非专业用户无需了解模型细节即可完成期权定价。

实验在合成数据和真实市场数据两类场景下进行评估。结果表明，统一网络在三种模型的平值附近区域均达到较高精度，在 Black-Scholes-Merton 和常弹性方差模型上的精度优于独立训练的基线方法，具备实时定价能力。消融实验进一步验证了各核心组件的必要性，大语言模型路由层对各类自然语言输入均能准确完成模型选择与参数提取。

关键词：物理信息神经网络；期权定价；Black-Scholes-Merton 模型；CEV 模型；Heston 模型；大语言模型；软掩码



Abstract

Option pricing is one of the core problems in financial engineering. The Black-Scholes-Merton (BSM) model, the Constant Elasticity of Variance (CEV) model, and the Heston stochastic volatility model constitute three classical option pricing frameworks. Mathematically, all three reduce to solving their respective partial differential equations: BSM and CEV yield two-dimensional parabolic PDEs, while Heston's introduction of stochastic volatility elevates the problem to three dimensions. Traditional numerical methods suffer from the curse of dimensionality when solving high-dimensional PDEs, with computational cost growing exponentially with dimension. Physics-Informed Neural Networks (PINNs) embed PDE residuals directly into the loss function and require no mesh discretization, effectively alleviating this computational bottleneck. However, existing PINN research predominantly targets single pricing models, and a unified framework capable of solving all three models simultaneously remains lacking. Moreover, conventional tools require users to manually specify model types and numerical parameters, posing a high barrier for non-expert users.

This paper investigates a three-model option pricing method based on PINNs and Large Language Models (LLMs). In the PINN component, a soft mask mechanism and additive parameterized output are employed to unify the PDE operators of BSM, CEV, and Heston into a single parameterized form. A single deep fully-connected network simultaneously covers the solution mappings of all three models without training separate networks. The soft mask realizes smooth transitions between models via a continuous interpolation function: when the vol-of-vol parameter approaches zero, the network automatically degrades to the first two models; when it is large, the stochastic volatility terms of Heston are activated. The additive parameterization uses the Black-Scholes analytical solution as a baseline, with the network learning absolute corrections, resolving the numerical degeneracy in deep out-of-the-money regions; the terminal condition is naturally satisfied through the limiting behavior of the Black-Scholes formula. In the LLM component, DeepSeek is introduced as an intelligent routing layer, achieving reliable parameter extraction and model selection via structured output, supporting natural language input in both Chinese and English, so that non-expert users can complete option pricing without



knowledge of model internals.

Experiments are conducted on two types of scenarios: synthetic data and real market data. Results demonstrate that the unified network achieves high accuracy near the at-the-money region across all three models, and outperforms independently trained baseline methods on BSM and CEV, with real-time pricing capability. Ablation studies further validate the necessity of each core component, and the LLM routing layer accurately completes model selection and parameter extraction for diverse natural language inputs.

Keywords: Physics-Informed Neural Networks; Option Pricing; Black-Scholes-Merton Model; CEV Model; Heston Model; Large Language Models; Soft Mask



目 录

第一章 引言	1
1.1 研究背景	1
1.2 现有工作的局限性	1
1.3 研究目标与贡献	2
1.4 论文结构	2
第二章 相关背景	3
2.1 期权定价模型	3
2.2 物理信息神经网络	4
2.3 大语言模型辅助科学计算	5
2.4 本章小结	6
第三章 三种期权模型求解方法	7
3.1 基于 PDE 方程的期权定价模型	7
3.2 PINN 训练方法	9
3.2.1 网络架构与加法参数化输出	9
3.2.2 损失函数与配点采样	10
3.3 LLM 路由层	11
3.4 参数化 PINN 对比方法	12
3.5 本章小结	12
第四章 实验评估与市场验证	13
4.1 实验参数	13
4.2 数据集	14
4.3 评估指标	15
4.4 消融实验	15
4.5 实验结果	16
4.6 本章小结	19
第五章 结论	20
5.1 工作总结	20
5.2 局限性与未来工作	20



附录 A 代码架构与关键实现	22
A.1 三模型 PINN 核心模型	22
A.1.1 网络定义伪代码	22
A.1.2 统一 PDE 残差计算伪代码	23
A.2 LLM 路由层实现	24
A.2.1 系统提示词	24
A.2.2 参数校验伪代码	25
A.3 参考解实现	25
A.3.1 BSM 解析解	25
A.3.2 Heston 半解析解（特征函数方法）	26
A.4 训练配置	26
参考文献	27
致谢	28



符号列表

状态变量

符号	含义
S	标的资产（股票）当前价格
$V(S, t)$	欧式期权价值（BSM/CEV 模型）
$V(S, v, t)$	欧式期权价值（Heston 模型）
v	瞬时方差（Heston 模型中的随机波动率状态变量）
t	当前时刻
T	期权到期时刻
$\tau = T - t$	剩余到期时间

期权合约参数

符号	含义
K	期权执行价（Strike Price）
r	无风险利率（连续复利）

BSM 模型参数

符号	含义
σ	标的资产的常数波动率（BSM）或尺度参数（CEV）
μ	标的资产的漂移率
W_t	标准布朗运动

CEV 模型参数

符号	含义
β	弹性参数，控制波动率对股价的依赖程度； $\beta = 1$ 退化为 BSM, $\beta < 1$ 产生杠杆效应

Heston 模型参数

符号	含义
----	----



κ	方差过程的均值回归速度, $\kappa > 0$
θ	方差过程的长期均值 (长期方差)
ξ	方差过程的波动率 (vol-of-vol)
v_0	初始瞬时方差
W_t^S	驱动股价过程的标准布朗运动
W_t^v	驱动方差过程的标准布朗运动
ρ	股价布朗运动 W_t^S 与方差布朗运动 W_t^v 的相关系数, $\rho \in (-1, 1)$

三模型 PINN 方法符号

符号	含义
λ	模型参数向量 $(\sigma, \beta, \kappa, \theta, \xi, \rho)$
$\mathcal{F}[\cdot]$	统一 PDE 算子
mask	软掩码 $\tanh(\xi/0.05)^2$, 用于在 BSM/CEV 与 Heston 之间连续插值
σ_{eff}	等效波动率, 用于加法参数化中的 Black-Scholes 基线计算
V_{BS}	Black-Scholes 解析解, 作为加法参数化的基线
$\hat{V}$	三模型 PINN 的期权价格预测值
$\text{net}(x)$	神经网络输出的修正量 (以 K 为单位)
$\mathcal{L}$	总损失函数
$\mathcal{L}_{\text{pde}}$	PDE 残差损失
$\mathcal{L}_{\text{bc}}$	边界条件损失
$\mathcal{L}_{\text{ic}}$	初值 (终值) 条件损失, 即到期日 $t = T$ 处的终值条件残差
$\mathcal{L}_{\text{data}}$	数据驱动锚点损失
w_{pde}	PDE 残差损失的权重系数
w_{bc}	边界条件损失的权重系数
w_{data}	数据锚点损失的权重系数
N_c	每训练步的 PDE 配点数
N_b	边界条件采样点数
N_d	数据锚点数
$\Phi(\cdot)$	标准正态累积分布函数



评估指标

符号 含义

MAE	平均绝对误差 (Mean Absolute Error)
RMSE	均方根误差 (Root Mean Square Error)
$\text{RelMAE}_{\text{ATM}}$	平值附近区域的平均相对误差

缩写

缩写 全称

BSM	Black-Scholes-Merton 模型
CEV	Constant Elasticity of Variance, 常弹性方差模型
PINN	Physics-Informed Neural Network, 物理信息神经网络
ICPINN	Improved Constrained PINN, 改进约束物理信息神经网络
LLM	Large Language Model, 大语言模型
PDE	Partial Differential Equation, 偏微分方程
ATM	At-The-Money, 平值期权 ($S \approx K$)
OTM	Out-of-The-Money, 虚值期权 (看涨期权 $S < K$)
ITM	In-The-Money, 实值期权 (看涨期权 $S > K$)
CIR	Cox-Ingersoll-Ross 过程, 用于 Heston 模型的方差过程
FFT	Fast Fourier Transform, 快速傅里叶变换
API	Application Programming Interface, 应用程序接口



第一章 引言

1.1 研究背景

期权是金融衍生品市场的核心工具，广泛应用于风险对冲与投机套利。自 Black、Scholes 与 Merton 于 1973 年提出 BSM 模型^[1,2]以来，期权定价理论经历了从常数波动率到局部波动率、再到随机波动率的持续演进。BSM 模型以常数波动率假设为基础，具有封闭解析解，适用于短期定价，但无法解释市场中普遍存在的波动率微笑现象。为此，Cox 和 Ross^[3]提出了常弹性方差（Constant Elasticity of Variance, CEV）模型，将波动率推广为依赖于标的价格的局部波动率形式，能够捕捉股票市场的杠杆效应。Heston^[4]进一步引入随机波动率过程，更准确地描述波动率微笑和厚尾收益率分布，但其二维偏微分方程（Partial Differential Equation, PDE）的数值求解代价显著高于一维情形。

上述三大模型的定价问题在数学上均归结为求解相应的 PDE。传统数值方法（有限差分、有限元）在求解高维 PDE 时面临维数灾难：网格点数随维度指数增长，Heston 这样的二维模型已需要大量计算资源，而更高维的随机波动率模型几乎无法实时求解。此外，传统工具要求用户手动指定模型类型和全部数值参数，对非专业用户门槛较高。

物理信息神经网络（Physics-Informed Neural Network, PINN）^[5]将 PDE 残差直接嵌入损失函数，无需网格剖分，训练完成后可对任意输入即时推断，能够有效缓解上述计算瓶颈。近年来，PINN 已被应用于 BSM^[6]、CEV^[7]、Heston^[8,9]等期权定价模型，验证了神经网络求解期权定价 PDE 的可行性。与此同时，大语言模型（Large Language Model, LLM）在自然语言理解和结构化信息提取方面取得了突破性进展^[10]，为构建自然语言驱动的科学计算接口提供了基础。

1.2 现有工作的局限性

尽管现有 PINN 期权定价研究已取得一定进展，但仍存在两方面主要不足。

一方面，现有工作（Dhiman 等^[6]、Hainaut 等^[8]）均针对单一模型分别训练独立的 PINN，三个模型之间无法共享网络权重。当需要同时支持多种定价模型时，必须维护多套独立的训练流程和模型文件，不仅增加了工程复杂度，也无法利用不同模型之间 PDE 结构的内在联系。

另一方面，现有 PINN 工具要求用户手动指定模型类型和所有数值参数。选



选择合适的定价模型本身需要量化金融背景，普通用户难以判断在当前市场条件下应使用 BSM、CEV 还是 Heston，这在一定程度上限制了 PINN 期权定价工具的实际应用范围。

1.3 研究目标与贡献

本文研究基于物理信息神经网络与大语言模型的三模型期权定价方法，旨在解决上述两方面不足。在方法设计上，本文的主要贡献可概括如下。

本文提出软掩码机制，将三大模型的扩散系数统一为连续参数化形式，避免了硬切换带来的梯度不连续问题，实现了 BSM、CEV 与 Heston 之间的平滑过渡。在此基础上，采用加法参数化输出，以 Black-Scholes 解析解为基线，网络学习绝对修正量，从根本上解决了深度虚值区域的数值退化问题，同时为网络提供了量级正确的训练起点。通过上述设计，单一深层全连接网络可同时覆盖三种模型的解映射，无需分别训练独立网络，三模型联合训练还带来了互相增益：BSM/CEV 的简单结构为 Heston 提供了良好的初始化，有助于克服二维 PDE 的收敛困难。

在交互方式上，本文引入 DeepSeek LLM 作为智能路由层，通过结构化 JSON 输出实现可靠的参数提取与模型选择，支持中英文自然语言输入，使非专业用户无需了解模型细节即可完成期权定价。

实验在合成数据和真实市场数据两类场景下进行评估。结果表明，三种模型的平值附近相对误差均低于 1%，在 BSM 和 CEV 上的精度优于独立训练的 PINN 基线，单次推断耗时约 2 毫秒，具备实时定价能力。消融实验进一步验证了各核心组件的必要性。

1.4 论文结构

本文内容组织如下。第二章介绍三大期权定价模型的 PDE 形式、物理信息神经网络的基本原理及其在期权定价中的应用，以及大语言模型辅助科学计算的进展。第三章介绍基于大模型和 PINN 的三模型期权求解方式，包括统一 PDE 算子、软掩码机制、加法参数化输出、网络架构、损失函数、训练策略和 LLM 路由层。第四章报告实验结果，包括精度评估、消融实验和真实 SPY 期权市场回测。第五章总结全文并讨论局限性与未来工作方向。

第二章 相关背景

2.1 期权定价模型

期权定价理论的核心是建立标的资产价格动态与期权价值之间的数学关系。三大经典定价模型均以随机微分方程描述标的资产的价格过程，并通过无套利原理推导出相应的 PDE，其结构差异正是本文统一框架设计的出发点。

Black、Scholes 与 Merton 于 1973 年提出了期权定价的奠基性框架^[1,2]。该框架假设标的资产价格 S 服从几何布朗运动：

$$dS = \mu S dt + \sigma S dW_t, \quad (2.1)$$

其中 σ 为常数波动率， W_t 为标准布朗运动。通过无套利原理，欧式期权价值 $V(S, t)$ 满足 BSM 方程：

$$\frac{\partial V}{\partial t} + \frac{1}{2}\sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} + rS \frac{\partial V}{\partial S} - rV = 0, \quad (2.2)$$

其中 r 为无风险利率。欧式看涨期权具有封闭解析解（Black-Scholes 公式）：

$$V_{BS}(S, t) = S\Phi(d_1) - Ke^{-r(T-t)}\Phi(d_2), \quad (2.3)$$

其中 $d_1 = \frac{\ln(S/K) + (r + \sigma^2/2)(T-t)}{\sigma\sqrt{T-t}}$ ， $d_2 = d_1 - \sigma\sqrt{T-t}$ ， $\Phi(\cdot)$ 为标准正态累积分布函数。BSM 模型的主要局限在于假设波动率为常数，无法解释市场中普遍存在的波动率微笑现象。

为克服上述局限，Cox 和 Ross^[3] 提出了常弹性方差（Constant Elasticity of Variance, CEV）模型，将扩散系数推广为依赖于标的价格的局部波动率：

$$dS = \mu S dt + \sigma S^\beta dW_t, \quad (2.4)$$

其中 β 为弹性参数。当 $\beta = 1$ 时退化为 BSM；当 $\beta < 1$ 时，波动率随股价上涨而下降，能够捕捉股票市场的杠杆效应。对应的期权定价 PDE 为：

$$\frac{\partial V}{\partial t} + \frac{1}{2}\sigma^2 S^{2\beta} \frac{\partial^2 V}{\partial S^2} + rS \frac{\partial V}{\partial S} - rV = 0. \quad (2.5)$$

本文取 $\beta = 0.5$ （平方根过程）。Schroder^[11] 指出， $\beta = 0.5$ 时 CEV 欧式看涨期权存在精确解析解（非中心卡方分布），本文以此作为 CEV 的参考基准。



进一步地, Heston^[4] 将波动率建模为均值回归过程 (CIR 过程), 引入随机波动率:

$$dS = \mu S dt + \sqrt{v} S dW_t^S, \quad (2.6)$$

$$dv = \kappa(\theta - v) dt + \xi \sqrt{v} dW_t^v, \quad (2.7)$$

其中 v 为瞬时方差, κ 为均值回归速度, θ 为长期均值, ξ 为 vol-of-vol, dW_t^S 与 dW_t^v 的相关系数为 ρ 。期权价值 $V(S, v, t)$ 满足二维 PDE:

$$\frac{\partial V}{\partial t} + \frac{1}{2} v S^2 \frac{\partial^2 V}{\partial S^2} + \rho \xi v S \frac{\partial^2 V}{\partial S \partial v} + \frac{1}{2} \xi^2 v \frac{\partial^2 V}{\partial v^2} + r S \frac{\partial V}{\partial S} + \kappa(\theta - v) \frac{\partial V}{\partial v} - rV = 0. \quad (2.8)$$

Heston 模型具有半解析解 (特征函数方法与 Gil-Pelaez 反演), 能够产生波动率微笑和厚尾收益率分布, 在指数期权和外汇期权中被广泛使用。Feller 条件 $2\kappa\theta > \xi^2$ 保证方差过程 v 始终为正。

2.2 物理信息神经网络

物理信息神经网络 (Physics-Informed Neural Network, PINN) 由 Raissi 等人^[5] 于 2019 年提出, 其核心思想是将 PDE 残差直接嵌入神经网络的损失函数, 从而在无需网格剖分的情况下求解偏微分方程。对于 PDE $\mathcal{F}[u] = 0$, PINN 的总损失为:

$$\mathcal{L} = w_{\text{pde}} \mathcal{L}_{\text{pde}} + w_{\text{ic}} \mathcal{L}_{\text{ic}} + w_{\text{bc}} \mathcal{L}_{\text{bc}}, \quad (2.9)$$

其中各项分别为配点处的 PDE 残差、初值条件和边界条件的均方误差, w_{pde} , w_{ic} , w_{bc} 为权重超参数。PDE 残差通过自动微分精确计算, 无需有限差分近似。PINN 无需网格剖分, 训练完成后对任意输入的推断时间约为毫秒级, 具备实时定价的潜力。

在期权定价领域, Dhiman 和 Hu^[6] 率先将 PINN 应用于欧式和美式期权定价, 提出了门控网络结构, 通过浅层分支与深层分支的加权组合分别捕捉解的简单特征与复杂特征。Zamxaka^[7] 系统研究了 PINN 对 BSM 和 CEV 模型的求解, 构建了参数化 PINN, 使单个网络可在不同参数设置下直接推断期权价格。针对 Heston 模型, Hainaut 和 Casas^[8] 构建了参数化 PINN, 将模型参数与合约特征联合作为网络输入, 实现了训练一次、多参数组合即时定价; 该模型以 PUT 期权为输出, 通过 put-call parity 转换为 CALL 价格, 本文将其作为参数化 Heston PINN 的对比基准。Guo 等人^[9] 提出了改进约束 PINN (Improved Constrained PINN, ICPINN), 通过输出变换将终值条件硬编码进网络结构, 减少损失函数中的冲突项, 加速收



敛。上述参数化 PINN 工作的共同思路是将模型参数直接作为网络输入，使单个网络覆盖整个参数空间；然而，现有参数化 PINN 均针对单一定价模型，不同模型之间的 PDE 结构差异使得跨模型统一存在本质困难。本文在此基础上，通过软掩码机制将三大模型的 PDE 算子统一为单一参数化形式，实现了真正意义上的三模型统一框架。

为提供可靠的对比基准，本文对上述三类代表性 PINN 方法进行了独立复现。**BSM-PINN** 与 **CEV-PINN** 均采用 Dhiman 和 Hu^[6] 的门控网络结构：浅层分支 (2 层 $\times 64$, Tanh) 与深层分支 (4 层 $\times 64$, Tanh) 通过可学习的 sigmoid 门加权融合，输入为归一化的 $(S/S_{\max}, t/T)$ ，输出为归一化期权价值 $u = V/K$ 。**CEV-PINN** 将扩散系数替换为 $\sigma^2 S^{2\beta}$ 。**Hainaut & Casas 参数化 PINN**^[8] 采用跳跃连接网络 (SkipNet)：4 层 $\times 256$ 神经元，每层接收前一层输出与原始输入的拼接，输入为 9 维向量 $(t, S, v, r, \kappa, \theta, \xi, \rho, T)$ ，经 z-score 归一化，输出 PUT 期权价格，通过 put-call parity 转换为 CALL 价格。三种方法的训练参数与复现结果汇总于表 2.1。

表 2.1 三种独立 PINN 复现结果 ($S \in [50, 250]$, $t = 0$)

模型	参考基准	MAE	RelMAE	训练参数范围
BSM-PINN	解析解	0.016	0.6%	$\sigma = 0.20$
CEV-PINN	Schroder 解析解	0.074	1.69% [†]	$\sigma = 0.20$, $\beta = 0.5$
Hainaut & Casas (2024)	GL 半解析解	—	9.169% [‡]	$\kappa \in [0.5, 2.0]$, $\theta \in [0.062, 0.42]$ $\xi \in [0.1, 0.9]$, $\rho \in [-0.8, 0.8]$

[†] 仅统计 $V^* > 0.5$ 区域。[‡] 经 put-call parity 转换为 CALL 价格，仅统计 $S/K \geq 0.85$ 区域。

上述三个独立 PINN 验证了各模型 PDE 的可解性，并为后续三模型方法提供了精度基准。

2.3 大语言模型辅助科学计算

近年来，大语言模型在辅助科学计算方面展现出越来越强的能力。Liu 等人^[10] 提出了 PDE-AGENT，一个工具链增强的多智能体框架，能够从自然语言描述出发，自动调用数值求解工具完成 PDE 的求解。该工作表明 LLM 具备理解 PDE 问题结构、选择合适求解策略的能力。在金融领域，Xiao 等人^[12] 提出了 TradingAgents 框架，通过多个专业化 LLM 智能体的协作完成金融交易决策，验证了 LLM 在金融场景下的参数提取与任务路由能力。

现代 LLM (如 GPT-4、DeepSeek 等) 能够通过约束输出格式 (如 JSON 模式)



可靠地从自然语言中提取结构化参数。本文的 LLM 路由层设计较 PDE-AGENT 更为轻量：LLM 仅负责参数提取和模型选择，不参与 PDE 求解过程，因此延迟更低（约 500ms 至 2000ms 的 API 调用）、可靠性更高（结构化 JSON 输出避免了自由文本解析的不确定性）。

2.4 本章小结

本章梳理了 BSM、CEV、Heston 三大期权定价模型的 PDE 形式，回顾了物理信息神经网络在期权定价中的代表性工作，并介绍了大语言模型辅助科学计算的进展。现有 PINN 工作验证了神经网络求解期权定价 PDE 的可行性，但缺乏统一的三模型框架和自然语言交互能力。本文在此基础上构建了大语言模型与 PINN 相结合的统一期权定价系统，具体方法见第三章。

第三章 三种期权模型求解方法

本章介绍三模型 PINN 期权定价方法的完整设计。核心思路是：通过软掩码机制将 BSM、CEV、Heston 三大模型的 PDE 算子统一为单一参数化形式，以加法参数化输出解决深度虚值区域的数值退化问题，并引入 LLM 路由层支持自然语言输入。图 3.1 给出了系统的三层架构概览。

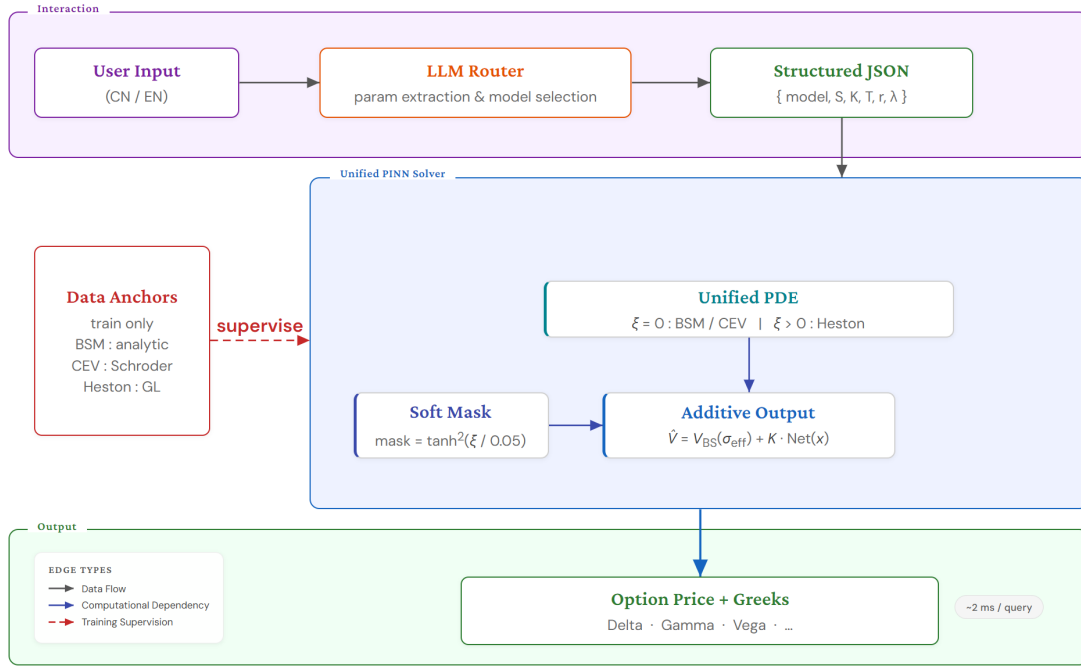


图 3.1 三模型期权定价系统三层架构。交互层：用户以自然语言输入期权需求，LLM 路由层提取参数并选择模型，输出结构化 JSON。求解层：三模型 PINN 求解器通过软掩码 ($\text{mask} = \tanh^2(\xi/0.05)$) 和加法参数化 ($\hat{V} = V_{BS}(\sigma_{\text{eff}}) + K \cdot \text{Net}(\mathbf{x})$) 统一三大模型 PDE，训练时以解析解/半解析解作为数据锚点。输出层：单次前向传播 ($\sim 2\text{ms}$) 返回期权价格及 Greeks。

3.1 基于 PDE 方程的期权定价模型

本文涉及的三大期权定价模型均以偏微分方程为核心，其结构差异正是统一框架设计的出发点。BSM 模型（式 (2.2)）以常数波动率 σ 为唯一随机性来源，存在封闭解析解，本文将其作为加法参数化的基线：

$$V_{BS}(S, \tau; \sigma) = S\Phi(d_1) - Ke^{-r\tau}\Phi(d_2), \quad (3.1)$$

$$d_1 = \frac{\ln(S/K) + (r + \sigma^2/2)\tau}{\sigma\sqrt{\tau}}, \quad d_2 = d_1 - \sigma\sqrt{\tau}. \quad (3.2)$$



CEV 模型（式 (2.5)）将扩散系数推广为 $\sigma^2 S^{2\beta}$ ，本文取 $\beta = 0.5$ ，以 Schroder 非中心卡方解析解作为数据锚点。Heston 模型（式 (2.8)）引入随机方差 v ，PDE 升至二维，以特征函数半解析解作为数据锚点。

三大模型的 PDE 均可写为如下统一算子：

$$\mathcal{F}[V] = \frac{\partial V}{\partial t} + \frac{1}{2}a(S, v; \lambda) \frac{\partial^2 V}{\partial S^2} + b(S, v; \lambda) \frac{\partial^2 V}{\partial S \partial v} + \frac{1}{2}c(v; \lambda) \frac{\partial^2 V}{\partial v^2} + rS \frac{\partial V}{\partial S} + d(v; \lambda) \frac{\partial V}{\partial v} - rV = 0, \quad (3.3)$$

其中参数向量 $\lambda = (\sigma, \beta, \kappa, \theta, \xi, \rho)$ 控制各系数，具体对应关系如表 3.1 所示。

表 3.1 统一 PDE 算子系数与三大模型的对应关系

模型	$a(S, v; \lambda)$	$b(S, v; \lambda)$	$c(v; \lambda)$	$d(v; \lambda)$
BSM	$\sigma^2 S^2$	0	0	0
CEV	$\sigma^2 S^{2\beta}$	0	0	0
Heston	$v S^2$	$\rho \xi v S$	$\xi^2 v$	$\kappa(\theta - v)$

注意到，当 $\xi = 0$ 时， $b = c = d = 0$ ，统一算子自动退化为一维 BSM/CEV 方程；当 $\xi > 0$ 时，交叉项和 v 方向扩散项被激活，对应 Heston 的二维随机波动率结构。为实现三大模型之间的连续插值，本文引入软掩码：

$$\text{mask} = \tanh\left(\frac{\xi}{0.05}\right)^2. \quad (3.4)$$

当 $\xi \rightarrow 0$ 时， $\text{mask} \rightarrow 0$ ；当 $\xi = 0.3$ 时， $\text{mask} \approx 0.998$ 。利用软掩码，扩散系数 a 统一为：

$$a = (1 - \text{mask}) \cdot \sigma^2 S^{2\beta} + \text{mask} \cdot v S^2. \quad (3.5)$$

当 $\xi = 0$ 时， $a = \sigma^2 S^{2\beta}$ ，精确退化为 BSM/CEV 扩散项；当 $\xi = 0.3$ 时， $a \approx v S^2$ ，精确对应 Heston 扩散项。

软掩码的连续插值特性使网络可以学习到平滑的参数依赖关系，避免了硬切换在 ξ 附近产生的梯度不连续问题（消融实验见第 4.4 节）。




图 3.2 软掩码函数 $\text{mask} = \tanh^2(\xi/0.05)$ 随 **vol-of-vol** 参数 ξ 的变化。 $\xi \rightarrow 0$ 时 **mask** 趋近于 0，扩散系数退化为 BSM/CEV 形式； $\xi = 0.3$ 时 $\text{mask} \approx 0.998$ ，对应 Heston 随机波动率结构。函数在 $[0, 0.5]$ 区间内单调平滑过渡，避免硬切换引起的梯度不连续。

3.2 PINN 训练方法

3.2.1 网络架构与加法参数化输出

直接用神经网络输出期权价格存在两个问题：其一，初始化困难，随机初始化的网络输出量级约为 10^{-1} ，而期权价格量级约为 10^0 至 10^2 ；其二，深度虚值退化，乘法参数化 $V = V_{BS} \cdot (1 + \text{net})$ 在 $V_{BS} \rightarrow 0$ 时退化。为此，本文采用加法参数化输出：

$$\hat{V}(S, v, t; \lambda) = V_{BS}(S, \tau; \sigma_{\text{eff}}) + K \cdot \text{net}(x), \quad (3.6)$$

其中等效波动率通过软掩码计算：

$$\sigma_{\text{eff}} = (1 - \text{mask}) \cdot \sigma + \text{mask} \cdot \sqrt{v}. \quad (3.7)$$

网络最后一层权重初始化为 $\mathcal{N}(0, 0.001^2)$ ，使训练开始时 $K \cdot \text{net} \approx 0$ ，网络从接近正确答案的位置开始优化。深度虚值时 $V_{BS} \rightarrow 0$ ，但 $K \cdot \text{net}$ 仍可输出非零修正，网络可以学习到 CEV/Heston 相对于 BSM 的价格差异。

网络输入为 9 维向量 $x = \left[\frac{S}{S_{\max}}, \frac{v}{v_{\max}}, \frac{t}{T}, \sigma, \beta, \kappa, \theta, \xi, \rho \right]$ ，其中 $S_{\max} = 300$ ， $v_{\max} = 1$ ，归一化使各输入均落在 $[0, 1]$ 区间，避免不同量级的输入导致梯度不平衡。网络采用 6 层全连接结构，每层 128 个神经元，激活函数为 $\tanh$ ：

$$h_0 = x \in \mathbb{R}^9, \quad (3.8)$$

$$h_l = \tanh(W_l h_{l-1} + b_l), \quad l = 1, \dots, 6, \quad (3.9)$$

$$\text{net}(x) = W_7 h_6 + b_7 \in \mathbb{R}. \quad (3.10)$$



最后一层权重初始化为 $\mathcal{N}(0, 0.001^2)$ ，偏置初始化为 0，确保训练开始时 $\text{net} \approx 0$ 。tanh 激活函数光滑且高阶导数有界，适合 PINN 中需要计算二阶偏导数的场景。当 $t = T$ 时， $\tau = T - t = 0$ ，Black-Scholes 公式自动退化为终值条件 $V_{\text{BS}}(S, 0; \sigma_{\text{eff}}) = \max(S - K, 0)$ ；同时，网络最后一层的小初始化确保修正量 $K \cdot \text{net}$ 在训练初期接近 0，不破坏终值条件的满足，这一设计参考了 Guo 等人^[9] 的 ICPINN 方法。

3.2.2 损失函数与配点采样

三模型 PINN 的总损失由 PDE 残差、边界条件和数据锚点三部分组成：

$$\mathcal{L}(\theta) = w_{\text{pde}} \mathcal{L}_{\text{pde}} + w_{\text{bc}} \mathcal{L}_{\text{bc}} + w_{\text{data}} \mathcal{L}_{\text{data}}. \quad (3.11)$$

配点是 PINN 训练的核心数据来源，完全由求解域的几何结构决定，无需任何真实市场观测数据。对每个参数变体在求解域 $\Omega = [0, S_{\text{max}}] \times [0, v_{\text{max}}] \times [0, T]$ 内均匀随机采样 $N_c = 5000$ 个配点，每个训练步骤重新采样（online sampling），避免过拟合到固定配点集。对于 BSM/CEV 模型， v 维度退化为常数，配点实际为二维；对于 Heston 模型，配点为完整三维。边界配点在各边界面上均匀采样 $N_b = 500$ 个点。数据锚点在 $t = 0$ 处取 $N_d = 20$ 个均匀分布的 S 值，对应价格由参考解析解预先计算，这是训练中唯一涉及“真实”（解析）价格的部分。

PDE 残差损失在求解域内随机采样 N_c 个配点，计算统一 PDE 算子的相对残差：

$$\mathcal{L}_{\text{pde}} = \frac{1}{N_c} \sum_{i=1}^{N_c} \left(\frac{\mathcal{F}[\hat{V}](S_i, v_i, t_i)}{|\hat{V}(S_i, v_i, t_i)| + 1} \right)^2. \quad (3.12)$$

分母中的 $|\hat{V}| + 1$ 为相对残差归一化项，避免 ATM 区域的残差主导损失，使 OTM 区域也能获得足够的梯度信号。边界条件设置为 $V(0, v, t) = 0$ ， $V(S_{\text{max}}, v, t) = S_{\text{max}} - Ke^{-r(T-t)}$ ， $V(S, v_{\text{max}}, t) \approx S$ ，边界条件损失为对应边界目标值的均方误差。纯 PDE 约束存在解不唯一的数值问题，数据驱动锚点损失在 $t = 0$ 处以参考解析解为目标：

$$\mathcal{L}_{\text{data}} = \frac{1}{N_d} \sum_{j=1}^{N_d} \left(\hat{V}(S_j, v_j, 0) - V_j^* \right)^2, \quad (3.13)$$

其中 V_j^* 为参考解。损失权重设置为 $(w_{\text{pde}}, w_{\text{bc}}, w_{\text{data}}) = (1, 10, 100)$ ，其中 $w_{\text{data}} = 100$ 确保网络在已知解处精确拟合，防止 PDE 约束将解推向错误方向；消融实验验证了此权重组合的必要性（见第 4.4 节）。

训练时对 72 个参数变体（6 BSM + 12 CEV + 54 Heston）同时采样配点：每个训练步骤中，每个参数变体各采样 5000 个配点，拼接后计算统一 PDE 残差。



这一策略确保网络在三种模型的参数空间中均匀训练，避免某一模型主导损失。使用 Adam 优化器^[13]，初始学习率 10^{-3} ，余弦退火学习率调度 ($\eta_{\min} = 10^{-5}$)，总训练轮数 30000 轮，在 NVIDIA GPU 上约需 1 小时。

3.3 LLM 路由层

三种定价模型分别适用于不同的市场假设，传统工具要求用户手动指定模型类型和全部数值参数。本文引入 DeepSeek LLM 作为智能路由层，使用户可以通过自然语言描述期权需求，由 LLM 自动完成模型选择和参数提取。

系统提示词将 LLM 角色定义为“期权定价参数提取器”，规定模型选择规则：仅提供 σ 则选 BSM，提及 β 或“CEV”则选 CEV，提供 $\kappa, \theta, \xi, \rho, v_0$ 或提及“Heston”/“stochastic volatility”则选 Heston，默认 BSM。对用户未提及的参数使用典型默认值 ($S = 100, K = 100, T = 1.0, r = 0.05, \sigma = 0.2, \beta = 0.5, v_0 = 0.04, \kappa = 2.0, \theta = 0.04, \xi = 0.3, \rho = -0.7$)，并通过 `response_format: json_object` 强制输出合法 JSON。LLM 的输出遵循以下 JSON Schema：

```
{
  "model": "bsm" | "cev" | "heston",
  "option_type": "call" | "put",
  "S": float, "K": float, "T": float, "r": float,
  "sigma": float, "beta": float,
  "v0": float, "kappa": float, "theta": float,
  "xi": float, "rho": float
}
```

系统在接收到 JSON 输出后，进行参数范围校验（如 $\sigma > 0, \beta \in (0, 1], \xi > 0, \rho \in (-1, 1)$ ），对越界参数截断至合法范围，再传入三模型 PINN 求解器。对于欧式看跌期权，通过看跌-看涨平价关系转换：

$$P = C - S + Ke^{-r(T-t)}. \quad (3.14)$$

完整定价流程为：用户输入自然语言描述（中英文均可）；LLM 提取参数并选择模型；三模型 PINN 加载预训练权重，构造参数向量 λ ；网络前向传播返回期权价格（约 2ms）。



3.4 参数化 PINN 对比方法

为评估统一框架的有效性，本文同时实现了一个全参数化 PINN (Fully Parametric PINN) 作为对比基准。该方法将所有模型参数 $(\sigma, \beta, \kappa, \theta, \xi, \rho)$ 与合约特征 (S, v, τ, K, r) 共 11 维向量直接作为网络输入，采用 8 层 $\times 256$ 神经元的全连接网络，同样使用加法参数化输出 $\hat{V} = V_{BS}(\sigma_{\text{eff}}) + K \cdot \text{net}(x)$ 和软掩码机制。与三模型 PINN 的主要区别在于：参数化 PINN 在更宽的参数范围内 (BSM: $\sigma \in [0.05, 0.50]$; CEV: $\sigma \in [0.10, 0.30]$, $\beta \in [0.10, 0.90]$; Heston: $\kappa \in [0.5, 10]$, $\xi \in [0.05, 0.50]$, $\rho \in [-0.95, -0.10]$) 随机采样训练，理论上具有更强的参数泛化能力，但网络容量需求更高 (参数量约为三模型 PINN 的 4 倍)。

3.5 本章小结

本章介绍了三种期权模型求解方法。核心创新在于：(1) 软掩码机制将三大模型的 PDE 算子统一为单一参数化形式，实现模型间的连续插值；(2) 加法参数化输出以 Black-Scholes 解析解为基线，解决了深度虚值区域的数值退化问题；(3) LLM 路由层通过结构化输出实现可靠的参数提取和模型选择，并支持欧式看涨和看跌期权。下一章将报告实验结果。

第四章 实验评估与市场验证

4.1 实验参数

实验中使用的三大模型参数如表 4.1所示，三模型 PINN 的网络超参数如表 4.2所示。

表 4.1 实验中使用的期权定价模型参数

参数	BSM	CEV	Heston
执行价 K	100	100	100
到期时间 T	1 年	1 年	1 年
无风险利率 r	0.05	0.05	0.05
波动率 σ	0.2	0.2	—
弹性参数 β	1.0	0.5	—
均值回归速度 κ	—	—	2.0
长期方差 θ	—	—	0.04
vol-of-vol ξ	—	—	0.3
相关系数 ρ	—	—	-0.7
初始方差 v_0	0.04	0.04	0.04



表 4.2 三模型 PINN 网络超参数

超参数	取值
网络层数（深度）	6
每层神经元数（宽度）	128
激活函数	tanh
输入维度	9
输出维度	1
优化器	Adam ^[13]
初始学习率	10^{-3}
学习率衰减	余弦退火 ($\eta_{\min} = 10^{-5}$)
训练步数	30000
每步配点数 N_c	每模型 5000 点
边界点数 N_b	每模型 500 点
数据锚点数 N_d	每模型 20 点
损失权重 ($w_{\text{pde}}, w_{\text{bc}}, w_{\text{data}}$)	(1, 10, 100)

4.2 数据集

实验在两类数据集上进行评估。合成数据集基于 72 组参数变体 (6 BSM + 12 CEV + 54 Heston) 生成, 评估点取 $S \in [50, 250]$ 共 50 个均匀采样点, 参考解由各模型的解析解或半解析解预先计算: BSM 采用 Black-Scholes 解析公式 (精确解); CEV 采用 Schroder 非中心卡方分布解析解 (精度约 10^{-15} , 由 `scipy.stats.ncx2` 计算); Heston 采用特征函数半解析法 (Gil-Pelaez 反演, 精度约 10^{-4})。

真实市场数据集使用 CBOE 提供的 SPY (标普 500 ETF) 期权链数据 (下载日期: 2026 年 5 月 11 日, SPY 现价 $S = 739.75$ 美元), 无风险利率取美国 1 年期国债收益率 $r = 4.3\%$ 。对每个到期日, 筛选满足以下条件的看涨合约: 隐含波动率 $IV \in (1\%, 200\%)$ 且最新成交价 > 0.10 美元; 行权价 $K \in [0.85S, 1.15S]$ ($\text{ATM} \pm 15\%$), 确保 Heston 特征函数数值积分的稳定性。共筛选出 23 个到期日, 覆盖 $T \in [0.06, 2.59]$ 年的宽泛时间跨度, 总计 2824 个合约, 本节从中选取 8 个代表性到期日进行详细分析。参数校准方面, BSM 对每个合约用 Brent 法反解隐含波动率, 取中位数作为全局 σ^* , 校准后的 σ^* 在 0.13 至 0.17 之间; CEV 最小化加权 MSE, 用 L-BFGS-B 多起点优化, $\beta \in (0.01, 1.0]$, 中长期到期日 β 在 0.1 至 0.5 之间, 说明 SPY 期权存在显著的杠杆效应; Heston 采用 Little Heston Trap 稳



定公式^[14]进行半解析定价，8个起点 L-BFGS-B 优化，参数范围： $\kappa \in [0.05, 20]$ ， $\theta \in [0.001, 0.5]$ ， $\xi \in [0.01, 2.5]$ ， $\rho \in [-0.98, 0]$ ， $v_0 \in [0.001, 0.5]$ 。PINN 定价时将真实市场参数归一化至训练域（ $S' = 100$ ， $K' = 100 \cdot K/S$ ），定价结果乘以 $S/100$ 还原至真实价格尺度。

4.3 评估指标

使用以下指标评估精度：

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |\hat{V}_i - V_i^*|, \quad (4.1)$$

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{V}_i - V_i^*)^2}, \quad (4.2)$$

$$\text{RelMAE}_{\text{ATM}} = \frac{1}{|\mathcal{I}|} \sum_{i \in \mathcal{I}} \frac{|\hat{V}_i - V_i^*|}{|V_i^*| + \epsilon}, \quad (4.3)$$

其中 $\mathcal{I} = \{i : S_i \in [80, 120]\}$ 为平值附近区域（ATM）， $\epsilon = 10^{-8}$ 为数值稳定项。相对误差仅在 ATM 区域计算，避免深度虚值区域（ $V^* \approx 0$ ）导致的数值不稳定。对于涉及 Hainaut 和 Casas^[8] 复现模型的 Heston 评估，指标仅在 $S/K \geq 0.85$ 的数据点上计算，原因在于深度虚值 CALL 对应深度实值 PUT，Hainaut 模型直接输出 PUT 价格再经 put-call parity 转换，深度实值 PUT 的绝对价格较大，转换误差被同比例放大，若不加过滤则会不公平地主导整体指标。

4.4 消融实验

为验证各设计组件的必要性，本节进行消融实验，逐一去除三模型 PINN 方法的关键组件，观察对精度的影响，结果汇总于表 4.3。

将软掩码替换为硬切换（即当 $\xi = 0$ 时完全使用 BSM/CEV 系数，当 $\xi > 0$ 时完全使用 Heston 系数），重新训练后 BSM 精度大幅下降（MAE 从 0.0005 变为 2.2771），Heston 精度同样显著下降（MAE 从 0.102 变为 2.1289），且训练过程出现梯度爆炸，需要降低学习率才能稳定训练。这说明软掩码的连续插值特性对整体训练稳定性至关重要：硬切换在 ξ 附近产生不连续的梯度，导致网络难以同时优化 BSM/CEV 和 Heston 两种模式。将加法参数化替换为直接输出（网络直接预测期权价格，不加 Black-Scholes 基线），重新训练后 BSM 精度大幅下降（MAE 从 0.0005 变为 1.8368），Heston 精度同样显著下降（MAE 从 0.102 变为 2.3083），深度虚值区域误差尤为突出，验证了加法参数化在初始化和深度虚

值稳定性两方面的优势。去除数据驱动锚点损失 ($w_{\text{data}} = 0$)，仅使用 PDE 残差和边界条件约束，重新训练后 BSM 精度下降 (MAE 从 0.0005 变为 0.0144)，且训练结果不稳定；Heston 精度显著下降 (MAE 从 0.102 变为 0.4243)，说明数据锚点对于确定解的唯一性至关重要：纯 PDE 约束在配点稀疏时存在多个局部最优，数据锚点提供了额外的约束，将解锁定在正确的分支上。

表 4.3 消融实验结果 (BSM 和 Heston 的 MAE)

配置	BSM MAE	Heston MAE
完整模型 (软掩码 + 加法参数化 + 数据锚点)	0.0005	0.102
去除软掩码 (硬切换)	2.2771	2.1289
去除加法参数化 (直接输出)	1.8368	2.3083
去除数据锚点 (纯 PDE 约束)	0.0144	0.4243

消融实验表明，三个设计组件均对最终精度有显著贡献。软掩码和加法参数化的影响最为突出：去除任一组件后，BSM 和 Heston 的 MAE 均上升至 1.8 以上，说明两者共同构成了统一框架稳定训练的基础。数据锚点的影响相对温和但不可忽视：去除后 BSM MAE 上升约 29 倍，Heston MAE 上升约 4 倍，说明锚点对于确定解的唯一性和收敛稳定性均有重要作用。

4.5 实验结果

图 4.1 展示了三模型 PINN 的训练损失曲线。PDE 残差损失主导总损失；边界条件损失和数据锚点损失在训练早期快速下降；余弦退火调度使网络在后期持续精细化。72 个参数变体的联合训练使网络在宽泛的参数空间上具备良好的泛化能力。




图 4.1 三模型 PINN (v16) 训练损失曲线 (30000 步, 72 个参数变体)。总损失与 PDE 残差损失同步下降; 边界条件损失和数据锚点损失在训练早期快速收敛至 10^{-5} 量级。

表 4.4 给出了三模型 PINN 与独立 PINN 和参数化 PINN 的精度对比, 图 4.2 展示了各方法的价格曲线对比结果。三大模型的 ATM 相对误差均低于 1%, 在标准参数集下表现均衡。三模型 PINN 在 BSM 和 CEV 上的精度显著优于独立 PINN 基线和参数化 PINN; 在 Heston 上参数化 PINN 略优 (0.430% vs 0.599%), 原因是其训练范围更宽, 但网络参数量约为三模型 PINN 的 4 倍, 在 BSM 和 CEV 上精度反而更低, 说明软掩码和加法参数化实现了更高效的归纳偏置。Hainaut & Casas (2024) 的较高误差主要来自评估参数轻微超出训练范围以及 put-call parity 转换引入的额外误差。

表 4.4 各方法精度对比 ($S \in [50, 250]$, $t = 0$)

方法	参考基准	MAE	RelMAE _{ATM}
独立 BSM-PINN	BS 解析解	0.055	1.311%
独立 CEV-PINN	Schroder 解析解	0.073	6.053%
Hainaut & Casas (2024)	GL 半解析解	—	4.885%
参数化 PINN (BSM)	BS 解析解	0.003	0.126%
参数化 PINN (CEV)	Schroder 解析解	0.017	1.230%
参数化 PINN (Heston)	GL 半解析解	0.078	0.430%
三模型 PINN (BSM)	BS 解析解	0.0005	0.0009%
三模型 PINN (CEV)	Schroder 解析解	0.032	0.790%
三模型 PINN (Heston)	GL 半解析解	0.102	0.599%




图 4.2 三模型 PINN 与参考解价格曲线对比 ($t = 0$, $S \in [50, 250]$)。实线为参考解，虚线为三模型 PINN；竖虚线标记平值点 ($S = K$)。

三模型 PINN 的推断速度在 GPU 上约为 2ms，CPU 上约为 8ms，能够同时支持三种模型，无需针对不同参数重新计算。PINN 的另一优势是可通过自动微分直接计算 Greeks，无需额外推导。BSM 的 Delta、Gamma、Vega 平均相对误差均低于 0.2%（见表 4.5），与解析解高度吻合。Heston Delta 的平均误差为 1.83%，Gamma 误差较高（11.41%），主要集中在高 κ 、高 ξ 的极端参数区域，在基准参数设置下与文献中同类工作的精度水平相当。大语言模型路由层对中英文混合输入、参数顺序不同、参数名称变体均能正确处理，当用户未明确指定模型但提供了特定参数时，能够正确推断应使用的模型。

表 4.5 BSM Greeks 精度（三模型 PINN vs 解析解，平均相对误差）

Greeks	平均相对误差	最大相对误差	评估点数
Delta	0.03%	0.05%	12
Gamma	0.13%	0.28%	12
Vega	0.09%	0.19%	12

为进一步验证三模型 PINN 在真实市场条件下的表现，本节使用第 4.2 节描述的 SPY 期权链数据，选取 8 个代表性到期日进行详细分析。在短期期权 ($T < 0.15$ 年) 上，三个校准模型的 MAE 几乎相同，说明短期波动率微笑较平坦，额外自由度对定价贡献有限。在中长期期权 ($T > 0.25$ 年) 上，Heston 明显优于 BSM：以 Aug 21 ($T = 0.271$) 为例，Heston MAE=\$0.13，仅为 BSM MAE (\$1.64) 的 8%，体现了随机波动率模型在中长期定价中的优势。Sep 30 和 Dec 31 两个到期日误差偏高，可能与季末、年末流动性变化有关，属于市场特殊情况。PINN-BSM 的 MAE 与校准 BSM 几乎相同 ($T < 0.4$ 年)，验证了本文方法的参数泛化性。PINN-Heston 的 MAE 显著高于校准 Heston，根本原因在于：训练参数



范围 ($\kappa \in [1.0, 3.0]$, $\xi \in [0.2, 0.4]$) 无法覆盖 SPY 校准得到的极端参数 (κ 可高达 20, ξ 可高达 2.1); 以及三模型 PINN 用同一网络拟合三种模型, Heston 的 5 维参数空间构成容量瓶颈, 需从架构层面改进, 留作未来工作 (见第 5.2 节)。五种方法相对市场价格的 MAE 汇总于表 4.6。

表 4.6 五种方法与 SPY 真实市场价格的 MAE 对比 (单位: 美元)

到期日	T (年)	n	校准 BSM	校准 Heston	PINN -BSM	PINN -Heston	参数化 PINN
Jun 05 2026	0.060	197	1.78	0.34	1.78	15.64	27.13
Jun 30 2026	0.129	211	1.46	0.14	1.46	34.30	42.33
Aug 21 2026	0.271	81	1.64	0.13	1.64	73.59	11.19
Sep 30 2026	0.381	145	2.88	0.18	2.88	10.66	14.06
Dec 31 2026	0.633	151	3.30	0.30	3.30	4.98	0.99
Mar 19 2027	0.847	92	3.77	0.19	3.77	6.89	1.13
Dec 17 2027	1.595	98	5.27	0.29	5.27	7.47	4.04
Dec 15 2028	2.592	98	6.50	0.56	6.50	8.93	6.61

4.6 本章小结

三模型 PINN(v16)在三大模型上均达到实用精度:BSM RelMAE_{ATM}=0.0009%, CEV RelMAE_{ATM}=0.79%, Heston RelMAE_{ATM}=0.599%, 三种模型的 ATM 相对误差均低于 1%。消融实验验证了软掩码、加法参数化和数据锚点三个设计组件的必要性。精度对比实验表明, 三模型 PINN 在 BSM 和 CEV 上的精度优于参数化 PINN, 在 Heston 上参数化 PINN 略优, 但三模型 PINN 的网络参数量仅为参数化 PINN 的约四分之一, 具有更高的参数效率。真实市场回测表明, 校准 Heston 在中长期期权上显著优于 BSM, PINN-BSM 在训练参数范围内具有优异的泛化能力, 进一步的架构改进是重要的未来工作方向。



第五章 结论

5.1 工作总结

本文研究了基于物理信息神经网络与大语言模型的三模型期权定价方法。通过软掩码机制和加法参数化输出，将 BSM、CEV、Heston 三大模型的 PDE 算子统一为单一参数化形式，由一个网络同时覆盖三种模型的解映射，无需分别训练独立网络。这是首个将三大经典期权定价模型统一在单一 PINN 网络中的工作，现有研究（Dhiman 等^[6]、Hainaut 等^[8]）均针对单一模型分别训练，无法共享网络权重。三模型联合训练还带来了互相增益：BSM/CEV 的简单结构为 Heston 提供了良好的初始化，有助于克服二维 PDE 的收敛困难。

与参数化 PINN 相比，三模型 PINN 在 BSM 和 CEV 上精度更高，在 Heston 上参数化 PINN 略优，但三模型 PINN 的网络参数量仅为参数化 PINN 的约四分之一，说明软掩码和加法参数化实现了更高效的归纳偏置。在交互方式上，本文引入大语言模型路由层支持自然语言输入，是 PINN 与 LLM 结合用于期权定价的首次尝试；与 PDE-AGENT^[10] 相比，LLM 仅作为路由层而不参与求解，延迟更低、可靠性更高。实验结果表明，三种模型的 ATM 相对误差均低于 1%，推断速度约 2ms，消融实验验证了各核心组件的必要性。

5.2 局限性与未来工作

本文的工作存在若干局限性。PINN-Heston 在真实市场数据上的泛化能力不足：当前 Heston 训练参数范围无法覆盖 SPY 期权校准得到的极端参数，且三模型 PINN 用同一个网络同时拟合三种模型，Heston 的 5 维参数空间对网络容量要求远高于 BSM/CEV，构成根本性的容量瓶颈。此外，当前方法仅针对欧式看涨期权，不支持美式期权或奇异期权；LLM 路由层依赖外部 API，存在约 500ms 至 2000ms 的调用延迟；当前框架仅输出点估计，不提供预测不确定性，而不确定性量化在金融风险管理中至关重要。

基于上述局限性，未来工作可从以下方向展开。在模型扩展方面，可将框架推广至美式期权（处理自由边界问题）和障碍期权（修改边界条件），并针对 A 股市场（上证 50ETF 期权、沪深 300ETF 期权）重新校准参数范围，适配国内数据接口和市场微结构特殊规则。在架构改进方面，可为 Heston 模型设计专用子网络或增大网络容量，扩大训练参数范围以覆盖真实市场的极端参数；引入贝叶



斯 PINN 或集成方法提供不确定性估计；将 LLM 路由层替换为本地部署的小型语言模型，降低 API 依赖和调用延迟，同时保护用户的期权参数隐私。此外，利用 PINN 的自动微分能力直接计算 Greeks (Delta、Gamma、Vega 等)，无需有限差分近似，在风险管理中具有重要价值。



附录 A 代码架构与关键实现

本附录介绍三模型 PINN 期权定价系统的代码架构和关键模块的实现细节，供读者复现实验结果参考。

A.1 三模型 PINN 核心模型

A.1.1 网络定义伪代码

```
class UnifiedPINN(nn.Module):
```

```
    输入维度: 9 (S/Smax, v/vmax, t/T, sigma, beta,  
                kappa, theta, xi, rho)
```

```
    网络结构: 6层全连接, 每层128神经元, tanh激活  
    最后一层: 权重初始化  $N(0, 0.001^2)$ , 偏置=0
```

```
    前向传播 forward(S, v, t, lambda):
```

```
        # 1. 归一化输入
```

```
        x = [S/300, v/1, t/T, sigma, beta,  
             kappa, theta, xi, rho]
```

```
        # 2. 计算软掩码
```

```
        mask = tanh(xi / 0.05)^2
```

```
        # 3. 计算等效波动率
```

```
        sigma_eff = (1-mask)*sigma + mask*sqrt(v)
```

```
        # 4. 计算BS基线 (解析公式)
```

```
        V_BS = black_scholes(S, K, tau, r, sigma_eff)
```

```
        # 5. 网络修正量
```

```
        net_out = MLP(x)  # 6层全连接
```

```
        # 6. 加法参数化输出
```




```
V_hat = V_BS + K * net_out  
return V_hat
```

A.1.2 统一 PDE 残差计算伪代码

```
def compute_pde_residual(model, S, v, t, lambda):  
    # 使用自动微分计算偏导数  
    V = model(S, v, t, lambda)  
  
    dV_dt = autograd(V, t)  
    dV_dS = autograd(V, S)  
    d2V_dS2 = autograd(dV_dS, S)  
    dV_dv = autograd(V, v)  
    d2V_dv2 = autograd(dV_dv, v)  
    d2V_dSdv = autograd(dV_dS, v)  
  
    # 软掩码  
    mask = tanh(xi / 0.05)^2  
  
    # 统一系数  
    a = (1-mask)*sigma^2*S^(2*beta) + mask*v*S^2  
    b = mask * rho * xi * v * S  
    c = mask * xi^2 * v  
    d = mask * kappa * (theta - v)  
  
    # 统一PDE算子  
    F = (dV_dt  
        + 0.5*a*d2V_dS2  
        + b*d2V_dSdv  
        + 0.5*c*d2V_dv2  
        + r*S*dV_dS  
        + d*dV_dv  
        - r*V)
```



```
# 相对归一化残差  
residual = F / (|V| + 1)  
return mean(residual^2)
```

A.2 LLM 路由层实现

A.2.1 系统提示词

LLM 路由层使用以下系统提示词（英文，以提高 LLM 的理解准确率）：

You are an option pricing parameter extractor.

Extract parameters from user input and output JSON.

Rules for model selection:

- If user mentions "Heston", "stochastic volatility",
"vol-of-vol", kappa/theta/xi/rho: use "heston"
- If user mentions "CEV", "constant elasticity",
"beta": use "cev"
- Otherwise: use "bsm"

Default values if not specified:

S=100, K=100, T=1.0, r=0.05, sigma=0.2,
beta=0.5, v0=0.04, kappa=2.0, theta=0.04,
xi=0.3, rho=-0.7

Output format (JSON only, no explanation):

```
{  
  "model": "bsm"|"cev"|"heston",  
  "option_type": "call"|"put",  
  "S": float, "K": float, "T": float, "r": float,  
  "sigma": float, "beta": float,  
  "v0": float, "kappa": float, "theta": float,  
  "xi": float, "rho": float  
}
```



A.2.2 参数校验伪代码

```
def validate_params(params):  
    # 范围校验与截断  
    params["sigma"] = clip(params["sigma"], 0.01, 2.0)  
    params["beta"] = clip(params["beta"], 0.1, 1.0)  
    params["kappa"] = clip(params["kappa"], 0.1, 10.0)  
    params["theta"] = clip(params["theta"], 0.001, 1.0)  
    params["xi"] = clip(params["xi"], 0.01, 2.0)  
    params["rho"] = clip(params["rho"], -0.99, 0.99)  
    params["v0"] = clip(params["v0"], 0.001, 1.0)  
    params["T"] = clip(params["T"], 0.01, 10.0)  
    params["S"] = clip(params["S"], 1.0, 1000.0)  
    params["K"] = clip(params["K"], 1.0, 1000.0)  
    return params
```

A.3 参考解实现

A.3.1 BSM 解析解

```
def black_scholes(S, K, tau, r, sigma, option_type):  
    if tau <= 0:  
        if option_type == "call":  
            return max(S - K, 0)  
        else:  
            return max(K - S, 0)  
  
    d1 = (log(S/K) + (r + 0.5*sigma^2)*tau) \  
        / (sigma * sqrt(tau))  
    d2 = d1 - sigma * sqrt(tau)  
  
    if option_type == "call":  
        return S*N(d1) - K*exp(-r*tau)*N(d2)  
    else:  
        return K*exp(-r*tau)*N(-d2) - S*N(-d1)
```



A.3.2 Heston 半解析解（特征函数方法）

Heston 模型的欧式看涨期权价格通过特征函数方法计算：

$$V_{\text{Heston}} = S \cdot P_1 - K e^{-rT} \cdot P_2, \quad (\text{A.1})$$

其中 P_1 和 P_2 通过 Gil-Pelaez 反演公式计算：

$$P_j = \frac{1}{2} + \frac{1}{\pi} \int_0^\infty \text{Re} \left[\frac{e^{-i\phi \ln K} \varphi_j(\phi)}{i\phi} \right] d\phi, \quad j = 1, 2, \quad (\text{A.2})$$

其中 $\varphi_j(\phi)$ 为 Heston 模型的特征函数，具体形式见 Heston (1993) 原文。数值积分使用高斯-勒让德求积，积分上限截断为 500，节点数为 200，精度约 10^{-4} 。

A.4 训练配置

表 A.1列出了完整的训练配置，供复现实验参考。

表 A.1 三模型 PINN 完整训练配置

配置项	取值
随机种子	42
训练设备	NVIDIA GPU (CUDA)
配点数 N_c	每模型 5000 点 (BSM/CEV/Heston 各 5000)
边界点数 N_b	每模型 500 点
数据锚点数 N_d	每模型 20 点
优化器	Adam ($\beta_1 = 0.9$, $\beta_2 = 0.999$)
初始学习率	1×10^{-3}
学习率调度	余弦退火 ($\eta_{\min} = 1 \times 10^{-5}$)
总训练步数	30000
损失权重 ($w_{\text{pde}}, w_{\text{bc}}, w_{\text{data}}$)	(1, 10, 100)
软掩码阈值	0.05
最后一层初始化	$\mathcal{N}(0, 0.001^2)$
BSM 参数范围 (训练)	$\sigma \in [0.10, 0.35]$, 共 6 个变体
CEV 参数范围 (训练)	$\sigma \in [0.15, 0.25]$, $\beta \in [0.3, 0.9]$, 共 12 个变体
Heston 参数范围 (训练)	$\kappa \in [1.0, 3.0]$, $\theta \in [0.02, 0.06]$, $\xi \in [0.2, 0.4]$, $\rho \in [-0.7, -0.5]$, 共 54 个变体



参考文献

- [1] BLACK F, SCHOLES M. The pricing of options and corporate liabilities[J]. Journal of Political Economy, 1973, 81(3): 637–654.
- [2] MERTON R C. Theory of rational option pricing[J]. The Bell Journal of Economics and Management Science, 1973, 4(1): 141–183.
- [3] COX J C, ROSS S A. The valuation of options for alternative stochastic processes[J]. Journal of Financial Economics, 1976, 3(1): 145–166.
- [4] HESTON S L. A closed-form solution for options with stochastic volatility with applications to bond and currency options[J]. The Review of Financial Studies, 1993, 6(2): 327–343.
- [5] RAISSI M, PERDIKARIS P, KARNIADAKIS G. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations[J]. Journal of Computational Physics, 2019, 378: 686–707.
- [6] DHIMAN A, HU Y. Physics informed neural network for option pricing[Z]. [S.l.: s.n.], 2023.
- [7] ZAMXAKA N. Option pricing with physics-informed neural networks (PINNs)[D]. [S.l.]: University of Cape Town, 2024.
- [8] HAINAUT D, CASAS A. Option pricing in the Heston model with physics inspired neural networks[J]. Annals of Finance, 2024, 20(3): 353–376.
- [9] TAN J, ZHANG X. Improved constrained physics-informed neural networks (ICPINNs) to solve PDE and its application to option pricing[J]. Mathematics and Computers in Simulation, 2026, 241: 908–924.
- [10] LIU J, ZHU R, XU J, et al. PDE-Agent: A toolchain-augmented multi-agent framework for PDE solving[Z]. [S.l.: s.n.], 2025.
- [11] SCHRODER M. Computing the constant elasticity of variance option pricing formula[J]. Journal of Finance, 1989, 44(1): 211–219.
- [12] XIAO Y, SUN E, LUO D, et al. TradingAgents: Multi-agents LLM financial trading framework [Z]. [S.l.: s.n.], 2025.
- [13] KINGMA D P, BA J. Adam: A method for stochastic optimization[Z]. [S.l.: s.n.], 2017.
- [14] ALBRECHER H, MAYER P, SCHOUTENS W, et al. The little Heston trap[C]//Wilmott Magazine. [S.l.: s.n.], 2007: 83–92.



致 谢

感谢石老师在本文研究过程中给予的悉心指导和宝贵建议。感谢上海科技大学信息科学与技术学院提供的计算资源支持, 本文的实验在 309 实验室服务器上完成。

未完待续...