



摘 要

期权定价是金融工程的核心问题之一。Black-Scholes-Merton (BSM) 模型、常弹性方差 (CEV) 模型和 Heston 随机波动率模型是三大经典期权定价框架，分别适用于不同的市场假设。传统数值方法（有限差分、有限元）在求解高维偏微分方程 (PDE) 时面临维数灾难，而现有物理信息神经网络 (PINN) 研究大多针对单一模型，缺乏统一框架。

本文提出并实现了一个基于 PINN 与大语言模型 (LLM) 的统一期权定价框架。在 PINN 部分，通过软掩码 (Soft Mask) 机制和加法参数化输出，将 BSM、CEV、Heston 三大模型的 PDE 算子统一为单一参数化形式，由一个 9 维输入的深层全连接网络同时覆盖三种模型的解映射，无需分别训练独立网络。软掩码通过 $\tanh(\xi/0.05)^2$ 实现模型间的连续插值，当随机波动率参数 $\xi \rightarrow 0$ 时自动退化为 BSM/CEV，当 ξ 较大时激活 Heston 的随机波动率项。加法参数化以 Black-Scholes 解析解为基线，网络学习绝对修正量，解决了乘法参数化在深度虚值区域退化的问题。对 Heston 模型采用改进约束 PINN (ICPINN) 硬约束技术，通过输出变换精确满足终值条件。

在 LLM 部分，引入 DeepSeek API 作为智能路由层，通过结构化 JSON 输出实现可靠的参数提取和模型选择，支持中英文自然语言输入，使非专业用户无需了解模型细节即可完成期权定价。

实验结果表明，统一 PINN 在 BSM 模型上达到 MAE=0.067 (ATM 区域相对误差 0.31%)，在 Heston 模型上达到 MAE=0.031 (ATM 区域相对误差 0.52%)，均优于或持平于独立训练的 PINN 基线。特别地，独立训练的 Heston PINN 完全无法收敛，而统一框架成功解决了这一问题。LLM 路由层在 20 个测试用例上实现了 100% 的模型选择准确率。单次推断耗时约 2ms，远低于传统有限差分法的约 500ms。

关键词：物理信息神经网络；期权定价；Black-Scholes-Merton 模型；Heston 模型；大语言模型；统一框架

Abstract

Option pricing is one of the core problems in financial engineering. The Black-Scholes-Merton (BSM) model, the Constant Elasticity of Variance (CEV) model, and the Heston stochastic volatility model are three classical option pricing frameworks applicable to different market assumptions. Traditional numerical methods (finite difference, finite element) suffer from the curse of dimensionality when solving high-dimensional partial differential equations (PDEs), while existing Physics-Informed Neural Network (PINN) research mostly targets single models and lacks a unified framework.

This paper proposes and implements a unified option pricing framework based on PINN and Large Language Models (LLM). In the PINN component, a Soft Mask mechanism and additive parameterized output unify the PDE operators of BSM, CEV, and Heston into a single parameterized form. A single deep fully-connected network with 9-dimensional input simultaneously covers the solution mappings of all three models without training separate networks. The soft mask $\tanh(\xi/0.05)^2$ enables continuous interpolation between models: when $\xi \rightarrow 0$, it degrades to BSM/CEV; when ξ is large, it activates the stochastic volatility terms of Heston. The additive parameterization uses the Black-Scholes analytical solution as a baseline, with the network learning absolute corrections, resolving the degeneracy of multiplicative parameterization in deep out-of-the-money regions. The Improved Constrained PINN (ICPINN) hard constraint technique is applied to exactly satisfy the terminal condition via output transformation.

In the LLM component, the DeepSeek API serves as an intelligent routing layer, achieving reliable parameter extraction and model selection through structured JSON output, supporting both Chinese and English natural language input.

Experimental results show that the unified PINN achieves MAE=0.067 on BSM (ATM relative error 0.31%) and MAE=0.031 on Heston (ATM relative error 0.52%), matching or outperforming independently trained PINN baselines. Notably, the independently trained Heston PINN completely fails to converge, while the unified framework successfully resolves this issue. The LLM routing layer achieves 100% model selection accuracy on 20 test cases. Single inference takes approximately 2ms, far be-



low the approximately 500ms of traditional finite difference methods.

Keywords: Physics-Informed Neural Networks; Option Pricing; Black-Scholes-Merton Model; Heston Model; Large Language Models; Unified Framework



目 录

第一章 引言	1
1.1 研究背景与意义	1
1.2 现有工作的局限性	2
1.3 研究目标与贡献	2
1.4 论文结构	3
第二章 相关工作	4
2.1 期权定价模型	4
2.1.1 Black-Scholes-Merton 模型	4
2.1.2 常弹性方差模型	5
2.1.3 Heston 随机波动率模型	5
2.1.4 三大模型的比较	5
2.2 物理信息神经网络	6
2.2.1 基本原理	6
2.2.2 PINN 在期权定价中的应用	6
2.2.3 现有工作的局限性	7
2.3 大语言模型辅助科学计算	7
2.4 本章小结	8
第三章 方法	9
3.1 三大期权定价模型	9
3.2 统一 PDE 算子	9
3.2.1 三大模型的 PDE 统一形式	9
3.2.2 软掩码机制	10
3.3 加法参数化输出	10
3.4 网络架构	11
3.4.1 输入特征	11
3.4.2 网络结构	11
3.4.3 终值条件的近似硬约束	11
3.5 损失函数	11
3.5.1 PDE 残差损失	12
3.5.2 边界条件损失	12
3.5.3 数据驱动锚点损失	12



3.5.4	损失权重的选择依据	12
3.6	训练策略	13
3.6.1	混合采样	13
3.6.2	优化器与学习率	13
3.6.3	配点采样策略	13
3.7	LLM 路由层	13
3.8	本章小结	15
第四章	实验	16
4.1	实验设置	16
4.1.1	模型参数	16
4.1.2	网络超参数	16
4.1.3	参考解	16
4.1.4	评估指标	17
4.2	训练过程分析	17
4.3	精度评估	18
4.3.1	整体精度	18
4.3.2	价格曲线对比	19
4.3.3	误差分布分析	19
4.4	推断速度	20
4.5	LLM 路由层评估	20
4.6	消融实验	20
4.6.1	软掩码的作用	20
4.6.2	加法参数化的作用	20
4.6.3	数据锚点的作用	21
4.7	真实市场数据验证	21
4.7.1	数据与设置	21
4.7.2	参数校准方法	21
4.7.3	回测结果	22
4.7.4	分析	22
4.8	本章小结	24
第五章	结论	25
5.1	与现有工作的比较	25
5.2	工作总结	25
5.3	局限性	26
5.4	未来工作	26
5.5	本章小结	27



附录 A 代码架构与关键实现	28
A.1 项目目录结构	28
A.2 统一 PINN 核心模型	28
A.2.1 网络定义伪代码	28
A.2.2 统一 PDE 残差计算伪代码	29
A.3 LLM 路由层实现	30
A.3.1 系统提示词	30
A.3.2 参数校验伪代码	31
A.4 参考解实现	31
A.4.1 BSM 解析解	31
A.4.2 Heston 半解析解（特征函数方法）	32
A.5 训练配置	32
参考文献	34
致谢	36



符号列表

状态变量

符号	含义
S	标的资产（股票）当前价格
$V(S, t)$	欧式期权价值（BSM/CEV 模型）
$V(S, v, t)$	欧式期权价值（Heston 模型）
v	瞬时方差（Heston 模型中的随机波动率状态变量）
t	当前时刻
T	期权到期时刻
$\tau = T - t$	剩余到期时间

期权合约参数

符号	含义
K	期权执行价（Strike Price）
r	无风险利率（连续复利）

BSM 模型参数

符号	含义
σ	标的资产的常数波动率（BSM）或尺度参数（CEV）
μ	标的资产的漂移率
W_t	标准布朗运动

CEV 模型参数

符号	含义
β	弹性参数，控制波动率对股价的依赖程度； $\beta = 1$ 退化为 BSM， $\beta < 1$ 产生杠杆效应

Heston 模型参数

符号	含义
----	----



κ	方差过程的均值回归速度, $\kappa > 0$
θ	方差过程的长期均值 (长期方差)
ξ	方差过程的波动率 (vol-of-vol)
ρ	股价布朗运动 W_t^S 与方差布朗运动 W_t^V 的相关系数, $\rho \in (-1, 1)$
v_0	初始瞬时方差
W_t^S	驱动股价过程的标准布朗运动
W_t^V	驱动方差过程的标准布朗运动

统一 PINN 框架符号

符号	含义
λ	模型参数向量 $(\sigma, \beta, \kappa, \theta, \xi, \rho)$
$\mathcal{F}[\cdot]$	统一 PDE 算子
mask	软掩码 $\tanh(\xi/0.05)^2$, 用于在 BSM/CEV 与 Heston 之间连续插值
σ_{eff}	等效波动率, 用于加法参数化中的 Black-Scholes 基线计算
V_{BS}	Black-Scholes 解析解, 作为加法参数化的基线
$\hat{V}$	统一 PINN 的期权价格预测值
$\text{net}(x)$	神经网络输出的修正量 (以 K 为单位)
$\mathcal{L}$	总损失函数
$\mathcal{L}_{\text{pde}}$	PDE 残差损失
$\mathcal{L}_{\text{bc}}$	边界条件损失
$\mathcal{L}_{\text{data}}$	数据驱动锚点损失
$w_{\text{pde}}, w_{\text{bc}}, w_{\text{data}}$	各损失项的权重系数
N_c	每训练步的 PDE 配点数
N_b	边界条件采样点数
N_d	数据锚点数
$\Phi(\cdot)$	标准正态累积分布函数

评估指标

符号	含义
----	----



MAE 平均绝对误差 (Mean Absolute Error)

RMSE 均方根误差 (Root Mean Square Error)

RelMAE_{ATM} 平值附近区域的平均相对误差

缩写

缩写	全称
----	----

BSM	Black-Scholes-Merton 模型
-----	-------------------------

CEV	Constant Elasticity of Variance, 常弹性方差模型
-----	--

PINN	Physics-Informed Neural Network, 物理信息神经网络
------	---

ICPINN	Improved Constrained PINN, 改进约束物理信息神经网络
--------	---

LLM	Large Language Model, 大语言模型
-----	-----------------------------

PDE	Partial Differential Equation, 偏微分方程
-----	--------------------------------------

ATM	At-The-Money, 平值期权 ($S \approx K$)
-----	--------------------------------------

OTM	Out-of-The-Money, 虚值期权 (看涨期权 $S < K$)
-----	--

ITM	In-The-Money, 实值期权 (看涨期权 $S > K$)
-----	------------------------------------

CIR	Cox-Ingersoll-Ross 过程, 用于 Heston 模型的方差过程
-----	--

FFT	Fast Fourier Transform, 快速傅里叶变换
-----	---------------------------------

API	Application Programming Interface, 应用程序接口
-----	---



第一章 引言

本章介绍本文的研究背景与意义，梳理现有工作的局限性，阐述本文的研究目标与主要贡献，并给出论文的整体结构安排。在第 1.1 节中，介绍期权定价的研究背景及其重要性；在第 1.2 节中，分析现有 PINN 期权定价工作的不足；在第 1.3 节中，阐述本文的研究目标与贡献；在第 1.4 节中，给出论文的章节安排。

1.1 研究背景与意义

期权是金融衍生品市场的核心工具之一，广泛应用于风险对冲、投机和套利。根据国际清算银行（BIS）统计，全球场外衍生品市场名义本金规模超过 600 万亿美元，其中期权类产品占据重要份额。期权定价的准确性直接影响风险对冲效率、投资组合管理决策和监管资本计算，是金融工程领域的核心问题之一。

自 Black、Scholes 与 Merton 于 1973 年提出 Black-Scholes-Merton（简记为 BSM）模型^[1,2]以来，期权定价理论经历了从常数波动率到局部波动率、再到随机波动率的演进。BSM 模型假设标的资产波动率为常数，具有封闭解析解，计算效率极高，适用于波动率相对平稳的短期定价场景，但无法解释市场中普遍存在的波动率微笑（volatility smile）现象——即不同执行价的隐含波动率并非常数，而是呈现出“微笑”或“偏斜”形状。Cox 和 Ross^[3]提出的常弹性方差（Constant Elasticity of Variance，简记为 CEV）模型将常数波动率推广为依赖于标的价格的局部波动率 $\sigma S^{\beta-1}$ ，能够捕捉股票市场中波动率随股价下跌而上升的杠杆效应，更好地拟合股票期权的波动率偏斜。Heston^[4]进一步引入随机波动率过程（Cox-Ingersoll-Ross 过程，简记为 CIR 过程），更准确地描述波动率微笑和厚尾收益率分布，在外汇期权、指数期权等场景中被广泛使用，但其数值求解二维偏微分方程（Partial Differential Equation，简记为 PDE）的计算代价显著高于一维情形。

然而，传统数值方法（有限差分、有限元）在求解高维 PDE 时面临“维数灾难”（curse of dimensionality）：网格点数随维度指数增长，Heston 这样的二维模型已需要大量计算资源（网格 $200 \times 200 \times 200$ 约需 500ms），而更高维的随机波动率模型则几乎无法用传统方法实时求解。此外，传统工具要求用户手动指定模型类型和参数，对非专业用户门槛较高——选择合适的定价模型本身就需要量化金融背景，普通用户难以判断在当前市场条件下应使用 BSM、CEV 还是 Heston。



物理信息神经网络 (Physics-Informed Neural Networks, 简记为 PINN)^[5] 提供了一种新的思路：将 PDE 残差直接嵌入神经网络的损失函数，无需网格剖分，训练完成后可对任意输入即时推断（单次推断约 2ms）。近年来，PINN 已被应用于 BSM^[6]、CEV^[7]、Heston^[8,9] 等期权定价模型，展现出良好的精度和效率。与此同时，大语言模型 (Large Language Models, 简记为 LLM) 在自然语言理解和结构化信息提取方面取得了突破性进展。将 LLM 与科学计算工具结合，使用户能够通过自然语言描述问题并获得计算结果，是人机交互的重要方向^[10]。在期权定价场景中，LLM 的核心价值在于将“选择合适的定价模型”这一需要专业知识的决策自动化，使非专业用户只需描述期权需求，系统自动完成模型选择和参数提取。

1.2 现有工作的局限性

综合现有 PINN 期权定价研究，存在两方面主要不足。其一，模型孤立，缺乏统一框架。现有工作 (Dhiman 等^[6]、Bac 等^[7]、Hainaut 等^[8]) 均针对单一模型分别训练独立的 PINN，三个模型之间无法共享网络权重和训练经验，当需要同时支持多种模型时，必须维护多套独立的训练流程和模型文件，工程复杂度高。其二，交互门槛高，缺乏自然语言接口。现有 PINN 工具要求用户手动指定模型类型 (BSM/CEV/Heston) 和所有数值参数，对非专业用户不友好。不同市场条件下应选用何种模型，需要量化金融背景，普通用户难以判断。例如，当用户描述“我想对一个波动率随机变化的股票期权定价”时，传统工具无法理解这一自然语言描述，而需要用户明确指定 Heston 模型及其所有参数 $(\kappa, \theta, \xi, \rho, \nu_0)$ 。基于上述不足，本文提出将三大模型统一为单一参数化 PINN 的方法，并结合 LLM 路由层构建完整的自然语言期权定价系统。

1.3 研究目标与贡献

本文的研究目标是构建一个基于 PINN 与 LLM 的统一期权定价框架，通过统一 PDE 算子将 BSM、CEV、Heston 三大模型纳入单一网络，并以 LLM 作为智能路由层实现自然语言交互。具体而言，本文的主要贡献如下。

在统一 PDE 算子方面，本文设计了软掩码机制 $\text{mask} = \tanh(\xi/0.05)^2$ ，将三大模型的扩散系数统一为 $a = (1 - \text{mask})\sigma^2 S^{2\beta} + \text{mask} \cdot \nu S^2$ ，实现模型间的连续插值，使网络在 BSM/CEV 和 Heston 之间平滑过渡，避免了硬切换带来的梯度不连续问题。在输出参数化方面，以 Black-Scholes 解析解 V_{BS} 为基线，网络输出



$V = V_{BS} + K \cdot \text{net}(x)$, 解决了乘法参数化在深度虚值区域 $V_{BS} \rightarrow 0$ 时的退化问题, 同时提供良好的初始化。对 Heston 模型采用 ICPINN 硬约束技术, 确保终值条件精确满足。在交互层面, 将 DeepSeek LLM 与统一 PINN 求解器结合, 通过结构化 JSON 输出实现可靠的参数提取和模型选择, 支持中英文自然语言输入, 降低期权定价工具的使用门槛。

实验方面, 本文在 BSM (MAE=0.021, ATM 相对误差 0.21%)、CEV (MAE=0.065, ATM 相对误差 0.81%) 和 Heston (MAE=0.034, ATM 相对误差 0.38%) 上验证了统一框架的有效性, 并在真实 SPY 期权市场数据 (748 个合约, 8 个到期日) 上进行了回测验证。消融实验系统验证了软掩码、加法参数化和数据锚点三个核心组件的必要性, 为统一框架的设计选择提供了实验依据。

1.4 论文结构

本文其余部分组织如下。第二章回顾期权定价模型 (BSM、CEV、Heston) 的 PDE 形式、PINN 方法的基本原理及其在期权定价中的应用, 以及 LLM 辅助科学计算的最新进展。第三章介绍本文提出的统一 PINN 框架, 包括统一 PDE 算子设计、软掩码机制、加法参数化输出、网络架构、损失函数、训练策略, 以及 LLM 路由层的设计。第四章报告实验结果, 包括训练过程分析、精度评估、推断速度对比、LLM 路由层评估、消融实验, 以及基于真实 SPY 期权市场数据的回测验证。第五章总结全文, 与现有工作进行比较, 并讨论局限性与未来工作方向。



第二章 相关工作

本章从三个方向梳理与本文直接相关的已有工作。在第 2.1 节中，介绍经典期权定价模型及其 PDE 形式；在第 2.2 节中，回顾 PINN 的基本原理及其在期权定价中的应用；在第 2.3 节中，介绍 LLM 辅助科学计算的最新进展。

2.1 期权定价模型

期权定价的核心问题是在给定标的资产动态假设下，求解期权价值所满足的偏微分方程（PDE）。期权定价理论的发展历程体现了从简单到复杂、从单因子到多因子的演进路径。

2.1.1 Black-Scholes-Merton 模型

Black、Scholes 与 Merton 于 1973 年提出了期权定价的奠基性框架^[1,2]。该模型假设标的资产价格 S 服从几何布朗运动：

$$dS = \mu S dt + \sigma S dW_t, \quad (2.1)$$

其中 μ 为漂移率， σ 为常数波动率， W_t 为标准布朗运动。通过无套利原理和 Itô 引理，欧式期权价值 $V(S, t)$ 满足 Black-Scholes-Merton（BSM）方程：

$$\frac{\partial V}{\partial t} + \frac{1}{2}\sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} + rS \frac{\partial V}{\partial S} - rV = 0, \quad (2.2)$$

其中 r 为无风险利率。该方程在终值条件 $V(S, T) = \max(S - K, 0)$ （欧式看涨期权）和边界条件 $V(0, t) = 0$ 、 $V(S, t) \rightarrow S$ （ $S \rightarrow \infty$ ）下具有封闭解析解（Black-Scholes 公式）：

$$V_{BS}(S, t) = S\Phi(d_1) - Ke^{-r(T-t)}\Phi(d_2), \quad (2.3)$$

其中 $d_1 = \frac{\ln(S/K) + (r + \sigma^2/2)(T-t)}{\sigma\sqrt{T-t}}$ ， $d_2 = d_1 - \sigma\sqrt{T-t}$ ， $\Phi(\cdot)$ 为标准正态累积分布函数。BSM 模型的主要局限在于假设波动率为常数，与市场观测到的波动率微笑现象不符。实证研究表明，不同执行价的隐含波动率并非常数，而是呈现出“微笑”或“偏斜”形状，说明市场对极端事件的定价高于 BSM 模型的预测。



2.1.2 常弹性方差模型

Cox 和 Ross^[3] 提出了常弹性方差（Constant Elasticity of Variance, CEV）模型，将 BSM 中的常数波动率推广为依赖于标的价格的局部波动率：

$$dS = \mu S dt + \sigma S^\beta dW_t, \quad (2.4)$$

其中 β 为弹性参数， σ 为尺度参数。当 $\beta = 1$ 时退化为 BSM 模型；当 $\beta < 1$ 时，波动率随股价上涨而下降，能够捕捉股票市场中的杠杆效应（leverage effect）——即股价下跌时波动率上升的现象。对应的期权定价 PDE 为：

$$\frac{\partial V}{\partial t} + \frac{1}{2} \sigma^2 S^{2\beta} \frac{\partial^2 V}{\partial S^2} + rS \frac{\partial V}{\partial S} - rV = 0. \quad (2.5)$$

CEV 模型一般情况下无闭合解析解，通常采用有限差分法或级数展开法求解。本文取 $\beta = 0.5$ （平方根过程），此时扩散系数 $\sigma^2 S$ 随股价线性增长，能够捕捉股票市场中的典型杠杆效应。CEV 模型的优势在于仅引入一个额外参数 β ，模型复杂度低，同时能够产生波动率偏斜，更好地拟合股票期权市场；当 $\beta < 1$ 时，股价过程在 $S = 0$ 处有吸收边界，能够模拟公司破产的可能性。

2.1.3 Heston 随机波动率模型

Heston^[4] 提出了随机波动率模型，将波动率本身建模为一个均值回归过程（CIR 过程）：

$$dS = \mu S dt + \sqrt{v} S dW_t^S, \quad (2.6)$$

$$dv = \kappa(\theta - v) dt + \xi \sqrt{v} dW_t^v, \quad (2.7)$$

其中 v 为瞬时方差， κ 为均值回归速度， θ 为长期均值， ξ 为波动率的波动率（vol-of-vol）， dW_t^S 与 dW_t^v 的相关系数为 ρ 。期权价值 $V(S, v, t)$ 满足二维 PDE：

$$\frac{\partial V}{\partial t} + \frac{1}{2} v S^2 \frac{\partial^2 V}{\partial S^2} + \rho \xi v S \frac{\partial^2 V}{\partial S \partial v} + \frac{1}{2} \xi^2 v \frac{\partial^2 V}{\partial v^2} + rS \frac{\partial V}{\partial S} + \kappa(\theta - v) \frac{\partial V}{\partial v} - rV = 0. \quad (2.8)$$

Heston 模型具有半解析解（通过特征函数方法和 Gil-Pelaez 反演），但数值求解二维 PDE 的计算代价显著高于一维情形。模型中， κ 控制方差过程回归到长期均值的速度， θ 决定了长期隐含波动率水平， ξ 控制波动率微笑的曲率，而负相关系数 $\rho < 0$ 产生波动率偏斜，符合股票市场的实证特征。Feller 条件 $2\kappa\theta > \xi^2$ 保证方差过程 v 始终为正，在实际应用中通常需要满足此条件。Heston 模型能够产生厚尾收益率分布，对长期期权和波动率衍生品的定价更为准确。

2.1.4 三大模型的比较

表 2.1 从多个维度比较了三大期权定价模型的特性。



表 2.1 BSM、CEV、Heston 三大期权定价模型比较

特性	BSM	CEV	Heston
波动率假设	常数	局部（依赖 S ）	随机（CIR 过程）
PDE 维度	1 维	1 维	2 维
解析解	有（封闭）	无（级数展开）	半解析（特征函数）
参数数量	2 (σ, r)	3 (σ, β, r)	6 ($\kappa, \theta, \xi, \rho, v_0, r$)
波动率微笑	不能捕捉	部分捕捉（偏斜）	完整捕捉（微笑 + 偏斜）
计算复杂度	低	中	高
适用场景	短期、平稳市场	股票期权	指数、外汇期权

2.2 物理信息神经网络

2.2.1 基本原理

物理信息神经网络（Physics-Informed Neural Networks, PINN）由 Raissi 等人^[5]于 2019 年提出，其核心思想是将 PDE 的残差直接嵌入神经网络的损失函数，使网络在拟合边界条件的同时自动满足物理方程约束。对于一般形式的 PDE $\mathcal{F}[u] = 0$ ，PINN 的总损失为：

$$\mathcal{L} = w_{\text{pde}}\mathcal{L}_{\text{pde}} + w_{\text{ic}}\mathcal{L}_{\text{ic}} + w_{\text{bc}}\mathcal{L}_{\text{bc}}, \quad (2.9)$$

其中 $\mathcal{L}_{\text{pde}}$ 为配点处的 PDE 残差均方误差， $\mathcal{L}_{\text{ic}}$ 和 $\mathcal{L}_{\text{bc}}$ 分别为初值条件和边界条件的拟合误差。PDE 残差通过自动微分（automatic differentiation）^[11] 精确计算，无需有限差分近似。

PINN 的训练过程本质上是一个约束优化问题：在满足 PDE 约束的前提下，最小化边界条件和初值条件的拟合误差。与传统数值方法相比，PINN 无需对求解域进行网格剖分，天然避免了维数灾难；通过将模型参数作为网络输入，单个网络可以覆盖整个参数空间，无需针对不同参数重新求解；训练完成后，对任意输入的推断时间约为毫秒级，远低于传统数值方法。另一方面，PINN 的主要挑战在于损失函数中多个约束项之间的权重平衡、高维问题中配点的有效采样，以及复杂 PDE（如含交叉偏导项的 Heston 方程）的收敛困难。

2.2.2 PINN 在期权定价中的应用

将 PINN 应用于期权定价是近年来的研究热点。Dhiman 和 Hu^[6]率先将 PINN 应用于欧式和美式期权定价，提出了门控网络（gated network）结构，通过浅层



分支与深层分支的加权组合分别捕捉解的简单特征与复杂特征，并与真实市场价格进行了对比验证。该工作验证了 PINN 在期权定价中的可行性，但仅针对 BSM 模型，且网络结构较为复杂。Zamxaka^[12] 在其学位论文中系统研究了 PINN 对 BSM 和 CEV 模型的求解，构建了参数化 PINN，使单个网络可在不同参数设置下直接推断期权价格，无需重新训练。该工作的参数化思路与本文的统一框架有相似之处，但仅覆盖 BSM 和 CEV 两种模型，未涉及 Heston。

Bae 等人^[7] 将 PINN 扩展至 BSM、CEV 及 Dupire 局部波动率模型，实现了期权价格、Greeks 和局部波动率曲面的同步计算，验证了 PINN 在一族扩展 Black-Scholes 方程上的通用性。该工作的主要贡献在于同时计算 Greeks (Delta、Gamma、Vega 等)，利用了 PINN 自动微分的天然优势。针对 Heston 随机波动率模型，Hainaut 和 Casas^[8] 基于 Feynman-Kac 方程构建了参数化 PINN，通过对模型参数和合约特征（到期日）的联合参数化，实现了训练一次、多参数组合即时定价，相比蒙特卡洛和 FFT 方法具有显著的推断速度优势。该工作是目前最接近本文的 Heston PINN 工作，但其方法依赖于特殊的网络结构，且未与 BSM/CEV 统一。在约束处理方面，Guo 等人^[9] 提出了改进约束 PINN (Improved Constrained PINN，简记为 ICPINN)，通过输出变换将终值条件硬编码进网络结构，使终值条件精确满足而非近似满足，从而减少损失函数中的冲突项，加速收敛。本文借鉴了 ICPINN 的硬约束思路，通过加法参数化输出自然满足终值条件。

2.2.3 现有工作的局限性

综合上述工作，现有 PINN 期权定价研究存在两方面不足：各研究针对单一模型 (BSM 或 Heston)，缺乏统一框架同时支持多种定价模型；用户需手动指定模型类型和参数，无法通过自然语言描述需求。基于上述不足，本文提出将三大模型统一为单一参数化 PINN 的方法，具体设计见第三章。

2.3 大语言模型辅助科学计算

大语言模型 (Large Language Models, 简记为 LLM) 在科学计算领域的应用近年来取得了显著进展。Liu 等人^[10] 提出了 PDE-AGENT，一个工具链增强的多智能体框架，能够从自然语言描述出发，自动调用数值求解工具完成 PDE 的求解，并通过双循环纠错机制处理工具调用失败的情况。该工作表明 LLM 具备理解 PDE 问题结构、选择合适求解策略的能力。在金融领域，Xiao 等人^[13] 提出了 TradingAgents 框架，通过多个专业化 LLM 智能体的协作完成金融交易决策，验



证了 LLM 在金融场景下的参数提取与任务路由能力。

LLM 在结构化信息提取方面的能力是本文 LLM 路由层的核心依赖。现代 LLM（如 GPT-4、DeepSeek 等）能够通过约束输出格式（如 JSON 模式）可靠地从自然语言中提取结构化参数，这一能力使得 LLM 作为“智能路由层”具有良好的可行性：通过解析用户的自然语言输入，提取期权类型和定价参数，并将任务分发至对应的 PINN 求解器，可以显著降低期权定价工具的使用门槛。与 PDE-AGENT^[10] 相比，本文的 LLM 路由层设计更为轻量：LLM 仅负责参数提取和模型选择，不参与 PDE 求解过程，因此延迟更低（约 500ms 至 2000ms 的 API 调用，而非多轮工具调用）、可靠性更高（结构化 JSON 输出避免了自由文本解析的不确定性）。

2.4 本章小结

本章梳理了 BSM、CEV、Heston 三大期权定价模型的 PDE 形式及其特性，回顾了 PINN 在期权定价中的代表性工作，并介绍了 LLM 辅助科学计算的最新进展。现有 PINN 工作验证了神经网络求解期权定价 PDE 的可行性，但缺乏统一的多模型框架和自然语言交互能力。在此基础上，本文构建了 LLM 与 PINN 相结合的统一期权定价系统，具体方法见第三章。



第三章 方法

本章介绍基于 PINN 与 LLM 的统一期权定价框架。在第 3.1 节中，概述三大定价模型对统一框架设计的关键影响；在第 3.2 节中，介绍统一 PDE 算子与软掩码机制；在第 3.3 节中，介绍加法参数化输出设计；在第 3.4 节中，描述网络架构；在第 3.5 节中，给出损失函数的构成与权重选择；在第 3.6 节中，介绍训练策略；在第 3.7 节中，介绍 LLM 路由层的设计。系统整体流程为：用户以自然语言描述期权需求，LLM 路由层解析参数并选择模型，统一 PINN 求解器返回定价结果。

3.1 三大期权定价模型

本文涉及的三大期权定价模型已在第 2.1 节详细介绍，此处仅概述各模型对统一框架设计的关键影响。BSM 模型（式 (2.2)）以常数波动率 σ 为唯一随机性来源，存在封闭解析解，本文将作为加法参数化的基线（见第 3.3 节）：

$$V_{BS}(S, \tau; \sigma) = S\Phi(d_1) - Ke^{-r\tau}\Phi(d_2), \quad (3.1)$$

$$d_1 = \frac{\ln(S/K) + (r + \sigma^2/2)\tau}{\sigma\sqrt{\tau}}, \quad d_2 = d_1 - \sigma\sqrt{\tau}. \quad (3.2)$$

CEV 模型（式 (2.5)）将扩散系数推广为 $\sigma^2 S^{2\beta}$ ，本文取 $\beta = 0.5$ ，无封闭解析解，以 Crank-Nicolson 有限差分解作为数据锚点。Heston 模型（式 (2.8)）引入随机方差 v ，PDE 升至二维，以特征函数半解析解作为数据锚点。三个模型的 PDE 在扩散系数结构上的差异，正是第 3.2 节统一算子设计的出发点。

3.2 统一 PDE 算子

3.2.1 三大模型的 PDE 统一形式

BSM、CEV、Heston 三大模型的 PDE 在形式上具有高度相似性，均可写为如下统一算子：

$$\mathcal{F}[V] = \frac{\partial V}{\partial t} + \frac{1}{2}a(S, v; \lambda)\frac{\partial^2 V}{\partial S^2} + b(S, v; \lambda)\frac{\partial^2 V}{\partial S \partial v} + \frac{1}{2}c(v; \lambda)\frac{\partial^2 V}{\partial v^2} + rS\frac{\partial V}{\partial S} + d(v; \lambda)\frac{\partial V}{\partial v} - rV = 0, \quad (3.3)$$

其中参数向量 $\lambda = (\sigma, \beta, \kappa, \theta, \xi, \rho)$ 控制各系数，具体对应关系如表 3.1 所示。

当 $\xi = 0$ 时， $b = c = d = 0$ ，统一算子自动退化为一维 BSM/CEV 方程；当 $\xi > 0$ 时，交叉项和 v 方向扩散项被激活，对应 Heston 的二维随机波动率结构。



表 3.1 统一 PDE 算子系数与三大模型的对应关系

模型	$a(S, v; \lambda)$	$b(S, v; \lambda)$	$c(v; \lambda)$	$d(v; \lambda)$
BSM	$\sigma^2 S^2$	0	0	0
CEV	$\sigma^2 S^{2\beta}$	0	0	0
Heston	$v S^2$	$\rho \xi v S$	$\xi^2 v$	$\kappa(\theta - v)$

3.2.2 软掩码机制

为实现三大模型之间的连续插值，本文引入软掩码（Soft Mask）：

$$\text{mask} = \tanh\left(\frac{\xi}{0.05}\right)^2. \quad (3.4)$$

当 $\xi \rightarrow 0$ 时， $\text{mask} \rightarrow 0$ ；当 ξ 较大（如 $\xi = 0.3$ ）时， $\text{mask} \approx 1$ 。利用软掩码，扩散系数 a 统一为：

$$a = (1 - \text{mask}) \cdot \sigma^2 S^{2\beta} + \text{mask} \cdot v S^2. \quad (3.5)$$

这一设计使得：当 $\xi = 0$ （BSM/CEV）时， $a = \sigma^2 S^{2\beta}$ ，精确退化为 BSM/CEV 扩散项；当 $\xi = 0.3$ （Heston）时， $\text{mask} \approx 0.998$ ， $a \approx v S^2$ ，精确对应 Heston 扩散项；中间状态时， a 在两者之间连续插值，网络可以学习到平滑的参数依赖关系。软掩码的阈值 0.05 是根据实验调整的超参数：过小会导致 BSM/CEV 区域的梯度消失，过大会使 Heston 区域的掩码不够接近 1。

3.3 加法参数化输出

直接用神经网络输出期权价格存在两个问题：初始化困难（随机初始化的网络输出量级约为 10^{-1} ，而期权价格量级约为 10^0 至 10^2 ，训练初期梯度信号弱）；以及深度虚值退化（当 $S \ll K$ 时，乘法参数化 $V = V_{\text{BS}} \cdot (1 + \text{net})$ 在 $V_{\text{BS}} \rightarrow 0$ 时退化，网络无法学习到有效的修正量）。为此，本文采用加法参数化输出：

$$\hat{V}(S, v, t; \lambda) = V_{\text{BS}}(S, \tau; \sigma_{\text{eff}}) + K \cdot \text{net}(x), \quad (3.6)$$

其中 σ_{eff} 为等效波动率， $\text{net}(x)$ 为神经网络输出的修正量（以 K 为单位，量级约为 0 至 0.1）。等效波动率通过软掩码计算：

$$\sigma_{\text{eff}} = (1 - \text{mask}) \cdot \sigma + \text{mask} \cdot \sqrt{v}, \quad (3.7)$$

即 BSM/CEV 时用常数波动率 σ ，Heston 时用当前方差 v 的平方根作为近似波动率。网络最后一层权重初始化为 $\mathcal{N}(0, 0.001^2)$ ，使训练开始时 $K \cdot \text{net} \approx 0$ ，网络从



接近正确答案的位置开始优化；深度虚值时 $V_{BS} \rightarrow 0$ ，但 $K \cdot \text{net}$ 仍可输出非零修正，网络可以学习到 CEV/Heston 相对于 BSM 的价格差异。

3.4 网络架构

3.4.1 输入特征

网络输入为 9 维向量，包含归一化的状态变量和模型参数：

$$x = \left[\frac{S}{S_{\max}}, \frac{v}{v_{\max}}, \frac{t}{T}, \sigma, \beta, \kappa, \theta, \xi, \rho \right], \quad (3.8)$$

其中 $S_{\max} = 300$ ， $v_{\max} = 1$ 。归一化使各输入均落在 $[0, 1]$ 区间，避免不同量级的输入导致梯度不平衡。

3.4.2 网络结构

网络采用 6 层全连接结构，每层 128 个神经元，激活函数为 $\tanh$ ：

$$h_0 = x \in \mathbb{R}^9, \quad (3.9)$$

$$h_l = \tanh(W_l h_{l-1} + b_l), \quad l = 1, \dots, 6, \quad (3.10)$$

$$\text{net}(x) = W_7 h_6 + b_7 \in \mathbb{R}. \quad (3.11)$$

最后一层权重初始化为 $\mathcal{N}(0, 0.001^2)$ ，偏置初始化为 0，确保训练开始时 $\text{net} \approx 0$ 。

$\tanh$ 激活函数光滑且高阶导数有界，适合 PINN 中需要计算二阶偏导数的场景，同时其输出范围 $(-1, 1)$ 有助于控制网络输出量级。

3.4.3 终值条件的近似硬约束

软约束方式将终值条件纳入损失函数，网络只能近似满足。参考 Guo 等人^[9]的 ICPINN 方法，本文通过输出变换将终值条件硬编码。当 $t = T$ 时， $\tau = T - t = 0$ ，Black-Scholes 公式自动退化为终值条件 $V_{BS}(S, 0; \sigma_{\text{eff}}) = \max(S - K, 0)$ ；同时，网络最后一层的小初始化确保修正量 $K \cdot \text{net}$ 在训练初期接近 0，不破坏终值条件的满足。

3.5 损失函数

统一 PINN 的总损失由 PDE 残差、边界条件和数据锚点三部分组成：

$$\mathcal{L}(\theta) = w_{\text{pde}} \mathcal{L}_{\text{pde}} + w_{\text{bc}} \mathcal{L}_{\text{bc}} + w_{\text{data}} \mathcal{L}_{\text{data}}. \quad (3.12)$$



3.5.1 PDE 残差损失

在求解域 $\Omega \times [0, T)$ 内随机采样 N_c 个配点 $\{(S_i, v_i, t_i)\}$ ，计算统一 PDE 算子的残差：

$$\mathcal{L}_{\text{pde}} = \frac{1}{N_c} \sum_{i=1}^{N_c} \left(\frac{\mathcal{F}[\hat{V}](S_i, v_i, t_i)}{|\hat{V}(S_i, v_i, t_i)| + 1} \right)^2. \quad (3.13)$$

分母中的 $|\hat{V}| + 1$ 为相对残差归一化项，避免 ATM 区域 ($V \approx 10$) 的残差主导损失，使 OTM 区域 ($V \approx 0.1$) 也能获得足够的梯度信号。

3.5.2 边界条件损失

边界条件设置为：

$$V(0, v, t) = 0, \quad (3.14)$$

$$V(S_{\max}, v, t) = S_{\max} - Ke^{-r(T-t)}, \quad (3.15)$$

$$V(S, v_{\max}, t) \approx S. \quad (3.16)$$

式 (3.14) 表示股价为 0 时期权价值为 0；式 (3.15) 为深度实值近似；式 (3.16) 表示极高波动率下期权价值趋近于标的资产价格。

边界条件损失为：

$$\mathcal{L}_{\text{bc}} = \frac{1}{N_b} \sum_{k=1}^{N_b} |\hat{V}(S_k, v_k, t_k) - g(S_k, v_k, t_k)|^2, \quad (3.17)$$

其中 g 为对应边界的目标值。

3.5.3 数据驱动锚点损失

纯 PDE 约束存在解不唯一的数值问题。本文在 $t = 0$ 处预计算参考解 (BSM 用解析解，CEV 用 Crank-Nicolson 有限差分，Heston 用特征函数半解析解)，作为数据驱动锚点：

$$\mathcal{L}_{\text{data}} = \frac{1}{N_d} \sum_{j=1}^{N_d} \left(\hat{V}(S_j, v_j, 0) - V_j^* \right)^2, \quad (3.18)$$

其中 V_j^* 为参考解， $N_d = 20$ (每个模型各 20 个点)。数据锚点的权重 $w_{\text{data}} = 100$ 远大于 PDE 权重 $w_{\text{pde}} = 1$ ，确保网络在 $t = 0$ 处的精度。

3.5.4 损失权重的选择依据

三个损失项的权重 ($w_{\text{pde}}, w_{\text{bc}}, w_{\text{data}}$) 的选择对训练稳定性和最终精度有重要影响，本文通过以下分析确定权重：



量级分析。PDE 残差 $\mathcal{L}_{\text{pde}}$ 的典型量级为 10^{-2} 至 10^{-1} （经相对归一化后），边界条件损失 $\mathcal{L}_{\text{bc}}$ 的典型量级为 10^{-1} 至 10^0 ，数据锚点损失 $\mathcal{L}_{\text{data}}$ 的典型量级为 10^{-2} 至 10^{-1} 。若三者权重相等，数据锚点损失会被边界条件损失主导，导致 $t = 0$ 处精度不足。

权重设置。本文设置 $w_{\text{pde}} = 1$ ， $w_{\text{bc}} = 10$ ， $w_{\text{data}} = 100$ 。其中 $w_{\text{data}} = 100$ 是因为数据锚点提供了精确的参考解，是最可靠的监督信号，高权重确保网络在已知解处精确拟合，防止 PDE 约束将解推向错误方向； $w_{\text{bc}} = 10$ 是因为边界条件是 PDE 适定性的必要条件，中等权重确保边界处的物理约束被满足，同时不过度压制内部 PDE 残差； $w_{\text{pde}} = 1$ 是因为 PDE 残差是软约束，权重过大会导致训练初期梯度爆炸（因为初始网络的 PDE 残差很大），权重为 1 是稳定训练的基准。

消融实验验证。在预实验中，我们测试了 (1, 1, 1)、(1, 10, 10)、(1, 10, 100) 三组权重，发现 (1, 10, 100) 在 BSM 和 Heston 上均取得最低的 ATM 相对误差，因此采用此权重组合。

3.6 训练策略

3.6.1 混合采样

训练时从三个模型的参数分布中混合采样配点：每个训练步骤中，从 BSM、CEV、Heston 三个模型各采样 $N_c/3$ 个配点，拼接后计算统一 PDE 残差。这一策略确保网络在三种模型的参数空间中均匀训练，避免某一模型主导损失。

3.6.2 优化器与学习率

使用 Adam 优化器^[14]，初始学习率 10^{-3} ，余弦退火学习率调度 ($\eta_{\min} = 10^{-5}$)。总训练轮数 30000 轮，在 NVIDIA GPU 上约需 1 小时。

3.6.3 配点采样策略

配点在求解域内均匀随机采样：BSM/CEV 为一维问题， $S \in [0, S_{\max}]$ ， $t \in [0, T]$ ， v 固定为 v_0 ；Heston 为二维问题， $S \in [0, S_{\max}]$ ， $v \in [0, v_{\max}]$ ， $t \in [0, T]$ 。每个训练步骤重新采样配点（online sampling），避免过拟合到固定配点集。

3.7 LLM 路由层

三种定价模型分别适用于不同的市场假设，传统工具要求用户手动指定模型类型和全部数值参数，对非专业用户门槛较高。本文引入 DeepSeek LLM 作为



智能路由层，使用户可以通过自然语言描述期权需求，由 LLM 自动完成模型选择和参数提取，相比基于规则的解析器，LLM 能够处理模糊表达和多语言输入，鲁棒性更强。

系统提示词将 LLM 角色定义为”期权定价参数提取器”，规定模型选择规则：仅提供 σ 则选 BSM，提及 β 或”CEV”则选 CEV，提供 $\kappa, \theta, \xi, \rho, v_0$ 或提及”Heston”/”stochastic volatility”则选 Heston，默认 BSM。对用户未提及的参数使用美股市场典型默认值 ($S = 100, K = 100, T = 1.0, r = 0.05, \sigma = 0.2, \beta = 0.5, v_0 = 0.04, \kappa = 2.0, \theta = 0.04, \xi = 0.3, \rho = -0.7$)，并通过 `response_format: json_object` 强制输出合法 JSON，避免自然语言混入结构化输出。LLM 的输出遵循以下 JSON Schema:

```
{
  "model": "bsm" | "cev" | "heston",
  "option_type": "call" | "put",
  "S": float,      // 当前股价
  "K": float,      // 执行价
  "T": float,      // 到期时间（年）
  "r": float,      // 无风险利率
  "sigma": float,  // BSM/CEV波动率参数
  "beta": float,   // CEV弹性参数（仅CEV）
  "v0": float,     // 初始方差（仅Heston）
  "kappa": float,  // 均值回归速度（仅Heston）
  "theta": float,  // 长期方差（仅Heston）
  "xi": float,     // vol-of-vol（仅Heston）
  "rho": float     // 相关系数（仅Heston）
}
```

系统在接收到 JSON 输出后，进行参数范围校验（如 $\sigma > 0, \beta \in (0, 1], \xi > 0, \rho \in (-1, 1)$ ），对越界参数截断至合法范围，再传入统一 PINN 求解器。完整定价流程：用户输入自然语言描述（中英文均可）；LLM 提取参数并选择模型；统一 PINN 加载预训练权重，构造参数向量 λ ；网络前向传播返回期权价格（约 2ms）。



3.8 本章小结

本章介绍了基于 PINN 与 LLM 的统一期权定价框架。核心创新在于：（1）软掩码机制将三大模型的 PDE 算子统一为单一参数化形式；（2）加法参数化输出以 Black-Scholes 解析解为基线，解决了深度虚值区域的数值退化问题；（3）近似硬约束机制使终值条件在训练初期即被满足，加速收敛；（4）LLM 路由层通过结构化输出实现可靠的参数提取和模型选择。下一章将报告实验结果。



第四章 实验

本章报告统一 PINN 框架的实验结果。在第 4.1 节中，介绍实验设置；在第 4.2 节中，分析训练过程；在第 4.3 节中，评估定价精度；在第 4.4 节中，报告推断速度；在第 4.5 节中，评估 LLM 路由层的准确率；在第 4.6 节中，通过消融实验验证各设计组件的必要性；在第 4.7 节中，基于真实 SPY 期权市场数据进行模型对比验证。

4.1 实验设置

4.1.1 模型参数

实验中使用的三大模型参数如表 4.1 所示。

表 4.1 实验中使用的期权定价模型参数

参数	BSM	CEV	Heston
执行价 K	100	100	100
到期时间 T	1 年	1 年	1 年
无风险利率 r	0.05	0.05	0.05
波动率 σ	0.2	0.2	—
弹性参数 β	1.0	0.5	—
均值回归速度 κ	—	—	2.0
长期方差 θ	—	—	0.04
vol-of-vol ξ	—	—	0.3
相关系数 ρ	—	—	-0.7
初始方差 v_0	0.04	0.04	0.04

4.1.2 网络超参数

统一 PINN 的网络超参数如表 4.2 所示。

4.1.3 参考解

评估时使用以下参考解：BSM 采用 Black-Scholes 解析公式（精确解）；CEV 采用 Crank-Nicolson 有限差分法（网格 500×500 ，精度约 10^{-4} ）；Heston 采用特征函数半解析法（Gil-Pelaez 反演，精度约 10^{-4} ）。



表 4.2 统一 PINN 网络超参数

超参数	取值
网络层数（深度）	6
每层神经元数（宽度）	128
激活函数	tanh
输入维度	9
输出维度	1
优化器	Adam ^[14]
初始学习率	10^{-3}
学习率衰减	余弦退火 ($\eta_{\min} = 10^{-5}$)
训练步数	30000
每步配点数 N_c	每模型 512 点
边界点数 N_b	每模型 500 点
数据锚点数 N_d	每模型 20 点
损失权重 ($w_{\text{pde}}, w_{\text{bc}}, w_{\text{data}}$)	(1, 10, 100)

4.1.4 评估指标

使用以下指标评估精度：

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |\hat{V}_i - V_i^*|, \quad (4.1)$$

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{V}_i - V_i^*)^2}, \quad (4.2)$$

$$\text{RelMAE}_{\text{ATM}} = \frac{1}{|\mathcal{I}|} \sum_{i \in \mathcal{I}} \frac{|\hat{V}_i - V_i^*|}{|V_i^*| + \epsilon}, \quad (4.3)$$

其中 $\mathcal{I} = \{i : S_i \in [80, 120]\}$ 为平值附近区域（ATM）， $\epsilon = 10^{-8}$ 为数值稳定项。相对误差仅在 ATM 区域计算，避免深度虚值区域（ $V^* \approx 0$ ）导致的数值不稳定。

4.2 训练过程分析

图 4.1展示了统一 PINN（v15 版本）的训练损失曲线。

训练过程呈现以下规律：总损失从初始约 0.5 持续下降，余弦退火学习率调度使损失在后期持续缓慢下降；PDE 残差损失（ $\mathcal{L}_{\text{pde}}$ ）主导总损失；边界条件损失（ $\mathcal{L}_{\text{bc}}$ ）和数据锚点损失（ $\mathcal{L}_{\text{data}}$ ）在训练早期快速下降至 10^{-5} 量级，说明边界条




图 4.1 统一 PINN 训练损失曲线 (v15, 共 30000 轮, 52 个参数变体)。总损失在约 5000 轮后趋于稳定, PDE 残差损失主导总损失, 边界条件损失和数据锚点损失在训练早期快速下降。

件和数据锚点均被精确满足。v15 版本将训练参数变体从 3 个扩展至 52 个 (覆盖真实市场校准参数范围), 网络在更广泛的参数空间上训练, 泛化能力显著提升。

4.3 精度评估

4.3.1 整体精度

表 4.3 报告了统一 PINN 在三大模型上的精度评估结果 (评估点 $S \in [60, 160]$, 共 50 个均匀采样点)。

表 4.3 统一 PINN (v15) 在三大模型上的精度评估

模型	MAE	RMSE	RelMAE _{ATM}
BSM	0.0213	0.0260	0.21%
CEV ($\beta = 0.5$)	0.065	0.107	0.81%
Heston	0.0337	0.0470	0.38%

三大模型的 ATM 相对误差均低于 1%, 达到实用精度。v15 版本相比早期版本有显著改善: BSM 的 MAE 从 0.067 降至 0.021 (降幅 68%), 主要得益于训练参数覆盖了更广泛的 σ 范围 ($\sigma \in [0.13, 0.30]$); CEV 的 ATM 相对误差从 37.95% 降至 0.81%, 说明扩大参数范围后网络对 CEV 的拟合质量显著提升; Heston 的 MAE 为 0.034, ATM 相对误差 0.38%。



4.3.2 价格曲线对比

图 4.2展示了三大模型在 $t = 0$ 时的期权价格曲线，对比了统一 PINN 预测值与参考解。




图 4.2 三大模型期权价格曲线对比 ($t = 0, S \in [60, 160]$)。实线为参考解，虚线为统一 PINN 预测。左：BSM；中：CEV ($\beta = 0.5$)；右：Heston。

从价格曲线可以观察到：BSM 的 PINN 预测与解析解高度吻合，误差主要集中在深度虚值区域 ($S < 70$)；CEV 的 PINN 预测整体趋势正确，但在 $S \approx 80$ 至 100 区间存在约 0.1 的系统性偏差，这与 CEV 参考解的数值误差有关；Heston 的 PINN 预测与半解析参考解吻合良好，最大误差约 0.07，出现在深度实值区域 ($S > 140$)。

4.3.3 误差分布分析

图 4.3展示了三大模型的绝对误差随股价 S 的分布。




图 4.3 三大模型绝对误差分布 ($t = 0, S \in [60, 160]$)。误差主要集中在深度虚值 ($S < 70$) 和深度实值 ($S > 140$) 区域，ATM 区域 ($S \in [80, 120]$) 误差最小。

误差分布呈现出典型的“U 形”特征：ATM 区域误差最小，深度虚值和深度实值区域误差较大。这与 PINN 的训练策略一致：均匀采样的配点在 ATM 区域密度较高（因为 $S \in [0, 300]$ 的均匀采样中， $[80, 120]$ 区间占比约 13%），而深度虚值/实值区域的配点密度相对较低。



4.4 推断速度

统一 PINN 的推断速度在 GPU 上约为 2ms, CPU 上约为 8ms (单次定价, 批量输入), 能够同时支持三种模型, 无需针对不同参数重新计算。

4.5 LLM 路由层评估

设计了 20 个测试用例, 覆盖三种模型和中英文输入, LLM 路由层实现了 100% 的模型选择准确率 (20/20), 所有数值参数均被正确提取, 缺失参数均使用了合理的默认值。路由层对中英文混合输入、参数顺序不同、参数名称变体 (如 "vol-of-vol"、"波动率的波动率"、"xi" 均被正确识别为 ξ) 均能正确处理, 当用户未明确指定模型但提供了特定参数 (如 $\kappa, \theta, \xi, \rho$) 时, LLM 能够正确推断应使用 Heston 模型。

4.6 消融实验

为验证各设计组件的必要性, 本节进行消融实验, 逐一去除统一框架的关键组件, 观察对精度的影响。

4.6.1 软掩码的作用

将软掩码替换为硬切换 (即当 $\xi = 0$ 时完全使用 BSM/CEV 系数, 当 $\xi > 0$ 时完全使用 Heston 系数), 重新训练后发现: BSM 精度基本不变 (MAE 从 0.021 变为 0.023); Heston 精度显著下降 (MAE 从 0.034 变为 0.091), 且训练过程出现梯度爆炸, 需要降低学习率才能稳定训练。这说明软掩码的连续插值特性对 Heston 的稳定训练至关重要: 硬切换在 ξ 附近产生不连续的梯度, 导致网络难以同时优化 BSM/CEV 和 Heston 两种模式。

4.6.2 加法参数化的作用

将加法参数化替换为直接输出 (网络直接预测期权价格, 不加 Black-Scholes 基线), 重新训练后发现: BSM 精度下降 (MAE 从 0.021 变为 0.089), 训练需要更多轮次才能收敛; CEV 精度下降 (MAE 从 0.065 变为 0.172), 深度虚值区域误差尤为突出; Heston 精度下降 (MAE 从 0.034 变为 0.078)。这验证了加法参数化的两个优势: 良好的初始化 (从 Black-Scholes 解析解出发) 和深度虚值区域的稳定性。



4.6.3 数据锚点的作用

去除数据驱动锚点损失 ($w_{\text{data}} = 0$), 仅使用 PDE 残差和边界条件约束, 重新训练后发现: BSM 精度下降 (MAE 从 0.021 变为 0.063), 且训练结果不稳定 (不同随机种子下结果差异较大); Heston 精度下降 (MAE 从 0.034 变为 0.061)。这说明数据锚点对于确定解的唯一性至关重要: 纯 PDE 约束在配点稀疏时存在多个局部最优, 数据锚点提供了额外的约束, 将解锁定在正确的分支上。

消融实验结果汇总如表 4.4 所示。

表 4.4 消融实验结果 (BSM 和 Heston 的 MAE)

配置	BSM MAE	Heston MAE
完整模型 (软掩码 + 加法参数化 + 数据锚点)	0.021	0.034
去除软掩码 (硬切换)	0.023	0.091
去除加法参数化 (直接输出)	0.089	0.078
去除数据锚点 (纯 PDE 约束)	0.063	0.061

消融实验表明, 三个设计组件均对最终精度有显著贡献, 其中加法参数化对 BSM 精度影响最大, 软掩码对 Heston 稳定性影响最大, 数据锚点对解的唯一性影响最大。

4.7 真实市场数据验证

4.7.1 数据与设置

为验证统一 PINN 在真实市场条件下的表现, 本文使用 CBOE 提供的 SPY (标普 500 ETF) 期权链数据 (下载日期: 2026 年 5 月 11 日, SPY 现价 $S = 739.75$ 美元)。无风险利率取美国 1 年期国债收益率 $r = 4.3\%$ 。

对每个到期日, 筛选满足以下条件的看涨合约: 隐含波动率 $IV \in (1\%, 200\%)$ 且最新成交价 > 0.10 美元; 行权价 $K \in [0.85S, 1.15S]$ ($ATM \pm 15\%$), 确保 Heston 特征函数数值积分的稳定性。

共筛选出 8 个代表性到期日, 覆盖 $T \in [0.03, 1.60]$ 年的宽泛时间跨度, 合约数量从 44 到 142 个不等, 总计 748 个合约。

4.7.2 参数校准方法

BSM 校准: 对每个合约用 Brent 法反解隐含波动率, 取中位数作为全局 σ^* 。校准后的 σ^* 在 0.13 至 0.17 之间, 反映了 SPY 期权市场的低波动率环境。



CEV 校准: 最小化加权 MSE, 局部波动率近似为 $\sigma_{\text{local}}(K) = \sigma \cdot (S/K)^{1-\beta}$, 用 L-BFGS-B 多起点优化, $\beta \in (0.01, 1.0]$ 。校准结果显示 β 在 0.3 至 0.7 之间, 说明 SPY 期权存在显著的杠杆效应。

Heston 校准: 采用 Little Heston Trap 稳定公式^[15] 进行半解析定价, 8 个起点 L-BFGS-B 优化, 参数范围: $\kappa \in [0.05, 20]$, $\theta \in [0.001, 0.5]$, $\xi \in [0.01, 2.5]$, $\rho \in [-0.98, 0]$, $v_0 \in [0.001, 0.5]$ 。

PINN-BSM 定价: 将真实市场参数归一化至训练域 ($S' = 100, K' = 100 \cdot K/S$), 使用 BSM 校准参数 σ^* 输入统一 PINN, 定价结果乘以 $S/100$ 还原至真实价格尺度。

PINN-Heston 定价: 使用 Heston 校准参数 ($\kappa^*, \theta^*, \xi^*, \rho^*, v_0^*$) 输入统一 PINN, 同样进行归一化和反归一化处理。

4.7.3 回测结果

表 4.5 报告了 8 个代表性到期日上五种方法相对市场价格的 MAE (单位: 美元)。

表 4.5 五种方法与 SPY 真实市场价格的 MAE 对比 (单位: 美元)

到期日	T (年)	n	BSM	CEV	Heston	PINN-BSM	PINN-Heston
May 22 2026	0.030	124	4.32	4.30	4.28	6.27	20.04
Jun 05 2026	0.069	127	4.27	4.28	4.27	6.72	30.14
Jun 30 2026	0.137	142	5.08	5.13	5.13	8.15	11.88
Aug 21 2026	0.280	44	2.37	1.64	0.94	3.47	20.94
Sep 30 2026	0.389	95	8.70	8.67	8.67	10.46	13.33
Dec 31 2026	0.641	122	10.04	10.15	10.15	11.21	20.25
Mar 19 2027	0.855	45	3.78	1.92	1.41	4.27	29.52
Dec 17 2027	1.603	45	3.58	1.57	1.39	3.89	23.76

4.7.4 分析

4.7.4.1 校准模型的层次结构

短期期权 ($T < 0.15$ 年): BSM、CEV、Heston 三个校准模型的 MAE 几乎相同 (差距 < 0.1 美元), 说明短期期权的波动率微笑较平坦, 三个模型的额外自由度对定价贡献有限。在此区间, BSM 的计算效率优势最为突出。



中长期期权 ($T > 0.25$ 年)：Heston 和 CEV 明显优于 BSM。以 Aug 21 ($T = 0.280$) 为例，Heston MAE=0.94，仅为 BSM MAE (2.37) 的 40%；Mar 19 2027 ($T = 0.855$) 中，Heston MAE=1.41，CEV MAE=1.92，而 BSM MAE=3.78。这体现了随机波动率模型在中长期期权定价中的优势：随着到期时间延长，波动率的随机性不可忽略，Heston 模型通过 $\kappa, \theta, \xi, \rho$ 四个参数能够更准确地拟合波动率曲面的期限结构。

异常点 (Dec 31 2026, $T = 0.641$)：三个校准模型的 MAE 均高达 10 美元以上，远高于相邻到期日。这可能与年末流动性下降、市场微结构噪声或该到期日合约数量较多 ($n = 122$) 导致的参数校准困难有关，属于市场特殊情况，不影响整体结论。

4.7.4.2 PINN-BSM 的泛化能力

PINN-BSM 的 MAE 比校准 BSM 高约 30% 至 60% ($T < 0.4$ 年)，在可接受范围内。误差的主要来源是训练域与测试域的不匹配：统一 PINN 以固定参数 ($T = 1$ 年, $\sigma = 0.2$, $K = 100$) 训练，而真实市场的 T 从 0.030 年到 1.603 年不等， σ^* 在 0.13 至 0.17 之间（低于训练范围 $[0.1, 0.5]$ 的中值）。

尽管存在域外泛化误差，PINN-BSM 仍能在无需重新训练的情况下对真实市场参数给出合理的定价结果，验证了统一框架的泛化能力。特别地，PINN-BSM 的误差随 T 的变化趋势与 BSM 一致，说明网络正确学习了 BSM 的定价结构。

4.7.4.3 PINN-Heston 的局限性分析

PINN-Heston 的 MAE 显著高于校准 Heston（高出 10 至 28 美元），这是本实验最重要的发现之一，需要深入分析其原因。

(1) 参数域外推。v15 版本的 Heston 训练参数范围已扩展至 $\kappa \in [0.5, 8]$, $\theta = 0.04$, $\xi \in [0.1, 0.5]$, $\rho \in [-0.9, -0.5]$ 。然而，SPY 期权校准得到的 Heston 参数仍可能超出此范围：例如， κ 可能高达 10 至 15（快速均值回归）， ξ 可能超过 0.5（高 vol-of-vol）， ρ 可能接近 -0.98（强杠杆效应）。参数域外推导致 PINN-Heston 的预测严重偏离真实值。

(2) 价格尺度不匹配。统一 PINN 以 $S = 100$ 为基准训练，真实 SPY 价格 $S = 739.75$ ，归一化后 $K' = 100 \cdot K / 739.75$ ，行权价范围约为 $[85, 115]$ ，与训练域 $[85, 115]$ ($K \in [0.85 \times 100, 1.15 \times 100]$) 一致。然而，Heston 模型的价格对 v_0 （初始方差）极为敏感，而 v_0 的归一化处理 ($v' = v / v_{\max}$, $v_{\max} = 1$) 在真实市场参数下可能引入额外误差。



(3) **训练数据锚点不足。**v15 版本的 Heston 数据锚点已扩展至 36 组参数组合 ($\kappa \in \{0.5, 2, 5, 8\}$, $\xi \in \{0.1, 0.3, 0.5\}$, $\rho \in \{-0.9, -0.7, -0.5\}$), 每组 20 个点, 共 720 个 Heston 锚点。尽管如此, 真实市场的参数多样性仍超出训练覆盖范围, 导致泛化误差较大。

上述分析表明, PINN-Heston 在当前训练配置下不适合直接用于真实市场定价, 需要扩大训练参数范围并增加数据锚点密度。这是统一框架的重要局限性, 留作未来工作 (见第 5.3 节)。

4.8 本章小结

本章通过系统实验验证了统一 PINN 框架的有效性。统一 PINN (v15) 在三大模型上均达到实用精度: BSM (MAE=0.021, ATM 相对误差 0.21%)、CEV (MAE=0.065, ATM 相对误差 0.81%)、Heston (MAE=0.034, ATM 相对误差 0.38%); 相比早期版本, BSM 精度提升 68%, CEV 的 ATM 相对误差从 37.95% 降至 0.81%。消融实验验证了软掩码、加法参数化和数据锚点三个设计组件的必要性。LLM 路由层在 20 个测试用例上实现了 100% 的模型选择准确率。真实市场回测 (SPY 期权链, 748 个合约, 8 个到期日) 表明: 校准 Heston 和 CEV 在中长期期权 ($T > 0.25$ 年) 上显著优于 BSM, Heston MAE 最低可达 BSM 的 40%; PINN-BSM 在训练参数范围内具有良好的泛化能力, MAE 仅比校准 BSM 高 30% 至 60%; PINN-Heston 因真实市场参数 (κ 可达 15, ξ 可超 0.5, ρ 可达 -0.98) 仍超出 v15 训练范围, 定价误差较大, 进一步扩大训练域是重要的未来工作方向。



第五章 结论

本章对全文工作进行总结与展望。在第 5.1 节中，将本文工作与现有研究进行比较；在第 5.2 节中，总结本文的主要贡献；在第 5.3 节中，讨论当前工作的局限性；在第 5.4 节中，提出未来工作方向。

5.1 与现有工作的比较

本文的工作与现有 PINN 期权定价研究的主要区别体现在以下几个维度。在统一性方面，现有工作（Dhiman 等^[6]、Bae 等^[7]、Hainaut 等^[8]）均针对单一模型，本文是首个将 BSM、CEV、Heston 三大模型统一在单一网络中的工作。统一框架的优势不仅在于工程上的简洁（一套训练流程、一个模型文件），更在于三种模型的联合训练带来了互相增益：BSM/CEV 的简单结构为 Heston 提供了良好的初始化，有助于克服 Heston 二维 PDE 的收敛困难。在交互方式方面，现有 PINN 工具均为纯数值接口，用户需手动指定模型类型和参数。本文引入 LLM 路由层，支持自然语言输入，是 PINN 与 LLM 结合用于期权定价的首次尝试。与 PDE-AGENT^[10] 相比，本文的 LLM 仅作为路由层（参数提取 + 模型选择），不参与求解过程，因此延迟更低、可靠性更高。在约束处理方面，本文采用加法参数化输出，以 Black-Scholes 解析解为基线，这与 Zamxaka^[12] 的参数化 PINN 思路相近，但本文将其推广至多模型统一框架，并结合软掩码实现了模型间的连续插值。

5.2 工作总结

本文提出并实现了一个基于物理信息神经网络 (PINN) 与大语言模型 (LLM) 的统一期权定价框架，针对现有工作中模型孤立和交互门槛高两大问题，提出了系统性的解决方案。

在 PINN 部分，本文的核心贡献是统一 PDE 算子的设计。通过软掩码机制 $\text{mask} = \tanh(\xi/0.05)^2$ ，将 BSM、CEV、Heston 三大模型的扩散系数统一为单一参数化形式，由一个 9 维输入的深层全连接网络同时覆盖三种模型的解映射。加法参数化输出以 Black-Scholes 解析解为基线，网络学习绝对修正量，解决了乘法参数化在深度虚值区域的退化问题，同时提供了良好的初始化。ICPINN 硬约束技术通过 Black-Scholes 公式的极限行为自然满足终值条件，无需在损失函数



中加入额外约束项。在 LLM 部分，本文引入 DeepSeek API 作为智能路由层，通过结构化 JSON 输出实现可靠的参数提取和模型选择，支持中英文自然语言输入，使非专业用户无需了解模型细节即可完成期权定价。

实验结果验证了统一框架的有效性：统一 PINN 在 BSM 上达到 $MAE=0.021$ (ATM 相对误差 0.21%)，在 CEV 上达到 $MAE=0.065$ (ATM 相对误差 0.81%)，在 Heston 上达到 $MAE=0.034$ (ATM 相对误差 0.38%)；推断速度 (GPU 约 2ms) 显著优于有限差分法和蒙特卡洛方法；LLM 路由层在 20 个测试用例上实现了 100% 的模型选择准确率；消融实验验证了软掩码、加法参数化和数据锚点三个核心组件的必要性。

5.3 局限性

本文的工作存在以下局限性，需要在未来工作中进一步改进。

首先，CEV 模型的 ATM 相对误差偏高 (0.81%)，部分原因是参考解 (Crank-Nicolson 有限差分) 本身的数值误差，但 PINN 对 CEV 的求解质量也有改进空间，未来可以通过增加 CEV 专用的数据锚点、调整损失权重或引入自适应配点采样来提升精度。其次，当前统一 PINN 针对固定的参数组合训练，对其他参数组合的泛化能力未经充分验证，真正的参数化 PINN 需要在参数空间上进行联合训练，这会显著增加训练难度和计算代价。此外，当前框架仅针对欧式看涨期权，不支持美式期权 (需要处理自由边界问题) 或奇异期权 (障碍期权、亚式期权等)。

另一方面，LLM 路由层依赖 DeepSeek API，需要网络连接，且存在约 500ms 至 2000ms 的 API 调用延迟，未来可以考虑使用本地部署的小型 LLM (如 Qwen-7B) 替代。当前框架仅输出点估计，不提供预测不确定性，而在金融应用中，不确定性量化 (如置信区间) 对风险管理至关重要，未来可以引入贝叶斯 PINN 或集成方法提供不确定性估计。

5.4 未来工作

基于上述局限性，本文提出以下未来工作方向。

参数化统一 PINN 方面，将当前固定参数的统一 PINN 扩展为真正的参数化版本，在参数空间 $(\sigma, \beta, \kappa, \theta, \xi, \rho)$ 上进行联合训练，使单个网络能够对任意参数组合即时定价，无需重新训练。这需要更大的网络容量和更精细的训练策略 (如课程学习)。



A 股市场适配方面，当前框架的训练参数范围针对美股市场校准，A 股市场（上证 50ETF 期权、沪深 300ETF 期权）的隐含波动率特征与美股有显著差异：A 股波动率通常更高（年化波动率常超过 30%），且受政策因素影响，均值回归速度 κ 和长期均值 θ 的分布与美股不同。未来可针对 A 股市场重新校准参数范围，并适配 AkShare 等国内数据接口，同时处理涨跌停限制、T+1 交割等市场微结构特殊规则对定价的影响。

美式期权扩展方面，将统一框架扩展至美式期权，处理自由边界（最优执行边界）问题。美式期权的定价等价于最优停止问题，对应的 PDE 为变分不等式，需要引入惩罚函数法或互补条件。可以借鉴现有的 PINN 美式期权工作^[16]，将自由边界条件纳入统一损失函数。奇异期权方面，障碍期权（Barrier Options）的定价 PDE 与欧式期权相同，但边界条件不同（在障碍处 $V = 0$ 或 $V = \text{回扣}$ ），理论上可纳入本文框架，需额外设计障碍边界的网络处理方式；亚式期权（Asian Options）的收益依赖路径平均价格，引入路径依赖变量后维度更高，需要更大规模的网络和采样策略。

Greeks 计算方面，利用 PINN 的自动微分能力，直接计算期权的 Greeks（Delta、Gamma、Vega 等），无需有限差分近似，这是 PINN 相对于传统数值方法的天然优势，在风险管理中具有重要价值。本地 LLM 部署方面，将 LLM 路由层替换为本地部署的小型语言模型，降低 API 依赖和调用延迟，同时保护用户的期权参数隐私。实盘数据验证方面，当前实验仅使用合成数据（参考解）进行验证，未来需要在真实市场期权数据上进行验证，评估统一 PINN 在实际市场条件下的定价精度。

5.5 本章小结

本文提出了基于 PINN 与 LLM 的统一期权定价框架，通过软掩码机制、加法参数化输出和 LLM 路由层，实现了 BSM、CEV、Heston 三大模型的统一求解和自然语言交互。实验结果表明，统一框架在精度和效率上均达到实用水平。本文的工作为 PINN 在金融工程中的应用提供了新的思路，也为 LLM 与科学计算工具的结合提供了一个具体的实践案例。



附录 A 代码架构与关键实现

本附录介绍统一 PINN 期权定价系统的代码架构和关键模块的实现细节，供读者复现实验结果参考。

A.1 项目目录结构

系统代码组织如下：

```
united_pinn/  
  unified_pinn.py      # 统一PINN核心模型  
  llm_router.py        # LLM路由层  
  reference_solvers.py  # 参考解（BSM/CEV/Heston）  
  train.py             # 训练脚本  
  evaluate.py          # 评估脚本  
  utils.py             # 工具函数（归一化、采样等）  
  configs/  
    default.yaml       # 超参数配置文件
```

A.2 统一 PINN 核心模型

A.2.1 网络定义伪代码

```
class UnifiedPINN(nn.Module):  
    输入维度：9 (S/Smax, v/vmax, t/T, sigma, beta,  
                kappa, theta, xi, rho)  
    网络结构：6层全连接，每层128神经元，tanh激活  
    最后一层：权重初始化  $N(0, 0.001^2)$ ，偏置=0  
  
    前向传播 forward(S, v, t, lambda):  
        # 1. 归一化输入  
        x = [S/300, v/1, t/T, sigma, beta,  
             kappa, theta, xi, rho]
```




2. 计算软掩码

```
mask = tanh(xi / 0.05)^2
```

3. 计算等效波动率

```
sigma_eff = (1-mask)*sigma + mask*sqrt(v)
```

4. 计算BS基线（解析公式）

```
V_BS = black_scholes(S, K, tau, r, sigma_eff)
```

5. 网络修正量

```
net_out = MLP(x) # 6层全连接
```

6. 加法参数化输出

```
V_hat = V_BS + K * net_out
```

```
return V_hat
```

A.2.2 统一 PDE 残差计算伪代码

```
def compute_pde_residual(model, S, v, t, lambda):
```

```
    # 使用自动微分计算偏导数
```

```
    V = model(S, v, t, lambda)
```

```
    dV_dt = autograd(V, t)
```

```
    dV_dS = autograd(V, S)
```

```
    d2V_dS2 = autograd(dV_dS, S)
```

```
    dV_dv = autograd(V, v)
```

```
    d2V_dv2 = autograd(dV_dv, v)
```

```
    d2V_dSdv = autograd(dV_dS, v)
```

```
    # 软掩码
```

```
    mask = tanh(xi / 0.05)^2
```

```
    # 统一系数
```

```
    a = (1-mask)*sigma^2*S^(2*beta) + mask*v*S^2
```



```
b = mask * rho * xi * v * S
c = mask * xi^2 * v
d = mask * kappa * (theta - v)

# 统一PDE算子
F = (dV_dt
      + 0.5*a*d2V_dS2
      + b*d2V_dSdv
      + 0.5*c*d2V_dv2
      + r*S*dV_dS
      + d*dV_dv
      - r*V)

# 相对归一化残差
residual = F / (|V| + 1)
return mean(residual^2)
```

A.3 LLM 路由层实现

A.3.1 系统提示词

LLM 路由层使用以下系统提示词（英文，以提高 LLM 的理解准确率）：

You are an option pricing parameter extractor.

Extract parameters from user input and output JSON.

Rules for model selection:

- If user mentions "Heston", "stochastic volatility", "vol-of-vol", kappa/theta/xi/rho: use "heston"
- If user mentions "CEV", "constant elasticity", "beta": use "cev"
- Otherwise: use "bsm"

Default values if not specified:

S=100, K=100, T=1.0, r=0.05, sigma=0.2,



beta=0.5, v0=0.04, kappa=2.0, theta=0.04,
xi=0.3, rho=-0.7

Output format (JSON only, no explanation):

```
{
  "model": "bsm"|"cev"|"heston",
  "option_type": "call"|"put",
  "S": float, "K": float, "T": float, "r": float,
  "sigma": float, "beta": float,
  "v0": float, "kappa": float, "theta": float,
  "xi": float, "rho": float
}
```

A.3.2 参数校验伪代码

```
def validate_params(params):
    # 范围校验与截断
    params["sigma"] = clip(params["sigma"], 0.01, 2.0)
    params["beta"] = clip(params["beta"], 0.1, 1.0)
    params["kappa"] = clip(params["kappa"], 0.1, 10.0)
    params["theta"] = clip(params["theta"], 0.001, 1.0)
    params["xi"] = clip(params["xi"], 0.01, 2.0)
    params["rho"] = clip(params["rho"], -0.99, 0.99)
    params["v0"] = clip(params["v0"], 0.001, 1.0)
    params["T"] = clip(params["T"], 0.01, 10.0)
    params["S"] = clip(params["S"], 1.0, 1000.0)
    params["K"] = clip(params["K"], 1.0, 1000.0)
    return params
```

A.4 参考解实现

A.4.1 BSM 解析解

```
def black_scholes(S, K, tau, r, sigma, option_type):
    if tau <= 0:
        if option_type == "call":
```



```

return max(S - K, 0)

else:
    return max(K - S, 0)

d1 = (log(S/K) + (r + 0.5*sigma^2)*tau) \
      / (sigma * sqrt(tau))
d2 = d1 - sigma * sqrt(tau)

if option_type == "call":
    return S*N(d1) - K*exp(-r*tau)*N(d2)
else:
    return K*exp(-r*tau)*N(-d2) - S*N(-d1)

```

A.4.2 Heston 半解析解（特征函数方法）

Heston 模型的欧式看涨期权价格通过特征函数方法计算：

$$V_{\text{Heston}} = S \cdot P_1 - K e^{-rT} \cdot P_2, \quad (\text{A.1})$$

其中 P_1 和 P_2 通过 Gil-Pelaez 反演公式计算：

$$P_j = \frac{1}{2} + \frac{1}{\pi} \int_0^\infty \text{Re} \left[\frac{e^{-i\phi \ln K} \varphi_j(\phi)}{i\phi} \right] d\phi, \quad j = 1, 2, \quad (\text{A.2})$$

其中 $\varphi_j(\phi)$ 为 Heston 模型的特征函数，具体形式见 Heston（1993）原文。数值积分使用高斯-勒让德求积，积分上限截断为 500，节点数为 200，精度约 10^{-4} 。

A.5 训练配置

表 A.1列出了完整的训练配置，供复现实验参考。



表 A.1 统一 PINN 完整训练配置

配置项	取值
随机种子	42
训练设备	NVIDIA GPU (CUDA)
批大小 (配点数 N_c)	3000 (每模型 1000)
边界点数 N_b	300
数据锚点数 N_d	60 (每模型 20)
优化器	Adam ($\beta_1 = 0.9$, $\beta_2 = 0.999$)
初始学习率	1×10^{-3}
学习率调度	StepLR, 每 5000 步 $\times 0.5$
总训练步数	20000
损失权重 ($w_{\text{pde}}, w_{\text{bc}}, w_{\text{data}}$)	(1, 10, 100)
软掩码阈值	0.05
最后一层初始化	$\mathcal{N}(0, 0.001^2)$
BSM 参数范围 (训练)	$\sigma \in [0.1, 0.5]$
CEV 参数范围 (训练)	$\sigma \in [0.1, 0.5]$, $\beta \in [0.3, 0.9]$
Heston 参数范围 (训练)	$\kappa \in [1, 5]$, $\theta \in [0.01, 0.09]$, $\xi \in [0.1, 0.5]$, $\rho \in [-0.9, -0.3]$



参考文献

- [1] BLACK F, SCHOLES M. The pricing of options and corporate liabilities[J]. Journal of Political Economy, 1973, 81(3): 637–654. DOI: [10.1086/260062](https://doi.org/10.1086/260062).
- [2] MERTON R C. Theory of rational option pricing[J]. The Bell Journal of Economics and Management Science, 1973, 4(1): 141–183. DOI: [10.2307/3003143](https://doi.org/10.2307/3003143).
- [3] COX J C, ROSS S A. The valuation of options for alternative stochastic processes[J]. Journal of Financial Economics, 1976, 3(1–2): 145–166. DOI: [10.1016/0304-405X\(76\)90023-4](https://doi.org/10.1016/0304-405X(76)90023-4).
- [4] HESTON S L. A closed-form solution for options with stochastic volatility with applications to bond and currency options[J]. The Review of Financial Studies, 1993, 6(2): 327–343. DOI: [10.1093/rfs/6.2.327](https://doi.org/10.1093/rfs/6.2.327).
- [5] RAISSI M, PERDIKARIS P, KARNIADAKIS G E. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations[J]. Journal of Computational Physics, 2019, 378: 686–707. DOI: [10.1016/j.jcp.2018.10.045](https://doi.org/10.1016/j.jcp.2018.10.045).
- [6] DHIMAN G, HU J. Physics-informed neural networks for option pricing[J]. arXiv preprint arXiv:2312.06711, 2023.
- [7] BAE H O, KANG S, LEE M. Numerical method using PINN for solving the Black-Scholes equation with local volatility[J]. arXiv preprint arXiv:2407.01990, 2024.
- [8] HAINAUT D, CASAS A. Pricing of options in the Heston model using the Feynman-Kac formula and physics-informed neural networks[J]. arXiv preprint arXiv:2407.15054, 2024.
- [9] GUO Y, et al. IC-PINN: Initial condition-enforced physics-informed neural networks for solving partial differential equations[J]. arXiv preprint arXiv:2404.01234, 2024.
- [10] LIU J, ZHU R, XU J, et al. PDE-AGENT: A toolchain-augmented multi-agent framework for PDE solving[J]. arXiv preprint arXiv:2512.16214, 2025.
- [11] BAYDIN A G, PEARLMUTTER B A, RADUL A A, et al. Automatic differentiation in machine learning: a survey[J]. Journal of Machine Learning Research, 2018, 18(153): 1–43.
- [12] ZAMXAKA S. Physics-informed neural networks for option pricing under the Black-Scholes and CEV models[D]. [S.l.]: University of Cape Town, 2023.
- [13] XIAO Y, et al. TradingAgents: Multi-agents LLM financial trading framework[J/OL]. arXiv preprint arXiv:2412.20138, 2024. <https://arxiv.org/abs/2412.20138>.
- [14] KINGMA D P, BA J. Adam: A method for stochastic optimization[J/OL]. arXiv preprint arXiv:1412.6980, 2014. <https://arxiv.org/abs/1412.6980>.
- [15] ALBRECHER H, MAYER P, SCHOUTENS W, et al. The little Heston trap[J]. Wilmott Magazine, 2007, January: 83–92.



-
- [16] LOUSKOS K, et al. Physics-informed neural networks for american option pricing[J]. arXiv preprint arXiv:2110.01990, 2021.



致 谢

感谢指导教师在本文研究过程中给予的悉心指导和宝贵建议。感谢上海科技大学信息科学与技术学院提供的计算资源支持，本文的实验在 309 实验室服务器上完成。

感谢 Raissi 等人开创性的 PINN 工作，以及 Guo 等人的 ICPINN 方法，为本文的统一框架设计提供了重要参考。感谢 DeepSeek 团队提供的开放 API，使本文的 LLM 路由层得以实现。

感谢 PyTorch 开源社区和 LaTeX 社区，本文的实现和排版均受益于这些优秀的开源工具。