



摘要

期权定价是金融工程的核心问题之一。Black-Scholes-Merton (BSM) 模型、常弹性方差 (CEV) 模型和Heston随机波动率模型是三大经典期权定价框架，分别适用于不同的市场假设。传统数值方法（有限差分、有限元）在求解高维偏微分方程 (PDE) 时面临维数灾难，而现有物理信息神经网络 (PINN) 研究大多针对单一模型，缺乏统一框架。

本文提出并实现了一个基于PINN与大语言模型 (LLM) 的统一期权定价框架。在PINN部分，通过软掩码 (Soft Mask) 机制和加法参数化输出，将BSM、CEV、Heston三大模型的PDE算子统一为单一参数化形式，由一个9维输入的深层全连接网络同时覆盖三种模型的解映射，无需分别训练独立网络。软掩码通过 $\tanh(\xi/0.05)^2$ 实现模型间的连续插值，当随机波动率参数 $\xi \rightarrow 0$ 时自动退化为BSM/CEV，当 ξ 较大时激活Heston的随机波动率项。加法参数化以Black-Scholes解析解为基线，网络学习绝对修正量，解决了乘法参数化在深度虚值区域退化的问题。对Heston模型采用改进约束PINN (ICPINN) 硬约束技术，通过输出变换精确满足终值条件。

在LLM部分，引入DeepSeek API作为智能路由层，通过结构化JSON输出实现可靠的参数提取和模型选择，支持中英文自然语言输入，使非专业用户无需了解模型细节即可完成期权定价。

实验结果表明，统一PINN在BSM模型上达到MAE=0.067 (ATM区域相对误差0.31%)，在Heston模型上达到MAE=0.031 (ATM区域相对误差0.52%)，均优于或持平于独立训练的PINN基线。特别地，独立训练的Heston PINN完全无法收敛，而统一框架成功解决了这一问题。LLM路由层在20个测试用例上实现了100%的模型选择准确率。单次推断耗时约2ms，远低于传统有限差分法的约500ms。

关键词： 物理信息神经网络；期权定价；Black-Scholes-Merton模型；Heston模型；大语言模型；统一框架

Abstract

Option pricing is one of the core problems in financial engineering. The Black-Scholes-Merton (BSM) model, the Constant Elasticity of Variance (CEV) model, and the Heston stochastic volatility model are three classical option pricing frameworks applicable to different market assumptions. Traditional numerical methods (finite difference, finite element) suffer from the curse of dimensionality when solving high-dimensional partial differential equations (PDEs), while existing Physics-Informed Neural Network (PINN) research mostly targets single models and lacks a unified framework.

This paper proposes and implements a unified option pricing framework based on PINN and Large Language Models (LLM). In the PINN component, a Soft Mask mechanism and additive parameterized output unify the PDE operators of BSM, CEV, and Heston into a single parameterized form. A single deep fully-connected network with 9-dimensional input simultaneously covers the solution mappings of all three models without training separate networks. The soft mask $\tanh(\xi/0.05)^2$ enables continuous interpolation between models: when $\xi \rightarrow 0$, it degrades to BSM/CEV; when ξ is large, it activates the stochastic volatility terms of Heston. The additive parameterization uses the Black-Scholes analytical solution as a baseline, with the network learning absolute corrections, resolving the degeneracy of multiplicative parameterization in deep out-of-the-money regions. The Improved Constrained PINN (ICPINN) hard constraint technique is applied to exactly satisfy the terminal condition via output transformation.

In the LLM component, the DeepSeek API serves as an intelligent routing layer, achieving reliable parameter extraction and model selection through structured JSON output, supporting both Chinese and English natural language input.

Experimental results show that the unified PINN achieves MAE=0.067 on BSM (ATM relative error 0.31%) and MAE=0.031 on Heston (ATM relative error 0.52%), matching or outperforming independently trained PINN baselines. Notably, the independently trained Heston PINN completely fails to converge, while the unified framework successfully resolves this issue. The LLM routing layer achieves 100% model selection accuracy on 20 test cases. Single inference takes approximately 2ms, far below the approximately 500ms of traditional finite difference methods.



Keywords: Physics-Informed Neural Networks; Option Pricing; Black-Scholes-Merton Model; Heston Model; Large Language Models; Unified Framework



目 录

第一章 引言	1
1.1 研究背景	1
1.2 现有工作的局限性	1
1.3 研究目标与贡献	2
1.4 论文结构	2
第二章 相关工作	3
2.1 期权定价模型	3
2.1.1 Black-Scholes-Merton模型	3
2.1.2 常弹性方差模型	3
2.1.3 Heston随机波动率模型	4
2.2 物理信息神经网络	4
2.2.1 基本原理	4
2.2.2 PINN在期权定价中的应用	4
2.2.3 三种独立PINN的复现与基准建立	5
2.2.4 现有工作的局限性	6
2.3 大语言模型辅助科学计算	6
2.4 本章小结	7
第三章 方法	8
3.1 三大期权定价模型	8
3.2 统一PDE算子	8
3.2.1 三大模型的PDE统一形式	8
3.2.2 软掩码机制	9
3.3 加法参数化输出	9
3.4 网络架构	9
3.4.1 输入特征	9
3.4.2 网络结构	10
3.4.3 终值条件的近似硬约束	10
3.5 损失函数	10
3.5.1 PDE残差损失	10
3.5.2 边界条件损失	10
3.5.3 数据驱动锚点损失	11



3.6	训练策略	11
3.7	LLM路由层	11
3.8	本章小结	12
第四章 实验		13
4.1	实验设置	13
4.1.1	模型参数	13
4.1.2	网络超参数	13
4.1.3	参考解	13
4.1.4	评估指标	14
4.2	训练过程分析	14
4.3	精度评估	15
4.3.1	整体精度	15
4.3.2	价格曲线对比	16
4.3.3	误差分布分析	16
4.4	推断速度	17
4.5	LLM路由层评估	17
4.6	消融实验	17
4.6.1	软掩码的作用	17
4.6.2	加法参数化的作用	17
4.6.3	数据锚点的作用	18
4.7	真实市场数据验证	18
4.7.1	数据与设置	18
4.7.2	参数校准方法	19
4.7.3	回测结果	19
4.7.4	分析	20
4.8	独立PINN与统一PINN精度对比	21
4.9	希腊字母计算	22
4.9.1	BSM希腊字母	22
4.9.2	Heston希腊字母	22
4.10	本章小结	23
第五章 结论		24
5.1	与现有工作的比较	24
5.2	工作总结	24
5.3	局限性	25
5.4	未来工作	25
5.5	本章小结	26



附录 A 代码架构与关键实现	27
A.1 项目目录结构	27
A.2 统一PINN核心模型	27
A.2.1 网络定义伪代码	27
A.2.2 统一PDE残差计算伪代码	28
A.3 LLM路由层实现	29
A.3.1 系统提示词	29
A.3.2 参数校验伪代码	30
A.4 参考解实现	30
A.4.1 BSM解析解	30
A.4.2 Heston半解析解（特征函数方法）	31
A.5 训练配置	31
参考文献	33
致谢	35



符号列表

状态变量

符号	含义
S	标的资产（股票）当前价格
$V(S, t)$	欧式期权价值（BSM/CEV模型）
$V(S, v, t)$	欧式期权价值（Heston模型）
v	瞬时方差（Heston模型中的随机波动率状态变量）
t	当前时刻
T	期权到期时刻
$\tau = T - t$	剩余到期时间

期权合约参数

符号	含义
K	期权执行价（Strike Price）
r	无风险利率（连续复利）

BSM模型参数

符号	含义
σ	标的资产的常数波动率（BSM）或尺度参数（CEV）
μ	标的资产的漂移率
W_t	标准布朗运动

CEV模型参数

符号	含义
β	弹性参数，控制波动率对股价的依赖程度； $\beta = 1$ 退化为BSM， $\beta < 1$ 产生杠杆效应

Heston模型参数

符号	含义
----	----



κ	方差过程的均值回归速度, $\kappa > 0$
θ	方差过程的长期均值 (长期方差)
ξ	方差过程的波动率 (vol-of-vol)
ρ	股价布朗运动 W_t^S 与方差布朗运动 W_t^v 的相关系数, $\rho \in (-1, 1)$
ν_0	初始瞬时方差
W_t^S	驱动股价过程的标准布朗运动
W_t^v	驱动方差过程的标准布朗运动

统一PINN框架符号

符号	含义
λ	模型参数向量 $(\sigma, \beta, \kappa, \theta, \xi, \rho)$
$\mathcal{F}[\cdot]$	统一PDE算子
mask	软掩码 $\tanh(\xi/0.05)^2$, 用于在BSM/CEV与Heston之间连续插值
σ_{eff}	等效波动率, 用于加法参数化中的Black-Scholes基线计算
V_{BS}	Black-Scholes解析解, 作为加法参数化的基线
$\hat{V}$	统一PINN的期权价格预测值
$\text{net}(x)$	神经网络输出的修正量 (以 K 为单位)
$\mathcal{L}$	总损失函数
$\mathcal{L}_{\text{pde}}$	PDE残差损失
$\mathcal{L}_{\text{bc}}$	边界条件损失
$\mathcal{L}_{\text{data}}$	数据驱动锚点损失
$w_{\text{pde}}, w_{\text{bc}}, w_{\text{data}}$	各损失项的权重系数
N_c	每训练步的PDE配点数
N_b	边界条件采样点数
N_d	数据锚点数
$\Phi(\cdot)$	标准正态累积分布函数

评估指标

符号	含义
MAE	平均绝对误差 (Mean Absolute Error)



RMSE 均方根误差 (Root Mean Square Error)

RelMAE_{ATM} 平值附近区域的平均相对误差

缩写

缩写	全称
----	----

BSM	Black-Scholes-Merton模型
-----	------------------------

CEV	Constant Elasticity of Variance, 常弹性方差模型
-----	--

PINN	Physics-Informed Neural Network, 物理信息神经网络
------	---

ICPINN	Improved Constrained PINN, 改进约束物理信息神经网络
--------	---

LLM	Large Language Model, 大语言模型
-----	-----------------------------

PDE	Partial Differential Equation, 偏微分方程
-----	--------------------------------------

ATM	At-The-Money, 平值期权 ($S \approx K$)
-----	--------------------------------------

OTM	Out-of-The-Money, 虚值期权 (看涨期权 $S < K$)
-----	--

ITM	In-The-Money, 实值期权 (看涨期权 $S > K$)
-----	------------------------------------

CIR	Cox-Ingersoll-Ross过程, 用于Heston模型的方差过程
-----	---------------------------------------

FFT	Fast Fourier Transform, 快速傅里叶变换
-----	---------------------------------

API	Application Programming Interface, 应用程序接口
-----	---



第一章 引言

1.1 研究背景

期权是金融衍生品市场的核心工具，广泛用于风险对冲与投机套利。自Black、Scholes与Merton于1973年提出BSM模型^[1,2]以来，期权定价理论经历了从常数波动率到局部波动率、再到随机波动率的演进。BSM模型具有封闭解析解，适用于短期定价，但无法解释市场中普遍存在的波动率微笑现象。Cox和Ross^[3]提出的CEV模型将波动率推广为依赖于标的价格的局部波动率，能够捕捉股票市场的杠杆效应。Heston^[4]进一步引入随机波动率过程，更准确地描述波动率微笑和厚尾收益率分布，但其二维PDE的数值求解代价显著高于一维情形。

传统数值方法（有限差分、有限元）在求解高维PDE时面临维数灾难：网格点数随维度指数增长，Heston这样的二维模型已需要大量计算资源，而更高维的随机波动率模型几乎无法实时求解。此外，传统工具要求用户手动指定模型类型和参数，对非专业用户门槛较高。

物理信息神经网络（PINN）^[5]将PDE残差直接嵌入损失函数，无需网格剖分，训练完成后可对任意输入即时推断（单次推断约2ms）。近年来，PINN已被应用于BSM^[6]、CEV^[7]、Heston^[8,9]等期权定价模型。与此同时，大语言模型（LLM）在自然语言理解和结构化信息提取方面取得了突破性进展^[10]，为构建自然语言驱动的科学计算接口提供了基础。

1.2 现有工作的局限性

现有PINN期权定价研究存在两方面主要不足。

模型孤立。现有工作（Dhiman等^[6]、Bae等^[7]、Hainaut等^[8]）均针对单一模型分别训练独立的PINN，三个模型之间无法共享网络权重，当需要同时支持多种模型时，必须维护多套独立的训练流程和模型文件。

交互门槛高。现有PINN工具要求用户手动指定模型类型和所有数值参数。选择合适的定价模型本身需要量化金融背景，普通用户难以判断在当前市场条件下应使用BSM、CEV还是Heston。



1.3 研究目标与贡献

本文构建一个基于PINN与LLM的统一期权定价框架，通过统一PDE算子将BSM、CEV、Heston三大模型纳入单一网络，并以LLM作为智能路由层实现自然语言交互。主要贡献如下。

统一PDE算子。设计软掩码机制 $\text{mask} = \tanh(\xi/0.05)^2$ ，将三大模型的扩散系数统一为 $a = (1 - \text{mask})\sigma^2 S^{2\beta} + \text{mask} \cdot \nu S^2$ ，实现模型间的连续插值，避免硬切换带来的梯度不连续问题。

加法参数化输出。以Black-Scholes解析解 V_{BS} 为基线，网络输出 $\hat{V} = V_{\text{BS}} + K \cdot \text{net}(x)$ ，解决了深度虚值区域 $V_{\text{BS}} \rightarrow 0$ 时的数值退化问题，同时提供良好的初始化。

LLM路由层。将DeepSeek LLM与统一PINN求解器结合，通过结构化JSON输出实现可靠的参数提取和模型选择，支持中英文自然语言输入。

实验结果：统一PINN在BSM（MAE=0.021，ATM相对误差0.21%）、CEV（MAE=0.065，ATM相对误差0.81%）和Heston（MAE=0.034，ATM相对误差0.38%）上均达到实用精度；LLM路由层在20个测试用例上实现了100%的模型选择准确率；消融实验验证了三个核心组件的必要性。

1.4 论文结构

第二章回顾三大期权定价模型的PDE形式、PINN方法的基本原理及其在期权定价中的应用，以及LLM辅助科学计算的进展。第三章介绍统一PINN框架，包括统一PDE算子、软掩码机制、加法参数化输出、网络架构、损失函数、训练策略和LLM路由层。第四章报告实验结果，包括精度评估、消融实验和真实SPY期权市场回测。第五章总结全文并讨论局限性与未来工作。



第二章 相关工作

2.1 期权定价模型

2.1.1 Black-Scholes-Merton模型

Black、Scholes与Merton于1973年提出了期权定价的奠基性框架^[1,2]。假设标的资产价格 S 服从几何布朗运动：

$$dS = \mu S dt + \sigma S dW_t, \quad (2.1)$$

其中 σ 为常数波动率， W_t 为标准布朗运动。通过无套利原理，欧式期权价值 $V(S, t)$ 满足BSM方程：

$$\frac{\partial V}{\partial t} + \frac{1}{2}\sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} + rS \frac{\partial V}{\partial S} - rV = 0, \quad (2.2)$$

其中 r 为无风险利率。欧式看涨期权具有封闭解析解（Black-Scholes公式）：

$$V_{BS}(S, t) = S\Phi(d_1) - Ke^{-r(T-t)}\Phi(d_2), \quad (2.3)$$

其中 $d_1 = \frac{\ln(S/K) + (r + \sigma^2/2)(T-t)}{\sigma\sqrt{T-t}}$ ， $d_2 = d_1 - \sigma\sqrt{T-t}$ ， $\Phi(\cdot)$ 为标准正态累积分布函数。BSM模型的主要局限在于假设波动率为常数，无法解释市场中普遍存在的波动率微笑现象。

2.1.2 常弹性方差模型

Cox和Ross^[3]提出了常弹性方差（CEV）模型，将扩散系数推广为依赖于标的价格的局部波动率：

$$dS = \mu S dt + \sigma S^\beta dW_t, \quad (2.4)$$

其中 β 为弹性参数。当 $\beta = 1$ 时退化为BSM；当 $\beta < 1$ 时，波动率随股价上涨而下降，能够捕捉股票市场的杠杆效应。对应的期权定价PDE为：

$$\frac{\partial V}{\partial t} + \frac{1}{2}\sigma^2 S^{2\beta} \frac{\partial^2 V}{\partial S^2} + rS \frac{\partial V}{\partial S} - rV = 0. \quad (2.5)$$

本文取 $\beta = 0.5$ （平方根过程）。Schroder^[11]指出， $\beta = 0.5$ 时CEV欧式看涨期权存在精确解析解（非中心卡方分布），本文以此作为CEV的参考基准。



2.1.3 Heston随机波动率模型

Heston^[4]将波动率建模为均值回归过程（CIR过程）：

$$dS = \mu S dt + \sqrt{v} S dW_t^S, \quad (2.6)$$

$$dv = \kappa(\theta - v) dt + \xi \sqrt{v} dW_t^v, \quad (2.7)$$

其中 v 为瞬时方差， κ 为均值回归速度， θ 为长期均值， ξ 为vol-of-vol， dW_t^S 与 dW_t^v 的相关系数为 ρ 。期权价值 $V(S, v, t)$ 满足二维PDE：

$$\frac{\partial V}{\partial t} + \frac{1}{2}vS^2\frac{\partial^2 V}{\partial S^2} + \rho\xi vS\frac{\partial^2 V}{\partial S\partial v} + \frac{1}{2}\xi^2v\frac{\partial^2 V}{\partial v^2} + rS\frac{\partial V}{\partial S} + \kappa(\theta - v)\frac{\partial V}{\partial v} - rV = 0. \quad (2.8)$$

Heston模型具有半解析解（特征函数方法与Gil-Pelaez反演），能够产生波动率微笑和厚尾收益率分布，在指数期权和外汇期权中被广泛使用。Feller条件 $2\kappa\theta > \xi^2$ 保证方差过程 v 始终为正。

2.2 物理信息神经网络

2.2.1 基本原理

物理信息神经网络（PINN）由Raissi等人^[5]于2019年提出，其核心思想是将PDE残差直接嵌入神经网络的损失函数。对于PDE $\mathcal{F}[u] = 0$ ，PINN的总损失为：

$$\mathcal{L} = w_{\text{pde}}\mathcal{L}_{\text{pde}} + w_{\text{ic}}\mathcal{L}_{\text{ic}} + w_{\text{bc}}\mathcal{L}_{\text{bc}}, \quad (2.9)$$

其中各项分别为配点处的PDE残差、初值条件和边界条件的均方误差， $w_{\text{pde}}, w_{\text{ic}}, w_{\text{bc}}$ 为权重超参数。PDE残差通过自动微分精确计算，无需有限差分近似。PINN无需网格剖分，训练完成后对任意输入的推断时间约为毫秒级。

2.2.2 PINN在期权定价中的应用

Dhiman和Hu^[6]率先将PINN应用于欧式和美式期权定价，提出了门控网络（gated network）结构，通过浅层分支与深层分支的加权组合分别捕捉解的简单特征与复杂特征。Zamxaka^[12]系统研究了PINN对BSM和CEV模型的求解，构建了参数化PINN，使单个网络可在不同参数设置下直接推断期权价格。Bae等人^[7]将PINN扩展至BSM、CEV及Dupire局部波动率模型，实现了期权价格与Greeks的同步计算。针对Heston模型，Hainaut和Casas^[8]构建了参数化PINN，通过对模型参数和合约特征的联合参数化，实现了训练一次、多参数组合即时定价。Guo等人^[9]提出了改进约束PINN（ICPINN），通过输出变换将终值条件硬编码进网络结构，减少损失函数中的冲突项，加速收敛。



2.2.3 三种独立PINN的复现与基准建立

为提供可靠的对比基准，本文对上述三类代表性PINN方法进行了独立复现。

BSM-PINN。严格复现Dhiman和Hu^[6]的门控网络结构：浅层分支（2层×64神经元，Tanh）与深层分支（4层×64神经元，Tanh）通过可学习的sigmoid门加权融合，输入为归一化的 $(S/S_{\max}, t/T)$ ，输出为归一化期权价值 $u = V/K$ 。相对于原论文，做了两处工程改动：（1）将上边界采样区间从单点 $S_{\max}$ 扩展为 $[0.8S_{\max}, S_{\max}]$ 的均匀分布；（2）采用CosineAnnealingLR学习率调度（从 10^{-3} 衰减至 10^{-5} ）。以BSM解析解为参考，在 $S \in [60, 160]$ 、 $t = 0$ 处评估，MAE=0.016，RelMAE=0.6%。

CEV-PINN。网络结构采用Dhiman和Hu^[6]的门控网络（hidden=64），将扩散系数替换为 $\sigma^2 S^{2\beta}$ ，参数取 $\sigma = 0.20$ 、 $\beta = 0.5$ 。参考基准采用Schroder^[11]非中心卡方分布解析解：当 $\beta = 0.5$ 时，CEV欧式看涨期权价格为

$$C = S_0 \left[1 - F(\lambda K^{2(1-\beta)}; d, \lambda S_0^{2(1-\beta)} e^{2r(1-\beta)T}) \right] - K e^{-rT} F(\lambda S_0^{2(1-\beta)} e^{2r(1-\beta)T}; d-2, \lambda K^{2(1-\beta)}), \quad (2.10)$$

其中 $F(\cdot; d, \lambda)$ 为自由度 $d = 2 + 1/(1-\beta)$ 、非中心参数 $\lambda = 2r/[\sigma^2(1-\beta)(e^{2r(1-\beta)T} - 1)]$ 的非中心卡方累积分布函数，可由`scipy.stats.ncx2`精确计算（精度 $\sim 10^{-15}$ ）。评估结果：MAE=0.074，RelMAE=1.69%（仅统计 $V^* > 0.5$ 的区域）。

Heston-ICPINN。严格按照Tan和Zhang^[9]的ICPINN方法复现，采用双网络结构：辅助网络（AuxNet，3层×40神经元，ELU激活）预训练以满足Dirichlet边界条件，主网络（MainNet，8层×40神经元，Tanh激活）学习PDE内部解。试验解形式为：

$$U(S, v, \tau) = \phi(S) + S_n \tau_n \cdot [A(S_n, v_n, \tau_n) + \text{NN}(S_n, v_n, \tau_n)], \quad (2.11)$$

其中 $\phi(S) = \max(S - K, 0)$ 为解析嵌入的终值条件， $S_n \tau_n$ 在 $\tau = 0$ 和 $S = 0$ 处自动为零，从而将Dirichlet边界条件硬编码进网络结构。训练参数严格遵循论文设置： $K = 100$ ， $r = 0.1$ ， $\kappa = 1$ ， $\theta = 0.08$ ， $\xi = 0.39$ ， $\rho = -0.93$ ，内部配点 $N_r = 10000$ ，边界配点 $N_{bc} = 500$ ，Adam优化器，初始学习率 10^{-3} ，StepLR调度（ $\gamma = 0.75$ ，每5000步），共训练20000轮。评估结果：MAE=0.35，RelMAE=3.9%（仅统计实值期权）。

然而，ICPINN方法的收敛性对参数集高度敏感。当将参数替换为统一框架所需的参数集（ $r = 0.05$ ， $\kappa = 2.0$ ， $\theta = 0.04$ ， $\xi = 0.3$ ， $\rho = -0.7$ ）时，训



练无法收敛。根本原因在于Fichera退化边界条件 ($v = 0$ 处)：在 $\kappa\theta$ 较小时，该边界条件的损失项主导整体损失（约为PDE残差的40倍），而aux_net已被冻结，main_net无法独立修正此偏差。为解决这一问题，本文在独立Heston-PINN中引入数据锚点机制：在 $t = 0$ 处预计算GL特征函数半解析价格作为监督信号，以权重 $w_{\text{data}} = 100$ 加入损失函数，将解锁定在正确分支上，从而在任意参数集下均能稳定收敛。

三种独立PINN的复现结果汇总于表 2.1。

表 2.1 三种独立PINN复现结果 ($S \in [60, 160]$, $t = 0$)

模型	参考基准	MAE	RelMAE	网络结构
BSM-PINN	解析解	0.016	0.6%	门控网络, 2+4层 $\times$ 64, Tanh
CEV-PINN	非中心卡方解析解	0.074	1.69%	门控网络, 2+4层 $\times$ 64, Tanh
Heston-ICPINN	特征函数半解析解	0.35	3.9%	AuxNet(3 $\times$ 40)+MainNet(8 $\times$ 40)

上述三个独立PINN验证了各模型PDE的可解性，并为后续统一框架提供了精度基准。

2.2.4 现有工作的局限性

综合上述工作，现有PINN期权定价研究存在两方面不足：各研究针对单一模型，缺乏统一框架同时支持多种定价模型；用户需手动指定模型类型和参数，无法通过自然语言描述需求。本文针对上述不足，提出将三大模型统一为单一参数化PINN的方法，具体设计见第三章。

2.3 大语言模型辅助科学计算

Liu等人^[10]提出了PDE-AGENT，一个工具链增强的多智能体框架，能够从自然语言描述出发，自动调用数值求解工具完成PDE的求解。该工作表明LLM具备理解PDE问题结构、选择合适求解策略的能力。在金融领域，Xiao等人^[13]提出了TradingAgents框架，通过多个专业化LLM智能体的协作完成金融交易决策，验证了LLM在金融场景下的参数提取与任务路由能力。

现代LLM（如GPT-4、DeepSeek等）能够通过约束输出格式（如JSON模式）可靠地从自然语言中提取结构化参数。本文的LLM路由层设计较PDE-AGENT更为轻量：LLM仅负责参数提取和模型选择，不参与PDE求解过程，因此延迟更低（约500ms至2000ms的API调用）、可靠性更高（结构化JSON输出避免了自由



文本解析的不确定性)。

2.4 本章小结

本章梳理了BSM、CEV、Heston三大期权定价模型的PDE形式，回顾了PINN在期权定价中的代表性工作，并介绍了LLM辅助科学计算的进展。现有PINN工作验证了神经网络求解期权定价PDE的可行性，但缺乏统一的多模型框架和自然语言交互能力。本文在此基础上构建了LLM与PINN相结合的统一期权定价系统，具体方法见第三章。



第三章 方法

3.1 三大期权定价模型

本文涉及的三大期权定价模型已在第 2.1 节详细介绍，此处仅概述各模型对统一框架设计的关键影响。BSM模型（式 (2.2)）以常数波动率 σ 为唯一随机性来源，存在封闭解析解，本文将其作为加法参数化的基线：

$$V_{BS}(S, \tau; \sigma) = S\Phi(d_1) - Ke^{-r\tau}\Phi(d_2), \quad (3.1)$$

$$d_1 = \frac{\ln(S/K) + (r + \sigma^2/2)\tau}{\sigma\sqrt{\tau}}, \quad d_2 = d_1 - \sigma\sqrt{\tau}. \quad (3.2)$$

CEV模型（式 (2.5)）将扩散系数推广为 $\sigma^2 S^{2\beta}$ ，本文取 $\beta = 0.5$ ，以Schroder非中心卡方解析解作为数据锚点。Heston模型（式 (2.8)）引入随机方差 v ，PDE升至二维，以特征函数半解析解作为数据锚点。三个模型的PDE在扩散系数结构上的差异，正是统一算子设计的出发点。

3.2 统一PDE算子

3.2.1 三大模型的PDE统一形式

BSM、CEV、Heston三大模型的PDE均可写为如下统一算子：

$$\mathcal{F}[V] = \frac{\partial V}{\partial t} + \frac{1}{2}a(S, v; \lambda) \frac{\partial^2 V}{\partial S^2} + b(S, v; \lambda) \frac{\partial^2 V}{\partial S \partial v} + \frac{1}{2}c(v; \lambda) \frac{\partial^2 V}{\partial v^2} + rS \frac{\partial V}{\partial S} + d(v; \lambda) \frac{\partial V}{\partial v} - rV = 0, \quad (3.3)$$

其中参数向量 $\lambda = (\sigma, \beta, \kappa, \theta, \xi, \rho)$ 控制各系数，具体对应关系如表 3.1 所示。

表 3.1 统一PDE算子系数与三大模型的对应关系

模型	$a(S, v; \lambda)$	$b(S, v; \lambda)$	$c(v; \lambda)$	$d(v; \lambda)$
BSM	$\sigma^2 S^2$	0	0	0
CEV	$\sigma^2 S^{2\beta}$	0	0	0
Heston	vS^2	$\rho\xi vS$	$\xi^2 v$	$\kappa(\theta - v)$

当 $\xi = 0$ 时， $b = c = d = 0$ ，统一算子自动退化为一维BSM/CEV方程；当 $\xi > 0$ 时，交叉项和 v 方向扩散项被激活，对应Heston的二维随机波动率结构。



3.2.2 软掩码机制

为实现三大模型之间的连续插值，本文引入软掩码：

$$\text{mask} = \tanh\left(\frac{\xi}{0.05}\right)^2. \quad (3.4)$$

当 $\xi \rightarrow 0$ 时， $\text{mask} \rightarrow 0$ ；当 $\xi = 0.3$ 时， $\text{mask} \approx 0.998$ 。利用软掩码，扩散系数 a 统一为：

$$a = (1 - \text{mask}) \cdot \sigma^2 S^{2\beta} + \text{mask} \cdot \nu S^2. \quad (3.5)$$

当 $\xi = 0$ 时， $a = \sigma^2 S^{2\beta}$ ，精确退化为BSM/CEV扩散项；当 $\xi = 0.3$ 时， $a \approx \nu S^2$ ，精确对应Heston扩散项。软掩码的连续插值特性使网络可以学习到平滑的参数依赖关系，避免了硬切换在 ξ 附近产生的梯度不连续问题（消融实验见第4.6节）。

3.3 加法参数化输出

直接用神经网络输出期权价格存在两个问题：初始化困难（随机初始化的网络输出量级约为 10^{-1} ，而期权价格量级约为 10^0 至 10^2 ）；以及深度虚值退化（乘法参数化 $V = V_{\text{BS}} \cdot (1 + \text{net})$ 在 $V_{\text{BS}} \rightarrow 0$ 时退化）。为此，本文采用加法参数化输出：

$$\hat{V}(S, \nu, t; \lambda) = V_{\text{BS}}(S, \tau; \sigma_{\text{eff}}) + K \cdot \text{net}(x), \quad (3.6)$$

其中等效波动率通过软掩码计算：

$$\sigma_{\text{eff}} = (1 - \text{mask}) \cdot \sigma + \text{mask} \cdot \sqrt{\nu}. \quad (3.7)$$

网络最后一层权重初始化为 $\mathcal{N}(0, 0.001^2)$ ，使训练开始时 $K \cdot \text{net} \approx 0$ ，网络从接近正确答案的位置开始优化。深度虚值时 $V_{\text{BS}} \rightarrow 0$ ，但 $K \cdot \text{net}$ 仍可输出非零修正，网络可以学习到CEV/Heston相对于BSM的价格差异。

3.4 网络架构

3.4.1 输入特征

网络输入为9维向量：

$$x = \left[\frac{S}{S_{\text{max}}}, \frac{\nu}{\nu_{\text{max}}}, \frac{t}{T}, \sigma, \beta, \kappa, \theta, \xi, \rho \right], \quad (3.8)$$

其中 $S_{\text{max}} = 300$ ， $\nu_{\text{max}} = 1$ 。归一化使各输入均落在 $[0, 1]$ 区间，避免不同量级的输入导致梯度不平衡。



3.4.2 网络结构

网络采用6层全连接结构，每层128个神经元，激活函数为tanh：

$$h_0 = x \in \mathbb{R}^9, \quad (3.9)$$

$$h_l = \tanh(W_l h_{l-1} + b_l), \quad l = 1, \dots, 6, \quad (3.10)$$

$$\text{net}(x) = W_7 h_6 + b_7 \in \mathbb{R}. \quad (3.11)$$

最后一层权重初始化为 $\mathcal{N}(0, 0.001^2)$ ，偏置初始化为0，确保训练开始时 $\text{net} \approx 0$ 。tanh激活函数光滑且高阶导数有界，适合PINN中需要计算二阶偏导数的场景。

3.4.3 终值条件的近似硬约束

当 $t = T$ 时， $\tau = T - t = 0$ ，Black-Scholes公式自动退化为终值条件 $V_{\text{BS}}(S, 0; \sigma_{\text{eff}}) = \max(S - K, 0)$ ；同时，网络最后一层的小初始化确保修正量 $K \cdot \text{net}$ 在训练初期接近0，不破坏终值条件的满足。这一设计参考了Guo等人^[9]的ICPINN方法。

3.5 损失函数

统一PINN的总损失由PDE残差、边界条件和数据锚点三部分组成：

$$\mathcal{L}(\theta) = w_{\text{pde}} \mathcal{L}_{\text{pde}} + w_{\text{bc}} \mathcal{L}_{\text{bc}} + w_{\text{data}} \mathcal{L}_{\text{data}}. \quad (3.12)$$

3.5.1 PDE残差损失

在求解域内随机采样 N_c 个配点 $\{(S_i, v_i, t_i)\}$ ，计算统一PDE算子的相对残差：

$$\mathcal{L}_{\text{pde}} = \frac{1}{N_c} \sum_{i=1}^{N_c} \left(\frac{\mathcal{F}[\hat{V}](S_i, v_i, t_i)}{|\hat{V}(S_i, v_i, t_i)| + 1} \right)^2. \quad (3.13)$$

分母中的 $|\hat{V}|+1$ 为相对残差归一化项，避免ATM区域的残差主导损失，使OTM区域也能获得足够的梯度信号。

3.5.2 边界条件损失

边界条件设置为：

$$V(0, v, t) = 0, \quad (3.14)$$

$$V(S_{\text{max}}, v, t) = S_{\text{max}} - K e^{-r(T-t)}, \quad (3.15)$$

$$V(S, v_{\text{max}}, t) \approx S. \quad (3.16)$$



边界条件损失为：

$$\mathcal{L}_{bc} = \frac{1}{N_b} \sum_{k=1}^{N_b} |\hat{V}(S_k, v_k, t_k) - g(S_k, v_k, t_k)|^2, \quad (3.17)$$

其中 g 为对应边界的目标值。

3.5.3 数据驱动锚点损失

纯PDE约束存在解不唯一的数值问题。本文在 $t = 0$ 处预计算参考解（BSM用解析解，CEV用Schroder非中心卡方解析解，Heston用特征函数半解析解），作为数据驱动锚点：

$$\mathcal{L}_{data} = \frac{1}{N_d} \sum_{j=1}^{N_d} (\hat{V}(S_j, v_j, 0) - V_j^*)^2, \quad (3.18)$$

其中 V_j^* 为参考解， $N_d = 20$ （每个模型各20个点）。损失权重设置为 $(w_{pde}, w_{bc}, w_{data}) = (1, 10, 100)$ ，其中 $w_{data} = 100$ 确保网络在已知解处精确拟合，防止PDE约束将解推向错误方向；消融实验验证了此权重组合的必要性（见第4.6节）。

3.6 训练策略

训练时从三个模型的参数分布中混合采样配点：每个训练步骤中，从BSM、CEV、Heston三个模型各采样 $N_c/3$ 个配点，拼接后计算统一PDE残差。这一策略确保网络在三种模型的参数空间中均匀训练，避免某一模型主导损失。

使用Adam优化器^[14]，初始学习率 10^{-3} ，余弦退火学习率调度（ $\eta_{min} = 10^{-5}$ ）。总训练轮数30000轮，在NVIDIA GPU上约需1小时。配点在求解域内均匀随机采样，每个训练步骤重新采样（online sampling），避免过拟合到固定配点集。

3.7 LLM路由层

三种定价模型分别适用于不同的市场假设，传统工具要求用户手动指定模型类型和全部数值参数。本文引入DeepSeek LLM作为智能路由层，使用户可以通过自然语言描述期权需求，由LLM自动完成模型选择和参数提取。

系统提示词将LLM角色定义为“期权定价参数提取器”，规定模型选择规则：仅提供 σ 则选BSM，提及 β 或“CEV”则选CEV，提供 $\kappa, \theta, \xi, \rho, v_0$ 或提及“Heston”/“stochastic volatility”则选Heston，默认BSM。对用户未提及的参数使用典型默认值（ $S = 100$ ， $K = 100$ ， $T = 1.0$ ， $r = 0.05$ ， $\sigma = 0.2$ ， $\beta = 0.5$ ， $v_0 = 0.04$ ， $\kappa = 2.0$ ， $\theta = 0.04$ ， $\xi = 0.3$ ， $\rho = -0.7$ ），并通过`response_format: json_object`强制输出合法JSON。LLM的输出遵循以下JSON Schema：



```
{
  "model": "bsm" | "cev" | "heston",
  "option_type": "call" | "put",
  "S": float, "K": float, "T": float, "r": float,
  "sigma": float, "beta": float,
  "v0": float, "kappa": float, "theta": float,
  "xi": float, "rho": float
}
```

系统在接收到JSON输出后，进行参数范围校验（如 $\sigma > 0$, $\beta \in (0, 1]$, $\xi > 0$, $\rho \in (-1, 1)$ ），对越界参数截断至合法范围，再传入统一PINN求解器。对于欧式看跌期权，通过看跌-看涨平价关系转换：

$$P = C - S + Ke^{-r(T-t)}. \quad (3.19)$$

完整定价流程为：用户输入自然语言描述（中英文均可）；LLM提取参数并选择模型；统一PINN加载预训练权重，构造参数向量 λ ；网络前向传播返回期权价格（约2ms）。

3.8 本章小结

本章介绍了基于PINN与LLM的统一期权定价框架。核心创新在于：（1）软掩码机制将三大模型的PDE算子统一为单一参数化形式；（2）加法参数化输出以Black-Scholes解析解为基线，解决了深度虚值区域的数值退化问题；（3）LLM路由层通过结构化输出实现可靠的参数提取和模型选择，并支持欧式看涨和看跌期权。下一章将报告实验结果。

第四章 实验

4.1 实验设置

4.1.1 模型参数

实验中使用的三大模型参数如表 4.1所示。

表 4.1 实验中使用的期权定价模型参数

参数	BSM	CEV	Heston
执行价 K	100	100	100
到期时间 T	1年	1年	1年
无风险利率 r	0.05	0.05	0.05
波动率 σ	0.2	0.2	—
弹性参数 β	1.0	0.5	—
均值回归速度 κ	—	—	2.0
长期方差 θ	—	—	0.04
vol-of-vol ξ	—	—	0.3
相关系数 ρ	—	—	-0.7
初始方差 v_0	0.04	0.04	0.04

4.1.2 网络超参数

统一PINN的网络超参数如表 4.2所示。

4.1.3 参考解

评估时使用以下参考解：**BSM**采用Black-Scholes解析公式（精确解）；**CEV**采用Crank-Nicolson有限差分法（网格 500×500 ，精度约 10^{-4} ）；**Heston**采用特征函数半解析法（Gil-Pelaez反演，精度约 10^{-4} ）。



表 4.2 统一PINN网络超参数

超参数	取值
网络层数（深度）	6
每层神经元数（宽度）	128
激活函数	tanh
输入维度	9
输出维度	1
优化器	Adam ^[14]
初始学习率	10^{-3}
学习率衰减	余弦退火 ($\eta_{\min} = 10^{-5}$)
训练步数	30000
每步配点数 N_c	每模型512点
边界点数 N_b	每模型500点
数据锚点数 N_d	每模型20点
损失权重($w_{\text{pde}}, w_{\text{bc}}, w_{\text{data}}$)	(1, 10, 100)

4.1.4 评估指标

使用以下指标评估精度：

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |\hat{V}_i - V_i^*|, \quad (4.1)$$

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{V}_i - V_i^*)^2}, \quad (4.2)$$

$$\text{RelMAE}_{\text{ATM}} = \frac{1}{|\mathcal{I}|} \sum_{i \in \mathcal{I}} \frac{|\hat{V}_i - V_i^*|}{|V_i^*| + \epsilon}, \quad (4.3)$$

其中 $\mathcal{I} = \{i : S_i \in [80, 120]\}$ 为平值附近区域（ATM）， $\epsilon = 10^{-8}$ 为数值稳定项。相对误差仅在ATM区域计算，避免深度虚值区域（ $V^* \approx 0$ ）导致的数值不稳定。

4.2 训练过程分析

图 4.1展示了统一PINN（v15版本）的训练损失曲线。

训练过程呈现以下规律：总损失从初始约0.5持续下降，余弦退火学习率调度使损失在后期持续缓慢下降；PDE残差损失（ $\mathcal{L}_{\text{pde}}$ ）主导总损失；边界条件损失（ $\mathcal{L}_{\text{bc}}$ ）和数据锚点损失（ $\mathcal{L}_{\text{data}}$ ）在训练早期快速下降至 10^{-5} 量级，说明边界




图 4.1 统一PINN训练损失曲线（v15，共30000轮，52个参数变体）。总损失在约5000轮后趋于稳定，PDE残差损失主导总损失，边界条件损失和数据锚点损失在训练早期快速下降。

条件和数据锚点均被精确满足。v15版本将训练参数变体从3个扩展至52个（覆盖真实市场校准参数范围），网络在更广泛的参数空间上训练，泛化能力显著提升。

4.3 精度评估

4.3.1 整体精度

表 4.3报告了统一PINN在三大模型上的精度评估结果（评估点 $S \in [60, 160]$ ，共50个均匀采样点）。

表 4.3 统一PINN（v15）在三大模型上的精度评估

模型	MAE	RMSE	RelMAE _{ATM}
BSM	0.0213	0.0260	0.21%
CEV ($\beta = 0.5$)	0.065	0.107	0.81%
Heston	0.0337	0.0470	0.38%

三大模型的ATM相对误差均低于1%，达到实用精度。v15版本相比早期版本有显著改善：BSM的MAE从0.067降至0.021（降幅68%），主要得益于训练参数覆盖了更广泛的 σ 范围（ $\sigma \in [0.13, 0.30]$ ）；CEV的ATM相对误差从37.95%降至0.81%，说明扩大参数范围后网络对CEV的拟合质量显著提升；Heston的MAE为0.034，ATM相对误差0.38%。



4.3.2 价格曲线对比

图 4.2展示了三大模型在 $t = 0$ 时的期权价格曲线，对比了统一PINN预测值与参考解。




图 4.2 三大模型期权价格曲线对比 ($t = 0, S \in [60, 160]$)。实线为参考解，虚线为统一PINN预测。左：BSM；中：CEV ($\beta = 0.5$)；右：Heston。

从价格曲线可以观察到：BSM的PINN预测与解析解高度吻合，误差主要集中在深度虚值区域 ($S < 70$)；CEV的PINN预测整体趋势正确，但在 $S \approx 80$ 至100区间存在约0.1的系统性偏差，这与CEV参考解的数值误差有关；Heston的PINN预测与半解析参考解吻合良好，最大误差约0.07，出现在深度实值区域 ($S > 140$)。

4.3.3 误差分布分析

图 4.3展示了三大模型的绝对误差随股价 S 的分布。




图 4.3 三大模型绝对误差分布 ($t = 0, S \in [60, 160]$)。误差主要集中在深度虚值 ($S < 70$) 和深度实值 ($S > 140$) 区域，ATM区域 ($S \in [80, 120]$) 误差最小。

误差分布呈现出典型的"U形"特征：ATM区域误差最小，深度虚值和深度实值区域误差较大。这与PINN的训练策略一致：均匀采样的配点在ATM区域密度较高（因为 $S \in [0, 300]$ 的均匀采样中， $[80, 120]$ 区间占比约13%），而深度虚值/实值区域的配点密度相对较低。



4.4 推断速度

统一PINN的推断速度在GPU上约为2ms，CPU上约为8ms（单次定价，批量输入），能够同时支持三种模型，无需针对不同参数重新计算。

4.5 LLM路由层评估

设计了20个测试用例，覆盖三种模型和中英文输入，LLM路由层实现了100%的模型选择准确率（20/20），所有数值参数均被正确提取，缺失参数均使用了合理的默认值。路由层对中英文混合输入、参数顺序不同、参数名称变体（如"vol-of-vol"、"波动率的波动率"、"xi"均被正确识别为 ξ ）均能正确处理，当用户未明确指定模型但提供了特定参数（如 $\kappa, \theta, \xi, \rho$ ）时，LLM能够正确推断应使用Heston模型。

4.6 消融实验

为验证各设计组件的必要性，本节进行消融实验，逐一去除统一框架的关键组件，观察对精度的影响。

4.6.1 软掩码的作用

将软掩码替换为硬切换（即当 $\xi = 0$ 时完全使用BSM/CEV系数，当 $\xi > 0$ 时完全使用Heston系数），重新训练后发现：BSM精度基本不变（MAE从0.021变为0.023）；Heston精度显著下降（MAE从0.034变为0.091），且训练过程出现梯度爆炸，需要降低学习率才能稳定训练。这说明软掩码的连续插值特性对Heston的稳定训练至关重要：硬切换在 ξ 附近产生不连续的梯度，导致网络难以同时优化BSM/CEV和Heston两种模式。

4.6.2 加法参数化的作用

将加法参数化替换为直接输出（网络直接预测期权价格，不加Black-Scholes基线），重新训练后发现：BSM精度下降（MAE从0.021变为0.089），训练需要更多轮次才能收敛；CEV精度下降（MAE从0.065变为0.172），深度虚值区域误差尤为突出；Heston精度下降（MAE从0.034变为0.078）。这验证了加法参数化的两个优势：良好的初始化（从Black-Scholes解析解出发）和深度虚值区域的稳定性。



4.6.3 数据锚点的作用

去除数据驱动锚点损失 ($w_{\text{data}} = 0$)，仅使用PDE残差和边界条件约束，重新训练后发现：**BSM精度下降**（MAE从0.021变为0.063），且训练结果不稳定（不同随机种子下结果差异较大）；**Heston精度下降**（MAE从0.034变为0.061）。这说明数据锚点对于确定解的唯一性至关重要：纯PDE约束在配点稀疏时存在多个局部最优，数据锚点提供了额外的约束，将解锁定在正确的分支上。

消融实验结果汇总如表 4.4所示。

表 4.4 消融实验结果（BSM和Heston的MAE）

配置	BSM MAE	Heston MAE
完整模型（软掩码+加法参数化+数据锚点）	0.021	0.034
去除软掩码（硬切换）	0.023	0.091
去除加法参数化（直接输出）	0.089	0.078
去除数据锚点（纯PDE约束）	0.063	0.061

消融实验表明，三个设计组件均对最终精度有显著贡献，其中加法参数化对BSM精度影响最大，软掩码对Heston稳定性影响最大，数据锚点对解的唯一性影响最大。

4.7 真实市场数据验证

4.7.1 数据与设置

为验证统一PINN在真实市场条件下的表现，本文使用CBOE提供的SPY（标普500 ETF）期权链数据（下载日期：2026年5月11日，SPY现价 $S = 739.75$ 美元）。无风险利率取美国1年期国债收益率 $r = 4.3\%$ 。

对每个到期日，筛选满足以下条件的看涨合约：隐含波动率 $IV \in (1\%, 200\%)$ 且最新成交价 > 0.10 美元；行权价 $K \in [0.85S, 1.15S]$ （ $ATM \pm 15\%$ ），确保Heston特征函数数值积分的稳定性。

共筛选出34个到期日，覆盖 $T \in [0.005, 2.60]$ 年的宽泛时间跨度，合约数量从40到164个不等，总计2394个合约。本节从中选取8个代表性到期日（覆盖 $T \in [0.03, 1.60]$ 年）进行详细分析。



4.7.2 参数校准方法

BSM校准：对每个合约用Brent法反解隐含波动率，取中位数作为全局 σ^* 。校准后的 σ^* 在0.13至0.17之间，反映了SPY期权市场的低波动率环境。

CEV校准：最小化加权MSE，局部波动率近似为 $\sigma_{\text{local}}(K) = \sigma \cdot (S/K)^{1-\beta}$ ，用L-BFGS-B多起点优化， $\beta \in (0.01, 1.0]$ 。校准结果显示 β 在0.01至1.0之间，部分到期日 $\beta \approx 1$ （退化为BSM），中长期到期日 β 在0.1至0.5之间，说明SPY期权存在显著的杠杆效应。

Heston校准：采用Little Heston Trap稳定公式^[15]进行半解析定价，8个起点L-BFGS-B优化，参数范围： $\kappa \in [0.05, 20]$ ， $\theta \in [0.001, 0.5]$ ， $\xi \in [0.01, 2.5]$ ， $\rho \in [-0.98, 0]$ ， $v_0 \in [0.001, 0.5]$ 。

PINN-BSM定价：将真实市场参数归一化至训练域（ $S' = 100$ ， $K' = 100 \cdot K/S$ ），使用BSM校准参数 σ^* 输入统一PINN，定价结果乘以 $S/100$ 还原至真实价格尺度。

PINN-Heston定价：使用Heston校准参数 $(\kappa^*, \theta^*, \xi^*, \rho^*, v_0^*)$ 输入统一PINN，同样进行归一化和反归一化处理。

4.7.3 回测结果

表 4.5报告了8个代表性到期日上五种方法相对市场价格的MAE（单位：美元）。

表 4.5 五种方法与SPY真实市场价格的MAE对比（单位：美元）

到期日	T (年)	n	BSM	CEV	Heston	PINN-BSM	PINN-Heston
May 22 2026	0.027	124	4.32	4.30	4.32	4.32	8.72
Jun 05 2026	0.066	127	4.27	4.28	4.28	4.33	9.02
Jun 30 2026	0.134	142	5.08	5.13	5.16	5.19	16.24
Aug 21 2026	0.277	44	2.37	1.64	0.86	2.38	4.17
Sep 30 2026	0.386	95	8.70	8.67	8.72	8.78	38.00
Dec 31 2026	0.638	122	10.04	10.15	10.09	10.06	15.84
Mar 19 2027	0.852	45	3.78	1.92	1.22	3.78	7.92
Dec 17 2027	1.600	45	3.58	1.57	1.45	3.58	25.18



4.7.4 分析

4.7.4.1 校准模型的层次结构

短期期权 ($T < 0.15$ 年): BSM、CEV、Heston三个校准模型的MAE几乎相同 (差距 < 0.1 美元), 说明短期期权的波动率微笑较平坦, 三个模型的额外自由度对定价贡献有限。在此区间, BSM的计算效率优势最为突出。

中长期期权 ($T > 0.25$ 年): Heston和CEV明显优于BSM。以Aug 21 ($T = 0.277$) 为例, Heston MAE=0.86, 仅为BSM MAE (2.37) 的36%; Mar 19 2027 ($T = 0.852$) 中, Heston MAE=1.22, CEV MAE=1.92, 而BSM MAE=3.78, Heston仅为BSM的32%。这体现了随机波动率模型在中长期期权定价中的优势: 随着到期时间延长, 波动率的随机性不可忽略, Heston模型通过 $\kappa, \theta, \xi, \rho$ 四个参数能够更准确地拟合波动率曲面的期限结构。

异常点 (Sep 30 2026, $T = 0.386$; Dec 31 2026, $T = 0.638$): 这两个到期日的三个校准模型MAE均高达8至10美元, 远高于相邻到期日。Sep 30的高误差可能与季末流动性变化有关; Dec 31的高误差可能与年末流动性下降、市场微结构噪声或该到期日合约数量较多 ($n = 122$) 导致的参数校准困难有关, 属于市场特殊情况, 不影响整体结论。

4.7.4.2 PINN-BSM的泛化能力

PINN-BSM的MAE与校准BSM几乎相同 (差距 < 0.1 美元, $T < 0.4$ 年), 表现出优异的泛化能力。v15版本的BSM训练参数覆盖 $\sigma \in [0.13, 0.30]$, 而真实市场的 σ^* 在0.13至0.17之间, 恰好落在训练范围内, 因此PINN-BSM能够精确复现校准BSM的定价结果, 验证了统一框架的参数泛化性。

4.7.4.3 PINN-Heston的局限性分析

PINN-Heston的MAE显著高于校准Heston (高出3至37美元), 这是本实验最重要的发现之一, 需要深入分析其原因。

(1) 参数域外推。 v15版本的Heston训练参数范围为 $\kappa \in [0.5, 8]$, $\xi \in [0.1, 0.5]$, $\rho \in [-0.9, -0.5]$ 。然而, SPY期权校准得到的Heston参数常超出此范围: κ 可高达10至15 (快速均值回归), ξ 可低至0.01 (低vol-of-vol), ρ 可接近-0.98 (强杠杆效应)。参数域外推导致PINN-Heston的预测严重偏离真实值。

(2) 价格尺度不匹配。 统一PINN以 $S = 100$ 为基准训练, 真实SPY价格 $S = 739.75$, 归一化后 $K' = 100 \cdot K / 739.75$, 行权价范围约为 $[85, 115]$, 与训练域一



致。然而，Heston模型的价格对 v_0 （初始方差）极为敏感，而 v_0 的归一化处理（ $v' = v/v_{\max}$ ， $v_{\max} = 1$ ）在真实市场参数下可能引入额外误差。

（3）统一框架的容量瓶颈。BSM仅有1个参数（ σ ），CEV有2个（ σ, β ），而Heston有5个（ $\kappa, \theta, \xi, \rho, v_0$ ）。统一PINN用同一个6层128宽的网络同时拟合三种模型，Heston的高维参数空间对网络容量要求远高于BSM/CEV，是PINN-Heston泛化能力不足的根本原因。

上述分析表明，PINN-Heston在当前统一框架下存在根本性局限，需要从架构层面入手加以解决，留作未来工作（见第 5.3 节）。

4.8 独立PINN与统一PINN精度对比

为验证统一框架的有效性，本节在相同参数集下对比独立PINN与统一PINN的定价精度。评估点取 $S \in [60, 160]$ ，共50个均匀采样点， $t = 0$ 。参考解：BSM使用Black-Scholes解析解，CEV使用Schroder非中心卡方解析解，Heston使用GL特征函数半解析解。所有方法均使用统一参数集（BSM： $\sigma = 0.20$ ；CEV： $\sigma = 0.20$ ， $\beta = 0.5$ ；Heston： $\kappa = 2.0$ ， $\theta = 0.04$ ， $\xi = 0.3$ ， $\rho = -0.7$ ， $v_0 = 0.04$ ；公共参数： $K = 100$ ， $T = 1$ ， $r = 0.05$ ）。独立Heston-PINN在此参数集下重新训练，引入GL数据锚点机制以确保收敛（见第 2.2.3 节）。

表 4.6 独立PINN与统一PINN精度对比（ $S \in [60, 160]$ ， $t = 0$ ，统一参数集）

方法	参考基准	MAE	RMSE	RelMAE
独立BSM-PINN	BS解析解	0.087	0.114	2.98%
独立CEV-PINN	Schroder解析解	0.102	0.131	1.88%
独立Heston-PINN	GL半解析解	0.383	0.491	9.91%
统一PINN（BSM）	BS解析解	0.003	0.005	0.065%
统一PINN（CEV）	Schroder解析解	0.037	0.049	0.887%
统一PINN（Heston）	GL半解析解	0.036	0.042	0.487%

从表 4.6 可以看出，统一PINN在三种模型上的精度均显著优于对应的独立PINN：BSM的RelMAE从2.98%降至0.065%（提升约46倍），CEV从1.88%降至0.887%（提升约2.1倍），Heston的MAE从0.383降至0.036（降幅91%）。独立Heston-PINN的高误差（RelMAE=9.91%）反映了纯PDE约束在二维退化方程上的收敛困难；统一框架通过软掩码机制和数据锚点的协同作用，将Heston精度提升至与BSM/CEV相当的水平。



图 4.4展示了三种模型的价格曲线对比。




图 4.4 独立PINN与统一PINN价格曲线对比。实线为参考解，虚线为独立PINN，点线为统一PINN。

4.9 希腊字母计算

PINN的一个重要优势是可通过自动微分直接计算希腊字母，无需额外推导。本节验证统一PINN计算的Delta、Gamma、Vega与解析/有限差分参考值的一致性。

4.9.1 BSM希腊字母

对BSM模型，Delta和Gamma通过对 S 的自动微分计算，Vega通过对 σ 的有限差分计算（步长 $h = 0.001$ ）。参考值为Black-Scholes解析公式。评估点取 $S \in \{90, 100, 110\}$ （虚值、平值、实值）， $t = 0$ ， $\sigma \in \{0.13, 0.17, 0.20, 0.25\}$ 。

表 4.7 BSM希腊字母精度（统一PINN vs 解析解，平均相对误差）

希腊字母	平均相对误差	最大相对误差	评估点数
Delta	0.03%	0.05%	12
Gamma	0.13%	0.28%	12
Vega	0.09%	0.19%	12

BSM希腊字母的平均相对误差均低于0.2%，表明统一PINN通过自动微分计算的一阶和二阶导数与解析解高度吻合。

4.9.2 Heston希腊字母

Heston模型无简单解析希腊字母，参考值通过对GL半解析价格的中心有限差分计算。Delta和Gamma对 S 差分，Vega对 v_0 差分。评估参数： $\kappa = 2.0$ ， $\theta = 0.04$ ， $\xi = 0.3$ ， $\rho = -0.7$ ， $v_0 = 0.04$ ， $K = 100$ ， $T = 1$ ， $r = 0.05$ 。



表 4.8 Heston希腊字母精度（统一PINN vs 有限差分参考解，平均相对误差）

希腊字母	平均相对误差	说明
Delta	1.83%	跨4组参数集平均
Gamma	11.41%	高 κ 、高 ξ 区域误差较大

Heston Delta的平均误差为1.83%，处于可接受范围。Gamma误差较高（11.41%），主要集中在高均值回归速度（ $\kappa = 5$ ）和高vol-of-vol（ $\xi = 0.5$ ）的极端参数区域，这些区域PDE系数变化剧烈，二阶导数的数值精度本身也受有限差分步长影响。在基准参数设置（ $\kappa = 2.0$ ， $\xi = 0.3$ ， $\rho = -0.7$ ）下，Delta误差约0.56%，Gamma误差约9.93%，与文献中同类工作的精度水平相当。

4.10 本章小结

统一PINN（v15）在三大模型上均达到实用精度：BSM（MAE=0.021，ATM相对误差0.21%）、CEV（MAE=0.065，ATM相对误差0.81%）、Heston（MAE=0.034，ATM相对误差0.38%）。消融实验验证了软掩码、加法参数化和数据锚点三个设计组件的必要性。LLM路由层在20个测试用例上实现了100%的模型选择准确率。真实市场回测（SPY期权链，2394个合约，34个到期日）表明：校准Heston和CEV在中长期期权（ $T > 0.25$ 年）上显著优于BSM；PINN-BSM在训练参数范围内具有优异的泛化能力；PINN-Heston因真实市场参数超出训练范围且受制于网络容量瓶颈，定价误差较大，进一步的架构改进是重要的未来工作方向。



第五章 结论

5.1 与现有工作的比较

本文的工作与现有PINN期权定价研究的主要区别体现在以下几个维度。在统一性方面，现有工作（Dhiman等^[6]、Bae等^[7]、Hainaut等^[8]）均针对单一模型，本文是首个将BSM、CEV、Heston三大模型统一在单一网络中的工作。统一框架的优势不仅在于工程上的简洁（一套训练流程、一个模型文件），更在于三种模型的联合训练带来了互相增益：BSM/CEV的简单结构为Heston提供了良好的初始化，有助于克服Heston二维PDE的收敛困难。在交互方式方面，现有PINN工具均为纯数值接口，用户需手动指定模型类型和参数。本文引入LLM路由层，支持自然语言输入，是PINN与LLM结合用于期权定价的首次尝试。与PDE-AGENT^[10]相比，本文的LLM仅作为路由层（参数提取+模型选择），不参与求解过程，因此延迟更低、可靠性更高。在约束处理方面，本文采用加法参数化输出，以Black-Scholes解析解为基线，这与Zamxaka^[12]的参数化PINN思路相近，但本文将其推广至多模型统一框架，并结合软掩码实现了模型间的连续插值。

5.2 工作总结

本文提出并实现了一个基于物理信息神经网络（PINN）与大语言模型（LLM）的统一期权定价框架，针对现有工作中模型孤立和交互门槛高两大问题，提出了系统性的解决方案。

在PINN部分，本文的核心贡献是统一PDE算子的设计。通过软掩码机制 $\text{mask} = \tanh(\xi/0.05)^2$ ，将BSM、CEV、Heston三大模型的扩散系数统一为单一参数化形式，由一个9维输入的深层全连接网络同时覆盖三种模型的解映射。加法参数化输出以Black-Scholes解析解为基线，网络学习绝对修正量，解决了乘法参数化在深度虚值区域的退化问题，同时提供了良好的初始化。ICPINN硬约束技术通过Black-Scholes公式的极限行为自然满足终值条件，无需在损失函数中加入额外约束项。在LLM部分，本文引入DeepSeek API作为智能路由层，通过结构化JSON输出实现可靠的参数提取和模型选择，支持中英文自然语言输入，使非专业用户无需了解模型细节即可完成期权定价。

实验结果验证了统一框架的有效性：统一PINN在BSM上达到MAE=0.021（ATM相对误差0.21%），在CEV上达到MAE=0.065（ATM相对误差0.81%），在Heston上



达到 $MAE=0.034$ （ATM相对误差0.38%）；推断速度（GPU约2ms）显著优于有限差分法和蒙特卡洛方法；LLM路由层在20个测试用例上实现了100%的模型选择准确率；消融实验验证了软掩码、加法参数化和数据锚点三个核心组件的必要性。

5.3 局限性

本文的工作存在以下局限性，需要在未来工作中进一步改进。

首先，CEV模型的ATM相对误差偏高（0.81%），部分原因是参考解（Crank-Nicolson有限差分）本身的数值误差，但PINN对CEV的求解质量也有改进空间，未来可以通过增加CEV专用的数据锚点、调整损失权重或引入自适应配点采样来提升精度。其次，PINN-Heston在真实市场数据上的泛化能力不足：v15的Heston训练参数范围（ $\kappa \in [0.5, 8]$ ， $\xi \in [0.1, 0.5]$ ， $\rho \in [-0.9, -0.5]$ ）无法覆盖SPY期权校准得到的极端参数（ κ 可达15， ξ 可低至0.01， ρ 可达-0.98），且统一框架用同一个6层128宽的网络同时拟合三种模型，Heston的5维参数空间对网络容量要求远高于BSM/CEV，构成根本性的容量瓶颈。此外，当前框架仅针对欧式看涨期权，不支持美式期权（需要处理自由边界问题）或奇异期权（障碍期权、亚式期权等）。

另一方面，LLM路由层依赖DeepSeek API，需要网络连接，且存在约500ms至2000ms的API调用延迟，未来可以考虑使用本地部署的小型LLM（如Qwen-7B）替代。当前框架仅输出点估计，不提供预测不确定性，而在金融应用中，不确定性量化（如置信区间）对风险管理至关重要，未来可以引入贝叶斯PINN或集成方法提供不确定性估计。

5.4 未来工作

基于上述局限性，本文提出以下未来工作方向。

参数化统一PINN方面，将当前固定参数的统一PINN扩展为真正的参数化版本，在参数空间 $(\sigma, \beta, \kappa, \theta, \xi, \rho)$ 上进行联合训练，使单个网络能够对任意参数组合即时定价，无需重新训练。这需要更大的网络容量和更精细的训练策略（如课程学习）。

A股市场适配方面，当前框架的训练参数范围针对美股市场校准，A股市场（上证50ETF期权、沪深300ETF期权）的隐含波动率特征与美股有显著差异：A股波动率通常更高（年化波动率常超过30%），且受政策因素影响，均值回归



速度 κ 和长期均值 θ 的分布与美股不同。未来可针对A股市场重新校准参数范围，并适配AkShare等国内数据接口，同时处理涨跌停限制、T+1交割等市场微结构特殊规则对定价的影响。

美式期权扩展方面，将统一框架扩展至美式期权，处理自由边界（最优执行边界）问题。美式期权的定价等价于最优停止问题，对应的PDE为变分不等式，需要引入惩罚函数法或互补条件。可以借鉴现有的PINN美式期权工作^[16]，将自由边界条件纳入统一损失函数。奇异期权方面，障碍期权（Barrier Options）的定价PDE与欧式期权相同，但边界条件不同（在障碍处 $V = 0$ 或 $V = \text{回扣}$ ），理论上可纳入本文框架，需额外设计障碍边界的网络处理方式；亚式期权（Asian Options）的收益依赖路径平均价格，引入路径依赖变量后维度更高，需要更大规模的网络和采样策略。

Greeks计算方面，利用PINN的自动微分能力，直接计算期权的Greeks（Delta、Gamma、Vega等），无需有限差分近似，这是PINN相对于传统数值方法的天然优势，在风险管理中具有重要价值。本地LLM部署方面，将LLM路由层替换为本地部署的小型语言模型，降低API依赖和调用延迟，同时保护用户的期权参数隐私。实盘数据验证方面，当前实验仅使用合成数据（参考解）进行验证，未来需要在真实市场期权数据上进行验证，评估统一PINN在实际市场条件下的定价精度。

5.5 本章小结

本文提出了基于PINN与LLM的统一期权定价框架，通过软掩码机制、加法参数化输出和LLM路由层，实现了BSM、CEV、Heston三大模型的统一求解和自然语言交互。实验结果表明，统一框架在精度和效率上均达到实用水平。本文的工作为PINN在金融工程中的应用提供了新的思路，也为LLM与科学计算工具的结合提供了一个具体的实践案例。



附录 A 代码架构与关键实现

本附录介绍统一PINN期权定价系统的代码架构和关键模块的实现细节，供读者复现实验结果参考。

A.1 项目目录结构

系统代码组织如下：

```
united_pinn/
├── unified_pinn.py      # 统一PINN核心模型
├── llm_router.py        # LLM路由层
├── reference_solvers.py  # 参考解（BSM/CEV/Heston）
├── train.py             # 训练脚本
├── evaluate.py          # 评估脚本
├── utils.py             # 工具函数（归一化、采样等）
└── configs/
    └── default.yaml     # 超参数配置文件
```

A.2 统一PINN核心模型

A.2.1 网络定义伪代码

```
class UnifiedPINN(nn.Module):
    输入维度：9 (S/Smax, v/vmax, t/T, sigma, beta,
                kappa, theta, xi, rho)
    网络结构：6层全连接，每层128神经元，tanh激活
    最后一层：权重初始化  $N(0, 0.001^2)$ ，偏置=0
```

```
前向传播 forward(S, v, t, lambda):
    # 1. 归一化输入
    x = [S/300, v/1, t/T, sigma, beta,
         kappa, theta, xi, rho]
```



2. 计算软掩码

```
mask = tanh(xi / 0.05)^2
```

3. 计算等效波动率

```
sigma_eff = (1-mask)*sigma + mask*sqrt(v)
```

4. 计算BS基线（解析公式）

```
V_BS = black_scholes(S, K, tau, r, sigma_eff)
```

5. 网络修正量

```
net_out = MLP(x) # 6层全连接
```

6. 加法参数化输出

```
V_hat = V_BS + K * net_out
```

```
return V_hat
```

A.2.2 统一PDE残差计算伪代码

```
def compute_pde_residual(model, S, v, t, lambda):
```

```
    # 使用自动微分计算偏导数
```

```
    V = model(S, v, t, lambda)
```

```
    dV_dt = autograd(V, t)
```

```
    dV_dS = autograd(V, S)
```

```
    d2V_dS2 = autograd(dV_dS, S)
```

```
    dV_dv = autograd(V, v)
```

```
    d2V_dv2 = autograd(dV_dv, v)
```

```
    d2V_dSdv = autograd(dV_dS, v)
```

```
    # 软掩码
```

```
    mask = tanh(xi / 0.05)^2
```

```
    # 统一系数
```

```
    a = (1-mask)*sigma^2*S^(2*beta) + mask*v*S^2
```



```
b = mask * rho * xi * v * S
c = mask * xi^2 * v
d = mask * kappa * (theta - v)

# 统一PDE算子
F = (dV_dt
      + 0.5*a*d2V_dS2
      + b*d2V_dSdv
      + 0.5*c*d2V_dv2
      + r*S*dV_dS
      + d*dV_dv
      - r*V)

# 相对归一化残差
residual = F / (|V| + 1)
return mean(residual^2)
```

A.3 LLM路由层实现

A.3.1 系统提示词

LLM路由层使用以下系统提示词（英文，以提高LLM的理解准确率）：

You are an option pricing parameter extractor.

Extract parameters from user input and output JSON.

Rules for model selection:

- If user mentions "Heston", "stochastic volatility", "vol-of-vol", kappa/theta/xi/rho: use "heston"
- If user mentions "CEV", "constant elasticity", "beta": use "cev"
- Otherwise: use "bsm"

Default values if not specified:

S=100, K=100, T=1.0, r=0.05, sigma=0.2,



beta=0.5, v0=0.04, kappa=2.0, theta=0.04,
xi=0.3, rho=-0.7

Output format (JSON only, no explanation):

```
{  
  "model": "bsm"|"cev"|"heston",  
  "option_type": "call"|"put",  
  "S": float, "K": float, "T": float, "r": float,  
  "sigma": float, "beta": float,  
  "v0": float, "kappa": float, "theta": float,  
  "xi": float, "rho": float  
}
```

A.3.2 参数校验伪代码

```
def validate_params(params):  
    # 范围校验与截断  
    params["sigma"] = clip(params["sigma"], 0.01, 2.0)  
    params["beta"] = clip(params["beta"], 0.1, 1.0)  
    params["kappa"] = clip(params["kappa"], 0.1, 10.0)  
    params["theta"] = clip(params["theta"], 0.001, 1.0)  
    params["xi"] = clip(params["xi"], 0.01, 2.0)  
    params["rho"] = clip(params["rho"], -0.99, 0.99)  
    params["v0"] = clip(params["v0"], 0.001, 1.0)  
    params["T"] = clip(params["T"], 0.01, 10.0)  
    params["S"] = clip(params["S"], 1.0, 1000.0)  
    params["K"] = clip(params["K"], 1.0, 1000.0)  
    return params
```

A.4 参考解实现

A.4.1 BSM解析解

```
def black_scholes(S, K, tau, r, sigma, option_type):  
    if tau <= 0:  
        if option_type == "call":
```



```

return max(S - K, 0)

else:
    return max(K - S, 0)

d1 = (log(S/K) + (r + 0.5*sigma^2)*tau) \
      / (sigma * sqrt(tau))
d2 = d1 - sigma * sqrt(tau)

if option_type == "call":
    return S*N(d1) - K*exp(-r*tau)*N(d2)
else:
    return K*exp(-r*tau)*N(-d2) - S*N(-d1)

```

A.4.2 Heston半解析解（特征函数方法）

Heston模型的欧式看涨期权价格通过特征函数方法计算：

$$V_{\text{Heston}} = S \cdot P_1 - K e^{-rT} \cdot P_2, \quad (\text{A.1})$$

其中 P_1 和 P_2 通过Gil-Pelaez反演公式计算：

$$P_j = \frac{1}{2} + \frac{1}{\pi} \int_0^\infty \text{Re} \left[\frac{e^{-i\phi \ln K} \varphi_j(\phi)}{i\phi} \right] d\phi, \quad j = 1, 2, \quad (\text{A.2})$$

其中 $\varphi_j(\phi)$ 为Heston模型的特征函数，具体形式见Heston（1993）原文。数值积分使用高斯-勒让德求积，积分上限截断为500，节点数为200，精度约 10^{-4} 。

A.5 训练配置

表 A.1列出了完整的训练配置，供复现实验参考。



表 A.1 统一PINN完整训练配置

配置项	取值
随机种子	42
训练设备	NVIDIA GPU (CUDA)
批大小 (配点数 N_c)	3000 (每模型1000)
边界点数 N_b	300
数据锚点数 N_d	60 (每模型20)
优化器	Adam ($\beta_1 = 0.9$, $\beta_2 = 0.999$)
初始学习率	1×10^{-3}
学习率调度	StepLR, 每5000步 $\times 0.5$
总训练步数	20000
损失权重($w_{\text{pde}}, w_{\text{bc}}, w_{\text{data}}$)	(1, 10, 100)
软掩码阈值	0.05
最后一层初始化	$\mathcal{N}(0, 0.001^2)$
BSM参数范围 (训练)	$\sigma \in [0.1, 0.5]$
CEV参数范围 (训练)	$\sigma \in [0.1, 0.5]$, $\beta \in [0.3, 0.9]$
Heston参数范围 (训练)	$\kappa \in [1, 5]$, $\theta \in [0.01, 0.09]$, $\xi \in [0.1, 0.5]$, $\rho \in [-0.9, -0.3]$



参考文献

- [1] BLACK F, SCHOLES M. The pricing of options and corporate liabilities[J]. Journal of Political Economy, 1973, 81(3): 637–654. DOI: [10.1086/260062](https://doi.org/10.1086/260062).
- [2] MERTON R C. Theory of rational option pricing[J]. The Bell Journal of Economics and Management Science, 1973, 4(1): 141–183. DOI: [10.2307/3003143](https://doi.org/10.2307/3003143).
- [3] COX J C, ROSS S A. The valuation of options for alternative stochastic processes[J]. Journal of Financial Economics, 1976, 3(1–2): 145–166. DOI: [10.1016/0304-405X\(76\)90023-4](https://doi.org/10.1016/0304-405X(76)90023-4).
- [4] HESTON S L. A closed-form solution for options with stochastic volatility with applications to bond and currency options[J]. The Review of Financial Studies, 1993, 6(2): 327–343. DOI: [10.1093/rfs/6.2.327](https://doi.org/10.1093/rfs/6.2.327).
- [5] RAISSI M, PERDIKARIS P, KARNIADAKIS G E. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations[J]. Journal of Computational Physics, 2019, 378: 686–707. DOI: [10.1016/j.jcp.2018.10.045](https://doi.org/10.1016/j.jcp.2018.10.045).
- [6] DHIMAN G, HU J. Physics-informed neural networks for option pricing[J]. arXiv preprint arXiv:2312.06711, 2023.
- [7] BAE H O, KANG S, LEE M. Numerical method using PINN for solving the Black-Scholes equation with local volatility[J]. arXiv preprint arXiv:2407.01990, 2024.
- [8] HAINAUT D, CASAS A. Pricing of options in the Heston model using the Feynman-Kac formula and physics-informed neural networks[J]. arXiv preprint arXiv:2407.15054, 2024.
- [9] GUO Y, et al. IC-PINN: Initial condition-enforced physics-informed neural networks for solving partial differential equations[J]. arXiv preprint arXiv:2404.01234, 2024.
- [10] LIU J, ZHU R, XU J, et al. PDE-AGENT: A toolchain-augmented multi-agent framework for PDE solving[J]. arXiv preprint arXiv:2512.16214, 2025.
- [11] SCHRODER M. Computing the constant elasticity of variance option pricing formula[J]. Journal of Finance, 1989, 44(1): 211–219.
- [12] ZAMXAKA S. Physics-informed neural networks for option pricing under the Black-Scholes and CEV models[D]. [S.l.]: University of Cape Town, 2023.
- [13] XIAO Y, et al. TradingAgents: Multi-agents LLM financial trading framework[J/OL]. arXiv preprint arXiv:2412.20138, 2024. <https://arxiv.org/abs/2412.20138>.
- [14] KINGMA D P, BA J. Adam: A method for stochastic optimization[J/OL]. arXiv preprint arXiv:1412.6980, 2014. <https://arxiv.org/abs/1412.6980>.
- [15] ALBRECHER H, MAYER P, SCHOUTENS W, et al. The little Heston trap[J]. Wilmott Magazine, 2007, January: 83–92.



-
- [16] LOUSKOS K, et al. Physics-informed neural networks for american option pricing[J]. arXiv preprint arXiv:2110.01990, 2021.



致 谢

感谢指导教师在本文研究过程中给予的悉心指导和宝贵建议。感谢上海科技大学信息科学与技术学院提供的计算资源支持，本文的实验在309实验室服务器上完成。

感谢Raissi等人开创性的PINN工作，以及Guo等人的ICPINN方法，为本文的统一框架设计提供了重要参考。感谢DeepSeek团队提供的开放API，使本文的LLM路由层得以实现。

感谢PyTorch开源社区和LaTeX社区，本文的实现和排版均受益于这些优秀的开源工具。